

딥러닝과 영상 모델

시험 전 복습 문제 - 문제지

구성	객관식 42문제 + 단답형 8문제 + 서술형 5문제
대목차 분포	이미지 딥러닝 모델 17 / 다양한 신경망 모델 17 / 이미지 모델 학습 전략 16
출제 기준	제공 교재의 개념·계산·비교·응용 내용을 중심으로 구성

※ 객관식은 가장 적절한 답 하나를 고르시오. 단답형은 핵심 용어 또는 계산 결과를 쓰시오. 서술형은 핵심 개념과 이유가 드러나도록 작성하시오.

I. 객관식 - 이미지 딥러닝 모델 (1~15)

1. CNN과 완전연결신경망(FCN)의 차이에 대한 설명으로 가장 적절한 것은?

- ① CNN은 입력의 공간 구조를 유지하며 지역 영역에 동일한 필터 가중치를 반복 적용한다.
- ② FCN은 이미지의 모든 위치에서 동일한 합성곱 필터를 공유한다.
- ③ CNN은 입력을 반드시 하나의 스칼라로 변환한 뒤 학습한다.
- ④ CNN의 합성곱 계층은 학습 가능한 파라미터를 사용하지 않는다.

2. 합성곱 계층에서 출력 채널 수를 직접 결정하는 값은 무엇인가?

- ① 입력 이미지의 가로 크기
- ② 필터(커널)의 개수
- ③ Stride의 값
- ④ Padding의 크기

3. 입력 크기가 32×32, 커널 3×3, stride=1, padding=1인 합성곱의 출력 공간 크기는?

- ① 30×30
- ② 31×31
- ③ 32×32
- ④ 34×34

4. Pooling의 일반적인 목적과 가장 거리가 먼 것은?

- ① feature map의 공간 크기를 줄인다.
- ② 연산량을 줄인다.
- ③ 작은 위치 변화에 대한 강건성을 높인다.
- ④ 학습 파라미터 수를 의도적으로 크게 증가시킨다.

5. CNN에서 층을 깊게 쌓을수록 수용영역(Receptive Field)이 커진다는 설명의 의미로 가장 적절한 것은?

- ① 한 뉴런이 고려할 수 있는 원본 입력의 영역이 점차 넓어진다.
- ② 항상 커널 크기 자체가 자동으로 커진다.
- ③ 입력 채널 수가 반드시 감소한다.
- ④ 출력 클래스 수가 자동으로 증가한다.

6. Stride를 1보다 크게 설정한 합성곱의 효과로 가장 적절한 것은?

- ① 필터 개수를 늘린다.
- ② 공간 해상도를 줄이면서 합성곱을 수행할 수 있다.
- ③ 출력 채널을 항상 1개로 만든다.
- ④ Padding이 자동으로 0이 된다.

7. 교재의 AlexNet Conv1에서 입력 $227 \times 227 \times 3$, 커널 11×11 , stride=4, padding=0, 필터 96개일 때 출력 크기는?

- ① $55 \times 55 \times 96$
- ② $56 \times 56 \times 96$
- ③ $55 \times 55 \times 3$
- ④ $227 \times 227 \times 96$

8. 교재의 AlexNet Conv1(입력 채널 3, 출력 채널 96, 11×11 커널)의 가중치와 편향을 합한 파라미터 수는?

- ① 11,616개
- ② 34,848개
- ③ 34,944개
- ④ 105,415,200개

9. 교재의 AlexNet Conv1 출력 $55 \times 55 \times 96$ 을 float32(4 Byte)로 저장할 때 필요한 메모리에 가장 가까운 값은?

- ① 약 284 KB
- ② 약 568 KB
- ③ 약 1,134 KB
- ④ 약 4,536 KB

10. 교재 기준으로 AlexNet Conv1의 곱셈+덧셈을 2 FLOPs로 계산했을 때 연산량에 가장 가까운 값은?

- ① 약 34.9K FLOPs
- ② 약 1.13M FLOPs
- ③ 약 52.7M FLOPs
- ④ 약 105.4M FLOPs

11. VGGNet의 대표적인 설계 특징으로 가장 적절한 것은?

- ① 매우 큰 단일 커널만 사용한다.
- ② 작은 3×3 합성곱을 반복적으로 깊게 쌓는다.
- ③ 순환 연결을 사용해 시퀀스를 처리한다.
- ④ Depthwise convolution만으로 전체 네트워크를 구성한다.

12. VGG16과 VGG19를 비교한 설명으로 가장 적절한 것은?

- ① VGG19가 더 많은 층을 사용한다.
- ② VGG16은 합성곱 계층을 사용하지 않는다.
- ③ VGG19는 Residual Connection을 핵심으로 한다.
- ④ 두 모델은 MobileNet의 Depthwise Separable Convolution을 사용한다.

13. ResNet의 Residual/Skip Connection을 도입한 주요 의도로 가장 적절한 것은?

- ① 입력을 항상 1차원 벡터로 만들기 위해
- ② 깊은 네트워크의 최적화 어려움과 성능 저하 문제를 완화하기 위해
- ③ 모든 합성곱을 1×1 로 바꾸기 위해
- ④ RNN의 hidden state를 제거하기 위해

14. MobileNet이 모바일·임베디드 환경에 적합하도록 사용하는 핵심 아이디어는?

- ① Depthwise Separable Convolution
- ② Bidirectional RNN
- ③ Beam Search
- ④ Masked Language Modeling

15. 다음 CNN 모델을 등장 순서에 가깝게 나열한 것은?

- ① VGGNet → AlexNet → MobileNet → ResNet
- ② AlexNet → VGGNet → ResNet → MobileNet
- ③ ResNet → AlexNet → VGGNet → MobileNet
- ④ MobileNet → ResNet → VGGNet → AlexNet

II. 객관식 - 다양한 신경망 모델 (16~29)

16. CNN의 핵심 한계로 교재에서 강조한 내용과 가장 가까운 것은?

- ① 지역 패턴을 전혀 학습하지 못한다.
- ② 순차적·장거리 의존성을 직접 다루는 데 제한이 있다.
- ③ 이미지 입력을 사용할 수 없다.
- ④ 학습 가능한 필터를 사용할 수 없다.

17. RNN의 hidden state에 대한 설명으로 옳은 것은?

- ① 시간이 진행될수록 차원이 계속 증가한다.
- ② 이전 시점의 정보를 다음 시점 계산에 전달하는 상태이다.
- ③ 입력과 완전히 독립적이다.
- ④ 오직 마지막 시점에서만 생성된다.

18. RNN이 대규모 학습에서 병렬화가 어려운 가장 직접적인 이유는?

- ① 각 시점 계산이 이전 시점의 hidden state에 의존하기 때문이다.
- ② 모든 가중치가 0으로 고정되기 때문이다.
- ③ 합성곱을 사용할 수 없기 때문이다.
- ④ 출력층이 존재하지 않기 때문이다.

19. 하나의 입력 시퀀스를 받아 하나의 결과를 출력하는 RNN 사용 형태에 가장 가까운 것은?

- ① One-to-One
- ② Many-to-One
- ③ One-to-Many
- ④ Many-to-Many

20. RNN을 시간축으로 펼친(unroll) 계산 그래프에 대한 설명으로 옳은 것은?

- ① 각 시점마다 서로 완전히 다른 모델을 학습한다.
- ② 동일한 RNN 셀의 파라미터가 여러 시점에서 반복 사용된다.
- ③ 시간축을 펼치면 hidden state가 사라진다.
- ④ 출력은 항상 모든 시점에서 하나만 존재한다.

21. 단순 RNN이 긴 시퀀스에서 장기 의존성을 학습하기 어려운 대표적 원인은?

- ① 기울기 소실 또는 폭발
- ② 출력 채널 수 부족
- ③ Pooling의 부재
- ④ Padding 값의 고정

22. LSTM이 단순 RNN의 장기 의존성 문제를 완화하기 위해 추가한 핵심 구성은?

- ① Cell state와 여러 gate
- ② Depthwise convolution
- ③ Pooling layer
- ④ Beam search

23. LSTM의 gate 구성으로 옳은 것은?

- ① Forget, Input, Output gate
- ② Query, Key, Value gate
- ③ Conv, Pool, FC gate
- ④ Train, Valid, Test gate

24. Attention 메커니즘이 RNN의 장거리 의존성 문제를 보완하는 방식으로 가장 적절한 것은?

- ① 멀리 떨어진 정보도 관련도에 따라 직접 참조할 수 있게 한다.
- ② 항상 가장 가까운 위치만 참조한다.
- ③ 모든 토큰의 순서를 제거한다.
- ④ hidden state의 차원을 1로 고정한다.

25. Self-Attention에 대한 설명으로 가장 적절한 것은?

- ① 하나의 입력 집합 내부 요소들이 서로의 관련도를 계산한다.
- ② 서로 다른 두 모달리티 사이에서만 사용할 수 있다.
- ③ 반드시 RNN의 마지막 hidden state만 사용한다.
- ④ CNN의 Max Pooling과 동일한 연산이다.

26. Attention에서 Query(Q), Key(K), Value(V)의 역할 설명으로 가장 적절한 것은?

- ① Q와 K의 관련도로 가중치를 만들고, 그 가중치로 V를 조합한다.
- ② Q만으로 최종 출력을 결정하고 K와 V는 사용하지 않는다.
- ③ K는 출력 클래스 수만 나타낸다.
- ④ V는 위치 인코딩 자체를 의미한다.

27. Vision Transformer(ViT)의 입력 처리 방식으로 옳은 것은?

- ① 이미지를 패치로 나눈 뒤 임베딩하고 위치 정보를 더한다.
- ② 이미지를 문자 토큰으로만 변환한다.
- ③ 모든 화소를 순차적으로 RNN에 하나씩만 입력한다.
- ④ Pooling만 반복해 이미지를 분류한다.

28. ViT와 CNN의 비교에 대한 설명으로 옳지 않은 것은?

- ① ViT는 self-attention을 통해 전역 관계를 비교적 직접 다룰 수 있다.
- ② CNN은 지역적 귀납 편향을 가진다.
- ③ ViT는 데이터가 적어도 언제나 CNN보다 높은 성능을 보장한다.
- ④ ViT는 대규모 데이터에서 강한 성능을 보일 수 있다.

29. Knowledge Distillation을 ViT 학습에 활용하는 설명으로 가장 적절한 것은?

- ① 교사 모델의 지식을 학생 모델이 학습하도록 전달한다.
- ② 모든 가중치를 0으로 초기화한다.
- ③ 학습 데이터를 무조건 절반으로 줄인다.
- ④ Attention을 제거하고 RNN으로 바꾼다.

III. 객관식 - 이미지 모델 학습 전략 (30~42)

30. 교재가 “좋은 구조만으로는 충분하지 않다”고 강조하는 이유로 가장 적절한 것은?

- ① 모델 구조는 학습 결과에 영향을 주지 않기 때문이다.
- ② 활성화 함수, 전처리, 초기화, 정규화, 학습률 등 훈련 전략이 성능과 수렴에 큰 영향을 주기 때문이다.
- ③ 이미지 모델은 학습이 필요 없기 때문이다.
- ④ 모든 모델은 같은 하이퍼파라미터를 사용해야 하기 때문이다.

31. 신경망에서 활성화 함수를 사용하는 핵심 이유는?

- ① 비선형성을 추가해 복잡한 함수를 표현하기 위해
- ② 모든 입력을 반드시 0으로 만들기 위해
- ③ 파라미터 수를 항상 절반으로 만들기 위해
- ④ 학습률을 자동 선택하기 위해

32. Sigmoid 활성화 함수의 대표적 단점으로 가장 적절한 것은?

- ① 출력 범위가 무한대이다.
- ② 포화 구간에서 기울기가 매우 작아져 기울기 소실이 생길 수 있다.
- ③ 음수 입력에서 항상 큰 양의 기울기를 만든다.
- ④ 비선형성이 전혀 없다.

33. Tanh에 대한 설명으로 옳은 것은?

- ① 출력 범위가 대체로 -1과 1 사이이며, 포화 구간에서 기울기 소실이 생길 수 있다.
- ② 음수 구간의 출력은 항상 0이다.
- ③ ReLU와 완전히 동일하다.
- ④ 출력이 항상 0과 1 사이이다.

34. ReLU에 대한 설명으로 가장 적절한 것은?

- ① 양수 입력에서는 입력을 그대로 통과시키고 음수에서는 0을 출력한다.
- ② 모든 입력을 0과 1 사이로 압축한다.
- ③ 음수 입력에서 항상 큰 양의 값을 출력한다.
- ④ 미분이 모든 구간에서 동일하게 0이다.

35. Leaky ReLU가 ReLU와 다른 핵심 특징은?

- ① 음수 영역에도 작은 기울기를 남긴다.
- ② 양수 영역을 모두 0으로 만든다.
- ③ 출력을 확률로 정규화한다.
- ④ 학습 가능한 파라미터가 항상 없다.

36. 데이터 전처리를 모델 입력 형식에 맞게 통일해야 하는 이유로 가장 적절한 것은?

- ① 모델이 기대하는 크기·스케일·정규화 방식에 일관된 입력을 제공하기 위해
- ② 이미지의 클래스 수를 자동 증가시키기 위해
- ③ 모든 이미지의 의미를 같게 만들기 위해
- ④ 학습 데이터를 삭제하기 위해

37. 모든 가중치를 0으로 초기화하는 방식의 문제로 가장 적절한 것은?

- ① 뉴런들이 동일한 값을 학습하며 대칭성이 깨지지 않을 수 있다.
- ② 항상 기울기 폭발이 즉시 발생한다.
- ③ 입력 데이터가 사라진다.
- ④ 파라미터 수가 자동 증가한다.

38. ReLU 계열 활성화 함수와 함께 사용하기 적절한 초기화 방법으로 교재에서 제시된 것은?

- ① Zero initialization
- ② He initialization
- ③ 항상 상수 1 초기화
- ④ 라벨 기반 초기화

39. 가중치 감소(Weight Decay)와 가장 직접적으로 관련된 것은?

- ① 가중치 크기에 페널티를 주어 과도하게 큰 파라미터를 억제한다.
- ② 매 epoch마다 클래스 수를 늘린다.
- ③ 모든 뉴런을 영구 삭제한다.
- ④ 입력 이미지를 패치로 나눈다.

40. Dropout의 학습 시 동작으로 가장 적절한 것은?

- ① 일부 뉴런의 출력을 확률적으로 비활성화한다.
- ② 모든 뉴런을 항상 사용한다.
- ③ 가중치를 모두 0으로 고정한다.
- ④ 학습률을 0으로 만든다.

41. 학습률 스케줄을 사용하는 목적에 가장 가까운 것은?

- ① 학습 진행에 따라 학습률을 조절해 초기 탐색과 후반 안정적 수렴을 함께 노린다.
- ② 파라미터 수를 늘리기 위해
- ③ 입력 채널 수를 자동 변경하기 위해
- ④ 정답 라벨을 생성하기 위해

42. 하이퍼파라미터에 대한 설명으로 옳은 것은?

- ① 학습 과정에서 경사하강법으로 직접 업데이트되는 가중치만을 의미한다.
- ② 학습률, 배치 크기, 옵티마이저 설정 등 학습 전에 정하거나 탐색하는 설정값을 포함한다.
- ③ 정답 라벨과 같은 의미이다.
- ④ 항상 모델 구조와 무관하게 동일한 값을 사용한다.

IV. 단답형 (43~50)

43. 입력 크기 63×63 , 커널 3×3 , stride=2, padding=1인 합성곱 계층의 출력 공간 크기(H×W)를 구하시오.

44. 입력 채널 3, 출력 채널 16, 커널 3×3 인 Conv 계층의 파라미터 수(가중치+편향)를 구하시오.

45. RNN에서 이전 시점의 정보를 다음 시점으로 전달하는 상태의 이름을 쓰시오.

46. LSTM의 세 가지 대표 gate 이름을 모두 쓰시오.

47. ViT에서 이미지 패치의 순서·위치 정보를 모델에 알려주기 위해 추가하는 정보를 쓰시오.

48. ReLU 계열 활성화 함수와 함께 사용하기 적합한 대표 가중치 초기화 방법을 쓰시오.

49. 학습 중 일부 뉴런을 확률적으로 비활성화하여 과적합을 줄이는 방법을 쓰시오.

50. 하이퍼파라미터 탐색의 대표적인 두 가지 방법을 쓰시오.

V. 서술형 (51~55)

51. CNN에서 합성곱, stride, pooling, 수용영역(receptive field)이 각각 어떤 역할을 하는지 설명하고, 이 요소들이 이미지 모델의 연산량과 특징 추출에 어떤 영향을 주는지 서술하시오.

52. AlexNet, VGGNet, ResNet, MobileNet의 핵심 설계 아이디어를 비교하고, 모델 구조가 발전하면서 해결하려 한 문제를 흐름에 따라 설명하시오.

53. 단순 RNN, LSTM, Attention, ViT를 장기 의존성 처리와 병렬화 관점에서 비교하여 설명하시오.

54. 좋은 모델 구조를 선택했음에도 학습이 실패하거나 성능이 낮을 수 있는 이유를 활성화 함수, 데이터 전처리, 가중치 초기화, 정규화 관점에서 설명하시오.

55. 훈련 손실은 감소하지만 검증 성능이 더 이상 좋아지지 않고, 후반 학습이 불안정한 이미지 분류 모델이 있다고 하자. 학습률 스케줄, 정규화, 하이퍼파라미터 탐색, 학습 종료 판단을 이용해 개선 전략을 서술하시오.
