

이미지 파운데이션 모델

시험 전 복습 문제

교재 기반 · Markdown 문제 형식/난이도 참고

구분	대목차	문항 수
1	AI 파운데이션 모델 개념 및 대표 모델	13
2	Vision-Language Model (VLM)	12
3	Small VLM과 파운데이션 모델들 소개	13
4	개인화, 합성데이터 활용 사례	12
	객관식 + 단답형	50
	서술형	5

구성: 객관식 42문제 + 단답형 8문제 = 50문제, 서술형 5문제

객관식은 가장 적절한 답 하나를 고르고, 단답형은 핵심 용어를 쓰시오.

1. AI 파운데이션 모델 개념 및 대표 모델

문항 분포: 13문제

문제 1. 교재에서 설명하는 AI 모델의 특징으로 가장 적절한 것은?

- ① 학습 때 본 데이터에 대해서만 작동해야 한다.
- ② 데이터로부터 형태가 결정되며, 학습 때 보지 못한 데이터에도 작동하는 것이 요구된다.
- ③ 입력과 출력의 관계는 항상 사람이 규칙으로 직접 작성한다.
- ④ 모든 AI 모델은 이미지 데이터만 입력으로 사용한다.

문제 2. Representation Learning에 대한 설명으로 옳은 것은?

- ① 데이터를 그대로 모두 기억하는 과정만을 의미한다.
- ② 데이터의 패턴을 학습하여 압축된 표현을 만들고 새로운 데이터에 일반화하는 능력과 관련된다.
- ③ 정답 라벨을 제거하는 전처리 기법이다.
- ④ 모델의 파라미터를 무조건 줄이는 양자화 기법이다.

문제 3. 파운데이션 모델 기반 개발 프로세스의 순서로 가장 적절한 것은?

- ① Training → Data Creation → Deployment → Adaptation → Data Curation
- ② Data Creation → Data Curation → Training → Adaptation → Deployment
- ③ Data Curation → Deployment → Training → Data Creation → Adaptation
- ④ Adaptation → Training → Data Creation → Deployment → Data Curation

문제 4. 파운데이션 모델 등장 이전의 일반적인 AI 개발 방식에 대한 설명으로 옳은 것은?

- ① 모든 작업에 하나의 동일한 모델을 그대로 사용했다.
- ② 작업별로 별도의 데이터와 모델 학습이 필요한 경우가 많았다.
- ③ 항상 멀티모달 입력을 사용했다.
- ④ 항상 프롬프트만 바꾸어 새로운 작업에 적응했다.

문제 5. CLIP의 핵심 학습 목표로 가장 적절한 것은?

- ① 이미지의 픽셀을 복원하는 것
- ② 언어와 이미지 사이의 유사도를 학습하는 것
- ③ 텍스트의 다음 단어만 예측하는 것
- ④ 이미지의 해상도를 높이는 것

문제 6. CLIP의 기본 구조에 대한 설명으로 옳은 것은?

- ① 이미지 인코더 하나만 사용한다.
- ② 텍스트 인코더와 이미지 인코더를 사용해 두 표현을 비교한다.
- ③ 언어 모델의 디코더만으로 이미지를 처리한다.
- ④ 이미지와 텍스트를 하나의 원시 벡터로 단순 연결한다.

문제 7. 교재의 CLIP 구조 설명에서 텍스트 인코더로 제시된 구조는?

- ① Transformer Encoder
- ② CNN Pooling Layer
- ③ LSTM Cell 하나
- ④ Diffusion U-Net

문제 8. Vision Transformer(ViT)의 이미지 처리 방식으로 옳은 것은?

- ① 이미지를 한 픽셀씩 RNN에 순서대로 입력한다.
- ② 이미지를 작은 패치로 나누고 선형 투영 및 위치 정보를 이용해 Transformer Encoder로 처리한다.
- ③ 이미지를 반드시 1차원 원-핫 벡터로 변환한다.
- ④ 이미지 전체를 하나의 스칼라 값으로 압축한 뒤 처리한다.

문제 9. CLIP의 대조학습(Contrastive Learning)에 대한 설명으로 가장 적절한 것은?

- ① 서로 대응하는 이미지-텍스트 쌍은 멀어지고, 대응하지 않는 쌍은 가까워지도록 학습한다.
- ② 서로 대응하는 이미지-텍스트 쌍은 가깝게, 대응하지 않는 쌍은 멀어지도록 학습한다.
- ③ 모든 이미지-텍스트 쌍의 유사도를 동일하게 만든다.
- ④ 텍스트만 사용하고 이미지는 학습에 사용하지 않는다.

문제 10. 교재에서 CLIP의 대조 손실과 연결해 설명하는 확률 정규화 방식은?

- ① Softmax
- ② ReLU
- ③ Max Pooling
- ④ Batch Normalization

문제 11. SigLIP에 대한 설명으로 옳은 것은?

- ① CLIP의 Softmax 기반 방식 대신 Sigmoid 손실을 사용한다.
- ② 이미지 인코더를 제거한 순수 언어 모델이다.
- ③ 세그멘테이션 전용 모델이다.
- ④ 항상 Softmax만 사용하며 CLIP과 학습 방식이 완전히 같다.

문제 12. 파운데이션 모델 개발 프로세스에서 사전학습된 모델을 특정 목적이나 작업에 맞게 조정하는 단계를 영어 한 단어로 쓰시오.

문제 13. 이미지와 텍스트처럼 서로 다른 모달리티의 표현을 서로 비교할 수 있도록 정렬하는 공통 표현 공간을 무엇이라 하는가?

2. Vision-Language Model (VLM)

문항 분포: 12문제

문제 14. Vision-Language Model(VLM)에 대한 설명으로 가장 적절한 것은?

- ① 이미지만 입력받고 텍스트는 처리하지 못하는 모델
- ② 비전 모델과 언어 모델을 결합하여 이미지와 텍스트를 함께 이해하도록 하는 모델
- ③ 음성만 합성하는 모델
- ④ 텍스트를 숫자로 변환하는 토큰나이저만을 의미하는 용어

문제 15. LLaVA의 대표적인 활용 예로 교재에 제시되지 않은 것은?

- ① Visual Question Answering
- ② 이미지 설명 생성
- ③ 시각 정보 기반 대화
- ④ 고전적인 K-means 군집화만 수행

문제 16. LLaVA 구조의 핵심 구성요소 조합으로 옳은 것은?

- ① Vision Encoder + Projection Layer + Language Model
- ② CNN + K-means + SVM
- ③ Tokenizer + Decision Tree + PCA
- ④ Diffusion Decoder + Max Pooling + RNN

문제 17. LLaVA의 Step 1 사전학습(Pre-training)에 대한 설명으로 옳은 것은?

- ① Vision Encoder와 Language Model을 모두 처음부터 다시 학습한다.
- ② Projection layer를 중심으로 적은 파라미터를 학습하고, 기존 Vision Encoder와 Language Model은 고정한다.
- ③ 이미지 없이 텍스트 데이터만 사용한다.
- ④ Projection layer를 제거한다.

문제 18. LLaVA의 Step 2 Fine-tuning에 대한 설명으로 가장 적절한 것은?

- ① Vision Encoder만 학습한다.
- ② Projection layer와 Language Model 등 필요한 부분을 미세 조정하고 Vision Encoder는 고정하는 형태가 제시된다.
- ③ 모든 파라미터를 항상 동결한다.
- ④ 이미지 표현을 사용하지 않는다.

문제 19. LLaVA의 시각 지시 데이터(visual instruction data) 생성에 대한 설명으로 옳은 것은?

- ① COCO의 이미지·캡션·바운딩박스 정보와 ChatGPT를 활용해 지시/응답 데이터를 생성한다.
- ② 모든 학습 데이터는 사람이 한 문장씩 직접 작성해야 한다.
- ③ 이미지 없이 음성 데이터만으로 생성한다.
- ④ K-means로 데이터 라벨을 자동 생성한다.

문제 20. LLaVA 학습 데이터의 응답 유형으로 교재에 제시된 조합은?

- ① 대화(conversation), 자세한 설명(detailed description), 복잡한 추론(complex reasoning)
- ② 회귀, 군집화, PCA
- ③ 음성합성, 음악분리, 잡음제거
- ④ 객체 추적, 압축, 암호화만

문제 21. Qwen2-VL의 M-RoPE(Multimodal Rotary Position Embedding)에 대한 설명으로 옳은 것은?

- ① 1D 텍스트, 2D 시각, 3D 비디오의 위치 정보를 다룬다.
- ② 이미지에서 위치 정보를 완전히 제거한다.
- ③ 텍스트 토큰에만 절대 위치를 한 번 더한다.
- ④ 음성 주파수만 인코딩한다.

문제 22. Qwen2.5-Omni의 “Omni” 특성을 가장 잘 설명한 것은?

- ① 텍스트만 읽을 수 있다.
- ② 읽고, 쓰고, 보고, 듣고, 말하는 멀티모달 상호작용을 목표로 한다.
- ③ 이미지는 처리하지만 오디오는 처리하지 않는다.
- ④ 추론 결과를 반드시 숫자 하나로만 출력한다.

문제 23. 의료 도메인 특화 파운데이션 모델에 대한 설명으로 옳은 것은?

- ① X-Ray, MRI, CT 등의 의료 이미지를 이용해 진단·설명 등의 작업을 수행할 수 있다.
- ② 의료 이미지를 사용할 수 없고 일반 자연영상만 처리한다.
- ③ 대조학습은 의료 모델에 사용할 수 없다.
- ④ 의료 도메인에서는 이미지-텍스트 관계 학습이 필요하지 않다.

문제 24. Qwen2-VL에서 1D 텍스트·2D 이미지·3D 비디오의 위치 정보를 다루기 위해 사용하는 위치 임베딩 기법의 약어를 쓰시오.

문제 25. LLaVA에서 Vision Encoder의 시각 표현을 Language Model이 사용할 수 있는 표현으로 연결해 주는 학습 가능한 층의 이름을 쓰시오.

3. Small VLM과 파운데이션 모델들 소개

문항 분포: 13문제

문제 26. Small VLM(sVLM)이 필요한 주요 이유로 가장 적절한 것은?

- ① VLM은 항상 성능이 낮기 때문에
- ② 대형 VLM의 서버·메모리 비용을 줄이고 개인 PC나 스마트폰 같은 환경에서 실행하기 위해
- ③ 이미지를 사용하지 않기 위해
- ④ 토큰화를 완전히 제거하기 위해

문제 27. SmolVLM에 대한 설명으로 옳은 것은?

- ① Hugging Face가 개발한 경량 VLM으로 소개된다.
- ② 세그멘테이션 전용 모델이다.
- ③ 텍스트를 처리하지 못한다.
- ④ 반드시 수십 GB 이상의 GPU 메모리만 사용한다.

문제 28. Moondream 0.5B의 양자화 예시가 시사하는 바와 가장 가까운 것은?

- ① 비트 수를 낮추면 모델 다운로드 크기와 실행 메모리를 줄일 수 있다.
- ② 양자화하면 모델 파일이 항상 더 커진다.
- ③ 4비트 양자화는 메모리 사용량을 증가시키지만 한다.
- ④ 양자화는 이미지 모델에는 적용할 수 없다.

문제 29. 한국어 sVLM을 별도로 고려할 필요성이 있는 이유로 교재에서 강조하는 것은?

- ① 한국어에는 이미지가 존재하지 않기 때문에
- ② 영어 중심 토큰라이저에서는 언어별 토큰 정보 밀도 차이로 비영어권 언어의 토큰 낭비가 발생할 수 있기 때문에
- ③ 한국어는 항상 한 글자당 한 토큰이기 때문에
- ④ 한국어 모델은 시각 인코더를 사용할 수 없기 때문에

문제 30. Set of Mark(SoM) prompting의 핵심 아이디어로 가장 적절한 것은?

- ① 이미지의 객체나 영역에 번호·마크를 부여하여 VLM의 시각적 grounding을 돕는다.
- ② 이미지에서 모든 객체를 지운다.
- ③ 텍스트 토큰을 무작위로 섞는다.
- ④ 이미지 해상도를 1×1로 줄인다.

문제 31. Grounding DINO에 대한 설명으로 옳은 것은?

- ① 텍스트 입력을 이용해 이미지 내 물체를 탐지할 수 있는 모델이다.
- ② 텍스트를 이미지로 생성하는 확산 모델이다.
- ③ 언어 번역 전용 모델이다.
- ④ 오직 하나의 고정 클래스만 탐지할 수 있다.

문제 32. 다음 중 이미지 생성(text-to-image) 모델이 아닌 것은?

- ① DALL-E 3
- ② Stable Diffusion
- ③ Midjourney
- ④ SAM(Segment Anything Model)

문제 33. 생성 모델링의 목표를 교재의 표기와 가장 가깝게 나타낸 것은?

- ① $p_{\text{model}}(x)$ 가 $p_{\text{data}}(x)$ 와 가능한 한 유사해지도록 학습한다.
- ② $p_{\text{model}}(x)$ 를 항상 0으로 만든다.
- ③ $p_{\text{data}}(x)$ 를 제거한다.
- ④ 실제 데이터 분포와 생성 모델 분포가 최대한 달라지도록 한다.

문제 34. Latent Diffusion Model(LDM)의 특징으로 옳은 것은?

- ① 고차원 픽셀 공간에서만 diffusion을 수행한다.
- ② 이미지를 저차원 latent embedding으로 변환한 뒤 diffusion 연산을 수행하여 효율을 높인다.
- ③ 텍스트 인코더 없이 반드시 분류만 수행한다.
- ④ 노이즈를 전혀 사용하지 않는다.

문제 35. 교재와 제공된 문제 기준에서 “오픈” 이미지 생성 모델에 해당하는 조합은?

- ① DALL-E 3, Midjourney
- ② Stable Diffusion, Latent Diffusion Model
- ③ SAM, Grounding DINO
- ④ Qwen2.5-Omni, LLaVA

문제 36. ControlNet의 역할로 가장 적절한 것은?

- ① 스케치, depth map, edge, pose 같은 조건 신호를 이용해 원하는 형태의 이미지 생성을 제어한다.
- ② 텍스트를 암호화한다.
- ③ 모델의 파라미터를 0개로 만든다.
- ④ 이미지와 텍스트의 토큰 수를 동일하게 만든다.

문제 37. 텍스트로 “판다”, “달리는 소녀” 등의 대상을 지정해 이미지에서 해당 물체를 탐지하는 모델 이름을 쓰시오.

문제 38. Latent Diffusion Model에서 픽셀 공간 대신 diffusion 연산을 수행하는 압축된 저차원 표현 공간을 무엇이라 하는가?

4. 개인화, 합성데이터 활용 사례

문항 분포: 12문제

문제 39. 개인화가 필요한 상황으로 교재의 학습 시작 예시와 가장 가까운 것은?

- ① 파운데이션 모델이 일반 데이터에서는 잘 동작하지만 특정 지역 관광·위성·의료 등 자신의 도메인에서 성능이 떨어지는 경우
- ② 모델이 이미 모든 도메인에서 완벽한 경우
- ③ 데이터와 모델이 전혀 필요 없는 경우
- ④ 오직 문서의 글꼴만 바꾸고 싶은 경우

문제 40. 프롬프트 디자인(prompt design)의 장점과 단점을 올바르게 묶은 것은?

- ① 장점: 추가 학습 없이 사용 가능 / 단점: 사람이 직접 프롬프트를 설계해야 하고 성능 향상이 제한적일 수 있음
- ② 장점: 항상 최고 성능 / 단점: 모델을 반드시 처음부터 재학습
- ③ 장점: 파라미터 전체 학습 / 단점: 입력 텍스트 사용 불가
- ④ 장점: 토큰라이저 제거 / 단점: 이미지 입력 불가

문제 41. 프롬프트 튜닝(prompt tuning)의 특징으로 옳은 것은?

- ① 사전학습 모델을 고정하고 학습 가능한 프롬프트를 최적화한다.
- ② 사전학습 모델의 모든 가중치를 반드시 새로 초기화한다.
- ③ 프롬프트를 사람이 정한 고정 문자열로만 사용하며 학습하지 않는다.
- ④ 이미지 생성 모델에는 사용할 수 없는 개념이다.

문제 42. 교재의 “모델 튜닝-프롬프트 튜닝-프롬프트 디자인” 비교에서 가장 적절한 설명은?

- ① 모델 튜닝은 일반적으로 성능 향상 여지가 크지만 학습 비용이 더 들 수 있고, 프롬프트 디자인은 효율적이지만 항상 폭이 제한될 수 있다.
- ② 프롬프트 디자인이 항상 가장 많은 파라미터를 학습한다.
- ③ 프롬프트 튜닝은 사전학습 모델 전체를 반드시 재학습한다.
- ④ 세 방법은 학습 대상과 비용이 완전히 동일하다.

문제 43. DreamBooth의 개인화 활용에 대한 설명으로 가장 적절한 것은?

- ① 소수의 특정 대상 이미지를 이용해 그 대상을 새로운 장면·상황으로 생성하도록 개인화한다.
- ② 텍스트를 숫자로 정렬하는 알고리즘이다.
- ③ 객체 탐지 박스만 생성하는 모델이다.
- ④ 언어 토큰의 위치 임베딩만 변경한다.

문제 44. 합성데이터 활용에서 Knowledge Distillation(Teacher-Student 학습)의 핵심 아이디어로 가장 적절한 것은?

- ① 큰 Teacher 모델의 지식이나 출력 정보를 작은 Target/Student 모델 학습에 활용한다.
- ② Student 모델이 Teacher 모델을 무작위로 삭제한다.
- ③ 실제 데이터를 절대 사용할 수 없게 만든다.
- ④ 이미지를 모두 흑백으로 변환한다.

문제 45. InstructPix2Pix에서 지도학습용 데이터셋의 핵심 구성으로 가장 적절한 것은?

- ① 이미지 편집 지시사항 + 편집 전 이미지 + 편집 후 이미지
- ② 오직 편집 후 이미지만
- ③ 오직 숫자 라벨 하나
- ④ 음성 파일 + 군집 번호

문제 46. 합성데이터를 사용하는 이유로 교재의 문제의식과 가장 가까운 것은?

- ① 개인정보·비용·특수 장비 등의 이유로 현실 데이터를 충분히 확보하기 어려운 문제를 보완하기 위해
- ② 실제 데이터가 많을수록 성능이 반드시 나빠지기 때문에
- ③ 모든 라벨을 삭제하기 위해
- ④ 모델의 입력을 없애기 위해

문제 47. Sora 사례와 관련해 교재가 제시하는 응용 방향으로 옳은 것은?

- ① 텍스트-비디오 생성 결과를 활용한 3D 장면 복원 가능성을 탐색한다.
- ② 오직 표 계산만 수행한다.
- ③ 비디오를 입력받아 텍스트를 절대 생성하지 못한다.
- ④ K-means 중심점을 계산한다.

문제 48. RAG(Retrieval Augmented Generation)의 장점으로 교재에 제시되지 않은 것은?

- ① 추가 학습 없이 최신 정보 활용 가능
- ② 검색과 언어모델 결합을 통한 개인 맞춤형 답변 가능
- ③ Verification을 통한 환각 감소에 도움
- ④ 모델이 외부 정보를 절대 검색하지 못하게 함

문제 49. 사전학습 모델 전체가 아니라 일부 파라미터나 프롬프트 등 제한된 요소를 조정하여 효율적으로 미세 조정하는 방법을 통칭하는 약어를 쓰시오.

문제 50. 검색 결과를 언어 모델의 생성에 결합하여 최신 정보·개인화·검증을 지원하는 기법의 약어를 쓰시오.

서술형 문제

핵심 개념의 관계와 모델별 역할을 문장으로 설명해 보시오.

문제 51. 파운데이션 모델의 개념과 Representation Learning을 설명하고, 파운데이션 모델 기반 개발 프로세스(Data Creation부터 Deployment까지)를 순서대로 서술하시오. 이어서 CLIP과 SigLIP의 학습 방식 차이를 함께 설명하시오.

문제 52. LLaVA를 예로 들어 VLM의 기본 구조를 설명하고, LLaVA의 Step 1 사전학습과 Step 2 Fine-tuning에서 어떤 구성요소를 학습/고정하는지 비교하여 서술하시오. 또한 시각 지시 데이터가 어떻게 만들어지는지도 설명하시오.

문제 53. Small VLM이 필요한 이유를 설명하고, SmolVLM·Moondream과 같은 경량 모델에서 메모리 효율이 왜 중요한지 서술하시오. 이어서 영어 중심 토크나이저가 한국어 등 비영어권 언어에 불리할 수 있는 이유를 토큰 정보 밀도 관점에서 설명하시오.

문제 54. 다음 네 모델의 역할을 서로 비교하여 서술하시오: SAM, Grounding DINO, Latent Diffusion Model(LDM), ControlNet. 각 모델이 어떤 입력과 결과를 다루는지 중심으로 설명하시오.

문제 55. 파운데이션 모델을 특정 사용자나 도메인에 맞게 활용하는 방법을 프롬프트 디자인, 프롬프트 튜닝, 모델 미세조정 관점에서 비교하시오. DreamBooth 개인화와 합성데이터(InstructPix2Pix), RAG가 어떤 문제를 해결하는지도 함께 설명하시오.
