

자연어 처리 기본

복습 문제 - 문제지

시험 전 복습 · 개념 확인용

범위

워드 임베딩과 순환신경망 기반 모델

자연어 생성 모델

Transformer

사전 학습 기반 언어 모델

문항 구성 및 분포

총 50 문제(객관식 42 + 단답형 8) + 서술형 5 문제

대목차	문항 범위	문항 수
I. 워드 임베딩과 순환신경망 기반 모델	Q1-Q13	13
II. 자연어 생성 모델	Q14-Q26	13
III. Transformer	Q27-Q38	12
IV. 사전 학습 기반 언어 모델	Q39-Q50	12

풀이 안내: 객관식은 가장 적절한 답 하나를 고르고, 단답형은 핵심 용어를 정확히 쓰시오. 서술형은 핵심 개념과 원인-결과 관계가 드러나도록 작성하시오.

I. 워드 임베딩과 순환신경망 기반 모델

문제 1. 원-핫 인코딩(One-hot Encoding)의 한계에 대한 설명으로 옳지 않은 것은?

- ① 어휘 수가 커질수록 벡터 차원이 커진다.
- ② 대부분의 원소가 0 이어서 희소한 표현이 된다.
- ③ 서로 다른 단어 사이의 의미적 유사성을 자연스럽게 반영한다.
- ④ 서로 다른 단어의 원-핫 벡터는 직교하는 형태가 된다.

문제 2. 워드 임베딩(Word Embedding)에 대한 설명으로 가장 적절한 것은?

- ① 각 단어를 어휘 크기와 동일한 희소 이진 벡터로만 표현한다.
- ② 단어를 밀집된 실수 벡터로 표현하여 의미적 관계를 반영할 수 있다.
- ③ 단어의 순서를 제거하기 위해 사용하는 규칙 기반 전처리이다.
- ④ 문장 전체를 하나의 범주형 라벨로 변환하는 방법이다.

문제 3. Word2Vec의 핵심 아이디어에 가장 가까운 설명은?

- ① 단어와 주변 단어의 관계를 예측하는 방식으로 단어 표현을 학습한다.
- ② 모든 단어를 사전에 정의된 정수 하나로만 표현한다.
- ③ 문장 전체의 길이를 고정한 뒤 이미지처럼 합성곱한다.
- ④ 정답 라벨 없이 단어의 등장 횟수만 저장한다.

문제 4. CBOW와 Skip-gram의 예측 방향을 올바르게 연결한 것은?

- ① CBOW: 중심 단어→주변 단어 / Skip-gram: 주변 단어→중심 단어
- ② CBOW: 주변 단어→중심 단어 / Skip-gram: 중심 단어→주변 단어
- ③ 두 방법 모두 중심 단어→문장 전체를 예측한다.
- ④ 두 방법 모두 주변 단어의 순서를 직접 예측한다.

문제 5. 교재에서 설명한 CBOW와 Skip-gram의 일반적인 특성으로 옳은 것은?

- ① CBOW는 학습이 비교적 빠르고 빈출 단어에 강한 편이다.
- ② CBOW는 희귀 단어 학습에 항상 Skip-gram보다 강하다.
- ③ Skip-gram은 주변 단어를 입력으로 중심 단어를 예측한다.
- ④ Skip-gram은 지도학습이고 CBOW는 비지도학습이다.

문제 6. 순차적 데이터(Sequential Data)의 특징으로 가장 적절한 것은?

- ① 데이터의 순서를 바꾸어도 의미가 항상 동일하다.
- ② 현재 요소가 이전 요소들과의 관계에 영향을 받을 수 있다.
- ③ 입력 길이는 항상 고정되어야 한다.
- ④ 시간적 의존성은 학습 대상이 아니다.

문제 7. RNN이 FNN이나 일반적인 CNN과 구별되는 핵심 특징은?

- ① 은닉 상태를 다음 시점으로 전달하는 순환 구조를 가진다.
- ② 입력 데이터를 항상 고정 길이의 1 차원 벡터로만 받는다.
- ③ 순서 정보가 모델에 들어오지 않는다.
- ④ 학습 가능한 파라미터가 존재하지 않는다.

문제 8. RNN의 hidden state에 대한 설명으로 옳은 것은?

- ① 각 시점에서 이전 정보와 현재 입력을 반영한 내부 상태이다.
- ② 시간이 지날수록 차원이 반드시 계속 증가한다.
- ③ 출력과 무관한 고정된 임의 벡터이다.
- ④ 첫 시점에서만 사용되고 이후에는 폐기된다.

문제 9. 기본 RNN 이 긴 문맥의 장기 의존성을 학습하기 어려운 대표적 이유는?

- ① 모든 입력이 원-핫 벡터이기 때문이다.
- ② 역전파 과정에서 기울기 소실이 발생할 수 있기 때문이다.
- ③ 은닉 상태를 사용하지 않기 때문이다.
- ④ 항상 병렬 연산만 수행하기 때문이다.

문제 10. LSTM 이 기본 RNN 에 비해 장기 정보를 더 잘 유지하도록 도입한 핵심 요소는?

- ① Convolution filter
- ② Cell state 와 게이트 구조
- ③ Pooling layer
- ④ One-hot decoder

문제 11. LSTM 의 게이트와 역할에 대한 연결로 가장 적절한 것은?

- ① Forget gate: 유지하거나 버릴 정보를 조절한다.
- ② Input gate: 항상 모든 과거 정보를 삭제한다.
- ③ Output gate: 입력 문장을 원-핫 벡터로 바꾼다.
- ④ 세 게이트는 학습 과정에서 사용되지 않는다.

문제 12. LSTM 에서 정보의 흐름을 조절하는 세 가지 게이트의 이름을 모두 쓰시오.

문제 13. CBOW 와 Skip-gram 의 예측 방향을 각각 한 문장으로 쓰시오.

II. 자연어 생성 모델

문제 14. 언어 모델(Language Model)의 역할로 가장 적절한 것은?

- ① 주어진 문맥을 바탕으로 다음 단어(토큰)의 확률을 예측한다.
- ② 모든 문장을 고정 길이 이미지로 변환한다.
- ③ 문장 안의 모든 단어를 동시에 삭제한다.
- ④ 입력 문장의 클래스 라벨만 출력한다.

문제 15. 교재의 N-gram 언어 모델 설명으로 옳은 것은?

- ① 항상 문서 전체를 고려해 다음 단어를 예측한다.
- ② 직전 N 개의 단어만 고려하여 다음 단어를 예측한다.
- ③ 단어 순서를 전혀 사용하지 않는다.
- ④ 이미지 패치의 확률을 예측하는 모델이다.

문제 16. Seq2Seq의 기본 구조에 대한 설명으로 옳은 것은?

- ① 인코더가 입력 시퀀스를 처리하고, 디코더가 출력 시퀀스를 생성한다.
- ② 디코더가 입력 시퀀스를 처리하고, 인코더가 출력 시퀀스를 생성한다.
- ③ 인코더와 디코더는 서로 독립적으로 학습되어야 한다.
- ④ 입력과 출력의 길이는 반드시 같아야 한다.

문제 17. 기본 Seq2Seq에서 인코더가 수행하는 역할로 가장 적절한 것은?

- ① 입력 시퀀스를 고정 차원의 문맥 표현(Context)으로 변환한다.
- ② 출력 정답을 직접 분류 라벨로 바꾼다.
- ③ 미래 단어를 마스킹한다.
- ④ 입력 문장의 길이를 출력과 같게 강제한다.

문제 18. Seq2Seq 모델의 장점으로 옳은 것은?

- ① 입력과 출력 시퀀스의 길이가 달라도 처리할 수 있다.
- ② 항상 하나의 단어만 출력할 수 있다.
- ③ 출력 생성에 인코더 정보가 필요 없다.
- ④ 역전파를 통한 통합 학습이 불가능하다.

문제 19. Seq2Seq의 Bottleneck Problem에 대한 설명으로 가장 적절한 것은?

- ① 긴 입력 시퀀스의 모든 정보를 하나의 고정된 문맥 벡터에 압축하면서 정보가 손실될 수 있다.
- ② 디코더의 파라미터 수가 항상 0이 되는 문제이다.
- ③ 입력과 출력의 길이가 같아지는 문제이다.
- ④ 단어를 원-핫으로 표현할 수 없는 문제이다.

문제 20. Attention 메커니즘의 핵심 아이디어는?

- ① 출력 생성 시 입력 문장의 어느 부분이 중요한지 선택적으로 집중한다.
- ② 인코더의 크기를 무조건 두 배로 만든다.
- ③ 입력 문장의 단어를 모두 같은 가중치로 취급한다.
- ④ 디코더를 여러 개 독립적으로 학습한다.

문제 21. Attention이 기본 Seq2Seq의 병목을 완화하는 방식으로 가장 적절한 것은?

- ① 디코더가 각 시점에서 인코더의 여러 hidden state를 직접 참고할 수 있게 한다.
- ② 인코더의 hidden state를 모두 제거한다.
- ③ 출력 시퀀스를 항상 한 단어로 줄인다.
- ④ 모든 attention weight를 동일하게 고정한다.

문제 22. Attention weight에 대한 설명으로 옳은 것은?

- ① 현재 출력과 각 입력 위치의 관련성이 클수록 더 큰 가중치를 줄 수 있다.
- ② 항상 모든 입력 위치에서 동일해야 한다.
- ③ 학습과 무관한 난수이다.
- ④ 문장 길이가 길면 사용할 수 없다.

문제 23. Seq2Seq의 End-to-End 학습에 대한 설명으로 옳은 것은?

- ① 인코더와 디코더가 하나의 목적 함수에 의해 함께 최적화될 수 있다.
- ② 인코더만 학습되고 디코더는 고정된다.
- ③ 두 모듈은 반드시 별개의 데이터셋으로만 학습된다.
- ④ 역전파를 사용할 수 없다.

문제 24. 다음 중 Attention의 효과로 보기 가장 어려운 것은?

- ① 긴 시퀀스에서 정보 손실을 줄이는 데 도움을 준다.
- ② 출력 시점마다 중요한 입력 부분에 집중한다.
- ③ 입력과 출력 사이의 정렬 관계를 표현할 수 있다.
- ④ 모든 시점에서 하나의 동일한 고정 문맥 벡터만 사용하도록 강제한다.

문제 25. Seq2Seq를 구성하는 두 핵심 모듈의 이름을 쓰시오.

문제 26. Attention이 해결하려는 Seq2Seq의 대표적 한계 한 가지를 쓰시오.

III. Transformer

문제 27. RNN 기반 모델이 대규모 학습에서 비효율적일 수 있는 이유로 교재가 강조한 것은?

- ① 시퀀스 길이만큼 순차적인 계산 단계가 필요해 병렬화가 어렵다.
- ② 가중치를 전혀 공유하지 않기 때문이다.
- ③ 항상 이미지 입력만 처리하기 때문이다.
- ④ GPU에서는 연산할 수 없기 때문이다.

문제 28. Self-Attention 에서 각 입력 토큰으로부터 만들어지는 세 벡터는?

- ① Query, Key, Value
- ② Input, Output, Label
- ③ Forget, Input, Output
- ④ Mean, Variance, Bias

문제 29. Self-Attention 에서 Query 와 Key 의 내적이 주로 사용되는 목적은?

- ① 토큰 간 관련성(Attention Score)을 계산하기 위해
- ② 문장 길이를 줄이기 위해
- ③ 단어를 원-핫으로 되돌리기 위해
- ④ 모델의 층 수를 결정하기 위해

문제 30. Self-Attention 의 출력 생성 과정으로 가장 적절한 것은?

- ① Attention Score 를 이용해 Value 벡터들을 가중합한다.
- ② Query 벡터만 그대로 출력한다.
- ③ Key 벡터를 모두 삭제한다.
- ④ Value 벡터의 차원을 매 시점 증가시킨다.

문제 31. Self-Attention 만으로는 토큰의 순서 정보를 직접 알기 어렵기 때문에 사용하는 것은?

- ① Positional Encoding
- ② Max Pooling
- ③ Dropout 만 단독 사용
- ④ K-means

문제 32. 교재에서 소개한 Positional Encoding 의 대표적인 위치 표현 방식은?

- ① 사인(sine)·코사인(cosine) 함수를 이용한 위치 정보 표현
- ② 모든 위치에 동일한 상수만 더하기
- ③ 토큰 순서를 무작위로 섞기
- ④ 문장을 이미지 픽셀 좌표로 변환하기

문제 33. Self-Attention 뒤에 Feed-Forward Network(FFN)를 두는 주요 이유로 가장 적절한 것은?

- ① 비선형 변환 능력을 추가하여 더 복잡한 패턴을 학습하기 위해
- ② 토큰 순서를 완전히 제거하기 위해
- ③ 미래 단어를 모두 보이게 하기 위해
- ④ Attention Score 를 항상 1 로 만들기 위해

문제 34. 언어 생성에서 Masked Self-Attention 을 사용하는 이유는?

- ① 현재 위치가 미래 토큰을 미리 참조하는 정보 누수를 막기 위해
- ② 입력 문장의 위치 정보를 없애기 위해
- ③ 모든 토큰을 동시에 [MASK]로 바꾸기 위해
- ④ 인코더의 출력을 사용하지 않기 위해

문제 35. Transformer 인코더 블록의 역할에 대한 설명으로 옳은 것은?

- ① Self-Attention, 위치 정보, FFN 등을 이용해 입력 문맥을 분석한다.
- ② 미래 단어만 보고 이전 단어를 생성한다.
- ③ 입력을 하나의 고정 라벨로만 변환한다.
- ④ RNN의 hidden state를 반드시 순차적으로 전달한다.

문제 36. Multi-Head Attention에 대한 설명으로 옳지 않은 것은?

- ① 여러 헤드가 서로 다른 관계를 병렬로 포착할 수 있다.
- ② 헤드 수를 늘리면 언제나 성능이 무한히 향상된다.
- ③ 적정 헤드 수는 데이터·모델·최적화 조건에 따라 달라질 수 있다.
- ④ 헤드가 지나치게 많으면 중복된 패턴을 학습할 수도 있다.

문제 37. Self-Attention의 Q, K, V를 각각 풀어 쓰시오.

문제 38. Self-Attention의 세 가지 대표적 한계와 이를 보완하는 요소를 한 쌍씩 쓰시오.

IV. 사전 학습 기반 언어 모델

문제 39. 사전학습(Pretraining)에 대한 설명으로 가장 적절한 것은?

- ① 대규모 데이터에서 일반적인 언어 패턴을 먼저 학습한 뒤 특정 태스크에 적용하는 단계이다.
- ② 특정 태스크의 정답 데이터만으로 처음부터 모델을 학습하는 과정이다.
- ③ 학습 없이 프롬프트만 바꾸는 과정이다.
- ④ 모든 파라미터를 무작위로 고정하는 과정이다.

문제 40. 사전학습 기반 언어 모델의 대표적인 구조와 모델 연결로 옳은 것은?

- ① Encoder-BERT / Encoder-Decoder-T5 / Decoder-GPT
- ② Encoder-GPT / Encoder-Decoder-BERT / Decoder-T5
- ③ Encoder-T5 / Encoder-Decoder-GPT / Decoder-BERT
- ④ 세 모델 모두 Encoder-only 구조이다.

문제 41. 워드 임베딩만 사전학습하고 나머지 네트워크를 무작위 초기화하는 접근의 한계로 교재가 언급한 것은?

- ① 다운스트림 태스크에 필요한 풍부한 문맥 정보를 충분히 학습하기 어렵고, 나머지 네트워크 학습도 처음부터 필요하다.
- ② 단어 임베딩 자체를 사용할 수 없게 된다.
- ③ 모든 태스크에서 항상 완벽한 성능을 낸다.
- ④ 모델 파라미터가 전혀 존재하지 않는다.

문제 42. BERT의 Masked Language Modeling(MLM)에서 학습 대상으로 무작위 선택하는 입력 토큰의 비율은?

- ① 5%
- ② 10%
- ③ 15%
- ④ 50%

문제 43. BERT MLM에서 선택된 토큰의 처리 비율을 올바르게 설명한 것은?

- ① 80% [MASK] / 10% 랜덤 토큰 / 10% 그대로 유지
- ② 100% [MASK]
- ③ 50% 삭제 / 50% 그대로 유지
- ④ 80% 랜덤 토큰 / 20% [SEP]

문제 44. BERT의 Next Sentence Prediction(NSP)의 주된 목적은?

- ① 두 문장 사이의 관계를 학습하여 문장 수준 문맥 이해에 도움을 주는 것
- ② 이미지의 다음 픽셀을 예측하는 것
- ③ 한 문장 안의 모든 단어를 삭제하는 것
- ④ 단어 임베딩 차원을 줄이는 것

문제 45. BERT에서 두 문장 세그먼트를 구분하기 위해 사용하는 특별 토큰은?

- ① [CLS]
- ② [MASK]
- ③ [SEP]
- ④ [END]

문제 46. BERT의 토큰 수준(Token Level) 다운스트림 태스크 예로 교재에서 제시한 것은?

- ① 개체명 인식(Named Entity Recognition, NER)
- ② 이미지 분할
- ③ 주가 회귀 예측
- ④ 음성 파형 생성

문제 47. Decoder 기반 언어 모델(예: GPT)의 특징으로 가장 적절한 것은?

- ① 이전 토큰을 바탕으로 다음 토큰을 순차적으로 생성하는 단방향(Autoregressive) 구조이다.
- ② 항상 양방향 문맥을 모두 사용해 가려진 단어만 복원한다.
- ③ 출력 생성에는 적합하지 않다.
- ④ Encoder와 Decoder를 반드시 동시에 사용한다.

문제 48. T5에 대한 설명으로 옳지 않은 것은?

- ① Encoder-Decoder 구조를 사용한다.
- ② 다양한 NLP 문제를 Text-to-Text 형식으로 통일한다.
- ③ Span Corruption 방식으로 사전학습할 수 있다.
- ④ BERT의 NSP를 사용해 두 문장 연결 여부만을 예측하는 것이 핵심 학습 방식이다.

문제 49. GPT-3에서 강조된 In-Context Learning의 세 설정을 예시 개수 기준으로 쓰시오.

문제 50. Chain-of-Thought(CoT) prompting의 핵심 역할을 한 문장으로 쓰시오.

V. 서술형 문제

서술형은 단순 용어 나열보다 개념 간 관계와 동작 원리를 설명하는 것을 목표로 합니다.

문제 51. [워드 임베딩과 RNN/LSTM] 원-핫 인코딩과 워드 임베딩의 차이를 설명하고, Word2Vec의 CBOW와 Skip-gram의 예측 방향을 비교하시오. 마지막으로 워드 임베딩이 원-핫 인코딩의 어떤 한계를 완화하는지 서술하시오.

문제 52. [RNN과 LSTM] RNN이 순차 데이터를 처리하는 원리를 hidden state 관점에서 설명하고, 긴 시퀀스에서 발생하는 장기 의존성 문제의 원인을 쓰시오. 이어서 LSTM이 Cell state와 세 가지 게이트를 통해 이 문제를 어떻게 완화하는지 설명하시오.

문제 53. [Seq2Seq와 Attention] 기본 Seq2Seq의 Encoder-Decoder 동작을 설명하고 Bottleneck Problem이 왜 발생하는지 서술하시오. 이후 Attention이 디코딩 시점마다 입력의 중요한 부분을 선택하여 이 문제를 어떻게 완화하는지 설명하시오.

V. 서술형 문제 (계속)

문제 54. [Transformer] Self-Attention 의 Q, K, V 를 이용한 계산 흐름을 설명하고, Self-Attention 의 세 가지 한계인 순서 정보 부재·비선형성 부족·미래 참조 문제를 Transformer 가 각각 어떻게 보완하는지 서술하시오.

문제 55. [사전학습 기반 언어 모델] 사전학습의 목적을 설명한 뒤 BERT, T5, GPT 의 구조와 대표 학습/활용 특징을 비교하시오. 마지막으로 GPT-3 의 In-Context Learning 과 Chain-of-Thought prompting 이 무엇인지 설명하시오.
