

AI & 기계학습 기초 시험 전 복습문제

정답 및 해설

출제 범위: 제공된 「1-1. AI와 기계학습기초」 교재 전체

구성: 객관식 42문제 + 단답형 8문제 = 50문제, 서술형 5문제

대목차 분포: 기초 1 - 13문제 / 기초 2 - 13문제 / 기초 3 - 12문제 / 기초 4 - 12문제

정답지는 단순 정답뿐 아니라 오답을 구분하는 데 필요한 핵심 개념을 짧게 설명하도록 구성했습니다.

AI & 기계학습 기초 1 - AI와 ML은 무엇인가?

문제 1. [객관식] AI, ML, DL의 포함 관계를 올바르게 나타낸 것은?

- ① $AI \subset ML \subset DL$
- ② $DL \subset ML \subset AI$
- ③ $ML \subset AI \subset DL$
- ④ $DL \subset AI \subset ML$

정답: ②

해설: 교재에서는 AI가 가장 넓은 개념이고, ML은 AI의 한 분야, DL은 ML의 한 분야로 설명한다. 따라서 $DL \subset ML \subset AI$ 이다.

문제 2. [객관식] 교재에서 설명하는 머신러닝의 반복적 학습 흐름에 가장 가까운 것은?

- ① 데이터 → 모델 → 학습 → 평가, 그리고 평가 결과를 바탕으로 반복
- ② 모델 → 데이터 → 평가 → 학습, 이후 반복하지 않음
- ③ 학습 → 평가 → 데이터 → 모델, 순서는 항상 고정
- ④ 데이터 → 평가 → 모델 → 학습, 평가 결과는 학습에 사용하지 않음

정답: ①

해설: 교재는 데이터-모델-학습-평가의 반복적 개선 루프를 제시한다.

문제 3. [객관식] Feature와 Label에 대한 설명으로 옳지 않은 것은?

- ① Feature는 모델이 예측에 사용하는 입력 설명 변수이다.
- ② Label은 모델이 예측하려는 정답 또는 학습 목표이다.
- ③ Feature는 반드시 수치형 데이터만 가능하다.
- ④ Feature와 Label의 관계를 학습하여 새로운 입력의 값을 예측할 수 있다.

정답: ③

해설: Feature는 수치형뿐 아니라 범주형, 텍스트, 이미지, 음성 등 다양한 형태가 가능하다.

문제 4. [객관식] 1D 피쳐 기반 학습에 대한 설명으로 가장 적절한 것은?

- ① Feature가 하나인 가장 단순한 학습 형태이다.
- ② Label이 하나인 모든 학습을 의미한다.
- ③ 항상 선형 함수만 가설로 사용할 수 있다.
- ④ 측정오차가 전혀 없는 데이터에서만 사용할 수 있다.

정답: ①

해설: 교재는 Feature가 하나일 때를 1D 피쳐 기반 학습의 가장 단순한 형태로 설명한다. 선형/비선형 가설 모두 고려할 수 있다.

문제 5. [객관식] 관측값 Y 와 미지의 참 함수 $f^*(X)$, 관측오차 ε 의 관계로 가장 적절한 것은?

- ① $Y = f^*(X) + \varepsilon$
- ② $Y = f^*(X) \times \varepsilon$
- ③ $f^*(X) = Y + \varepsilon$
- ④ $\varepsilon = f^*(X) + Y$

정답: ①

해설: 교재의 모델 가정은 관측된 Label이 참 함수의 출력에 관측오차가 더해진 형태, 즉 $Y = f^*(X) + \varepsilon$ 이다.

문제 6. [객관식] 가설공간(Hypothesis Space)에 대한 설명으로 옳은 것은?

- ① 학습에 사용할 원본 데이터 전체의 집합
- ② Feature와 Label의 관계를 표현할 수 있는 후보 함수들의 집합
- ③ 학습이 끝난 뒤 정답 Label만 모은 집합
- ④ 평가 과정에서 계산된 오차만 모은 집합

정답: ②

해설: 가설공간은 Feature와 Label의 관계를 표현할 수 있는 후보 함수들의 집합이며, 모델은 그 안에서 선택되는 특정 함수로 볼 수 있다.

문제 7. [객관식] 다음 중 교재가 설명한 “학습”의 의미에 가장 가까운 것은?

- ① 주어진 데이터에서 정답 Label을 모두 암기하는 과정
- ② 주어진 데이터에서 성능을 가장 잘 낼 수 있도록 모델의 규칙을 조정하는 과정
- ③ Feature의 개수를 항상 줄이는 과정
- ④ 관측오차 ε 를 데이터에서 완전히 제거하는 과정

정답: ②

해설: 학습은 데이터로부터 적절한 모델을 선택·조정하여 성능을 높이는 과정이다. 관측오차를 완전히 제거하는 것이 학습의 정의는 아니다.

문제 8. [객관식] 학습에 필요한 요소에 대한 설명으로 옳지 않은 것은?

- ① 학습에 사용할 데이터
- ② 후보 모델을 포함하는 가설공간
- ③ 어떤 모델이 더 좋은지 판단할 선택 기준(손실 함수)
- ④ 반드시 정답을 사람이 직접 코딩한 규칙 집합

정답: ④

해설: 교재는 학습에 필요한 핵심 요소로 데이터, 가설공간, 선택 기준(손실 함수)을 제시한다. 사람이 정답 규칙을 직접 코딩할 필요는 없다.

문제 9. [객관식] Feature가 2개 이상인 복수 피쳐 학습에 대한 설명으로 옳은 것은?

- ① Feature가 늘어나면 모델은 반드시 직선만 표현한다.
- ② 2개의 Feature를 사용하는 경우 입력-출력 관계를 3차원 표면으로 생각할 수 있다.
- ③ Feature 수가 증가하면 Label은 더 이상 필요하지 않다.
- ④ 복수 피쳐 모델에서는 가설공간을 정의할 수 없다.

정답: ②

해설: 교재는 예를 들어 Years of Education과 Seniority 두 Feature를 사용하면 Income과의 관계를 3차원 표면으로 시각화할 수 있음을 보여 준다.

문제 10. [객관식] 다음 중 미지의 함수 $f(\cdot)$ 를 학습하는 이유로 적절하지 않은 것은?

- ① 새로운 입력 X 에 대한 Y 를 예측하기 위해
- ② 여러 Feature 중 어떤 Feature가 Label과 관련 있는지 파악하기 위해
- ③ Feature가 변할 때 Label이 어떻게 변하는지 해석하기 위해
- ④ 모든 관측오차 ϵ 를 완전히 제거하기 위해

정답: ④

해설: 학습을 잘하더라도 데이터에 존재하는 관측-측정오차 자체를 완전히 제거할 수 있는 것은 아니다.

문제 11. [단답형] 교재에서 설명한 “학습에 필요한 3가지”를 쓰시오.

정답: 데이터(Data), 가설공간(Hypothesis Space), 선택 기준(손실 함수/Loss Function)

해설: 학습할 자료, 후보 함수의 범위, 후보 가운데 무엇이 더 좋은지 판단할 기준이 필요하다.

문제 12. [객관식] 학습 과정의 일반적인 순서로 가장 적절한 것은?

- ① 데이터 문제 제시 → 가설공간 선택 → 손실 함수로 성능 비교 → 파라미터 조정 → 최종 모델 선택
- ② 가설공간 삭제 → Label 제거 → 임의 모델 선택 → 평가 생략
- ③ 손실 함수 선택 → 데이터 삭제 → 정답 규칙 직접 코딩 → 반복 중단
- ④ 최종 모델 선택 → 데이터 수집 → 가설공간 정의 → 손실 함수 정의

정답: ①

해설: 교재의 학습 과정은 문제/데이터를 제시하고, 가설공간과 손실함수를 정한 뒤 파라미터를 조정해 최종 모델을 찾는 흐름으로 정리된다.

문제 13. [단답형] p 개의 Feature를 갖는 일반적인 입력 벡터 X 와 모델 가정을 기호로 간단히 쓰시오.

정답: $X = (X_1, X_2, \dots, X_p) \in \mathbb{R}, Y = f^*(X) + \epsilon$

해설: 교재는 복수 피쳐 입력을 p 차원 벡터로 일반화하고, Label은 참 함수 출력에 오차가 더해진 것으로 가정한다.

AI & 기계학습 기초 2 - 지도학습은 무엇인가?

문제 14. [객관식] 지도학습(Supervised Learning)의 설명으로 옳은 것은?

- ① 정답 Label 없이 데이터 구조만 찾는 학습
- ② 입력 Feature와 정답 Label이 함께 있는 데이터를 사용해 새로운 데이터의 정답을 예측하는 규칙을 학습
- ③ 모델의 예측값을 사용하지 않는 학습
- ④ 분류 문제에만 사용할 수 있는 학습

정답: ②

해설: 지도학습은 Feature-Label 쌍을 이용하여 새로운 입력에 대한 정답을 예측하는 모델을 학습한다.

문제 15. [객관식] 회귀(Regression) 문제의 예로 가장 적절한 것은?

- ① 이메일 스팸/정상 판별
- ② 사진의 고양이/강아지/햄스터 분류
- ③ 공부 시간에 따른 시험 점수 예측
- ④ 종양의 양성/악성 판별

정답: ③

해설: 회귀는 가격, 점수, 온도처럼 연속적인 수치를 예측하는 문제이다.

문제 16. [객관식] 분류(Classification) 문제의 특징으로 옳은 것은?

- ① 출력이 연속적인 수치이다.
- ② 출력이 범주(카테고리) 또는 이산값이다.
- ③ 대표 손실 함수로 MSE만 사용할 수 있다.
- ④ Feature는 사용할 수 없고 Label만 사용한다.

정답: ②

해설: 분류는 스팸/정상, 고양이/강아지 등 범주형 Label을 예측한다.

문제 17. [객관식] 교재에서 문제 유형과 대표 손실 함수를 올바르게 짝지은 것은?

- ① 회귀-MSE / 분류-Cross Entropy
- ② 회귀-Cross Entropy / 분류- R^2
- ③ 회귀-Accuracy / 분류-MSE
- ④ 회귀-Precision / 분류-RMSE

정답: ①

해설: 교재는 회귀의 대표 손실로 평균제곱오차(MSE), 분류의 대표 손실로 교차 엔트로피(Cross Entropy)를 제시한다.

문제 18. [단답형] 지도학습에서 Feature, Label, 예측값(), 오차(error)의 의미를 각각 한 문장 이내로 쓰시오.

정답: Feature: 예측에 사용하는 입력 설명 변수 / Label: 맞혀야 하는 실제 정답 / 예측값(): 모델이 출력한 추정값 / 오차: 예측값과 실제 Label의 차이

해설: 교재의 지도학습 용어 정리를 그대로 연결하면 된다.

문제 19. [객관식] 평균제곱오차(MSE)에 대한 설명으로 옳지 않은 것은?

- ① 각 데이터의 예측오차를 제곱한 뒤 평균낸 값이다.
- ② 오차가 작을수록 일반적으로 더 좋은 회귀 예측을 의미한다.
- ③ 제곱을 사용하므로 큰 오차에 더 큰 패널티를 준다.
- ④ Label의 단위와 항상 동일한 단위를 갖는다.

정답: ④

해설: MSE는 오차를 제곱하므로 단위도 제곱 단위가 된다. 원래 단위로 해석하려면 RMSE를 사용할 수 있다.

문제 20. [객관식] 결정계수 R^2 에 대한 설명으로 옳은 것은?

- ① 값이 클수록 평균 예측에 비해 모델이 데이터를 더 잘 설명한다고 볼 수 있다.
- ② 항상 0과 1 사이에만 존재하며 음수가 될 수 없다.
- ③ 회귀 모델의 오차를 원래 단위로 직접 보여준다.
- ④ 분류 문제의 정확도를 계산하는 공식이다.

정답: ①

해설: R^2 는 평균 기준 대비 모델의 상대적 설명력을 나타낸다. 교재는 예측이 평균보다 못하면 음수가 될 수도 있음을 설명한다.

문제 21. [객관식] MSE와 R^2 를 함께 보는 이유로 가장 적절한 것은?

- ① 둘은 완전히 같은 정보를 같은 단위로 제공하기 때문이다.
- ② MSE는 구체적인 오차 크기, R^2 는 상대적 설명 정도를 보여 서로 보완적이기 때문이다.
- ③ R^2 만으로는 분류 정확도를 계산할 수 없기 때문이다.
- ④ MSE는 항상 0이고 R^2 는 항상 1이기 때문이다.

정답: ②

해설: 교재는 MSE가 구체적 오차 크기를, R^2 가 평균 대비 상대적 설명력을 제공하므로 필요에 따라 보완적으로 활용할 수 있다고 설명한다.

문제 22. [객관식] 분류 정확도(Accuracy)의 정의로 옳은 것은?

- ① 전체 예측 중 실제 정답과 일치한 예측의 비율
- ② 양성으로 예측한 것 중 실제 양성 비율
- ③ 실제 양성 중 양성으로 예측한 비율
- ④ 예측 확률의 평균값

정답: ①

해설: Accuracy = 맞춘 개수 / 전체 데이터 개수이다.

문제 23. [객관식] 정상 데이터 990개, 불량 데이터 10개인 데이터에서 모든 샘플을 “정상”으로 예측한 모델에 대한 설명으로 가장 적절한 것은?

- ① 정확도가 99%이므로 반드시 좋은 모델이다.
- ② 불균형 데이터에서는 높은 정확도만으로 모델을 좋다고 판단하기 어렵다.
- ③ 불량 데이터가 적으므로 혼동행렬을 사용할 수 없다.
- ④ 정확도는 회귀 문제에만 사용해야 한다.

정답: ②

해설: 교재는 불균형 데이터에서는 소수 클래스 예측이 전혀 안 되어도 전체 정확도가 높게 나올 수 있으므로 정확도만 보면 안 된다고 설명한다.

문제 24. [객관식] 혼동행렬의 항목 설명으로 옳지 않은 것은?

- ① TP: 실제 양성을 양성으로 예측
- ② TN: 실제 음성을 음성으로 예측
- ③ FP: 실제 양성인데 음성으로 예측
- ④ FN: 실제 양성인데 음성으로 예측

정답: ③

해설: FP(False Positive)는 실제 음성인데 양성으로 잘못 예측한 경우이다.

문제 25. [객관식] TP=40, FP=10, FN=20일 때 정밀도(Precision)는?

- ① $40/(40+10)=0.80$
- ② $40/(40+20)\approx 0.67$
- ③ $10/(40+10)=0.20$
- ④ $20/(40+20)\approx 0.33$

정답: ①

해설: Precision = $TP/(TP+FP)$ 이므로 $40/50=0.80$ 이다.

문제 26. [단답형] 오버피팅과 언더피팅을 훈련 오류와 테스트 오류의 관점에서 비교하여 설명하시오.

정답: 오버피팅: 훈련 데이터에는 지나치게 잘 맞아 훈련 오류는 작지만 새로운 데이터의 테스트 오류는 커지는 상태. 언더피팅: 모델이 너무 단순해 훈련 데이터조차 충분히 설명하지 못해 훈련 오류와 테스트 오류가 모두 큰 상태.

해설: 학습의 목적은 훈련 데이터를 암기하는 것이 아니라 새로운 데이터에도 잘 맞는 일반화 성능을 얻는 것이다.

AI & 기계학습 기초 3 - 교차검증(Cross-Validation)

문제 27. [객관식] 훈련 오류와 테스트 오류에 대한 설명으로 옳은 것은?

- ① 훈련 오류는 학습에 사용하지 않은 데이터에서 계산한다.
- ② 테스트 오류는 학습에 사용된 데이터에서만 계산한다.
- ③ 테스트 오류는 새로운 데이터에서의 일반화 성능을 평가하는 데 사용한다.
- ④ 좋은 모델은 훈련 오류와 테스트 오류가 반드시 모두 0이어야 한다.

정답: ③

해설: 훈련 오류는 학습에 사용한 데이터에서, 테스트 오류는 학습에 사용하지 않은 새로운 데이터에서 계산하여 일반화 성능을 본다.

문제 28. [객관식] 모델 복잡도와 테스트 오류의 관계를 설명한 교재의 그래프에 대한 해석으로 가장 적절한 것은?

- ① 모델이 복잡해질수록 테스트 오류는 항상 감소한다.
- ② 너무 단순하면 높은 편향, 너무 복잡하면 높은 분산 때문에 테스트 오류가 커질 수 있다.
- ③ 훈련 오류는 모델 복잡도와 무관하게 일정하다.
- ④ 테스트 오류는 훈련 오류보다 항상 작다.

정답: ②

해설: 교재는 Bias-Variance Trade-off 관점에서 너무 단순하거나 너무 복잡한 모델 모두 일반화 오류를 키울 수 있음을 보여 준다.

문제 29. [객관식] 검증셋(Validation Set, hold-out) 접근의 기본 아이디어로 옳은 것은?

- ① 전체 데이터를 모두 훈련에만 사용하고 성능 평가는 생략한다.
- ② 데이터를 훈련셋과 검증셋으로 나누어 훈련셋으로 학습하고 검증셋으로 성능을 평가한다.
- ③ 검증셋으로 학습하고 훈련셋으로만 평가한다.
- ④ 검증셋은 Label이 없는 데이터만 사용할 수 있다.

정답: ②

해설: Hold-out은 데이터를 두 부분으로 분할하여 한쪽은 학습, 다른 쪽은 검증에 사용한다.

문제 30. [객관식] 검증셋 접근의 한계로 가장 적절한 것은?

- ① 분할을 임의로 한 번 하면 어떤 샘플이 검증셋에 들어가는지에 따라 추정 오차가 달라질 수 있다.
- ② 검증셋을 사용하면 항상 학습 데이터가 더 많아진다.
- ③ 검증셋에서는 회귀 오차를 계산할 수 없다.
- ④ 검증셋을 사용하면 모델 선택을 할 수 없다.

정답: ①

해설: 교재는 한 번의 랜덤 분할에 따라 검증 오차가 달라질 수 있고, 훈련에 쓰는 데이터가 줄어드는 점을 한계로 제시한다.

문제 31. [단답형] Hold-out 검증의 절차를 2단계로 쓰고, 대표적인 한계를 한 가지 쓰시오.

정답: 절차: (1) 데이터를 훈련셋과 검증셋으로 임의 분할, (2) 훈련셋으로 모델을 학습하고 검증셋에서 오차를 측정.
한계: 분할에 따라 검증 오차 추정치가 달라질 수 있거나, 전체 데이터 일부만 학습에 사용하게 된다.

해설: 교재의 검증셋 절차와 한계 내용을 요약한 것이다.

문제 32. [객관식] K-겹 교차검증(K-fold Cross-Validation)의 주된 목적에 가장 가까운 것은?

- ① 검증셋을 한 번만 뽑아 빠르게 끝내기 위해
- ② 여러 분할에서 검증을 반복하여 테스트 오류에 대한 추정을 더 안정적으로 얻기 위해
- ③ Feature 수를 자동으로 1개로 줄이기 위해
- ④ Label을 제거하여 비지도 학습으로 바꾸기 위해

정답: ②

해설: K-fold는 데이터 분할을 바꾸어가며 K번 검증하고 평균 오차를 이용해 일반화 성능을 추정한다.

문제 33. [객관식] 5-fold 교차검증에 대한 설명으로 옳은 것은?

- ① 데이터를 5개 겹치는 그룹으로 나누고 모두 동시에 검증한다.
- ② 각 데이터는 정확히 한 번 검증용 fold에 포함되도록 5개 그룹으로 나눈다.
- ③ 5개 fold 중 하나만 사용하고 나머지는 버린다.
- ④ 훈련 없이 5개의 테스트 오류만 계산한다.

정답: ②

해설: 각 fold는 겹치지 않게 나뉘며, 각 fold가 한 번씩 검증셋 역할을 한다.

문제 34. [객관식] K-fold 교차검증의 최종 오차 추정 방식으로 옳은 것은?

- ① 첫 번째 fold의 오차만 사용
- ② 가장 작은 fold 오차만 사용
- ③ K개 검증 오차의 평균을 사용
- ④ K개 검증 오차의 합을 K배하여 사용

정답: ③

해설: 교재는 K번 계산한 검증 MSE(또는 해당 성능 지표)를 평균하여 교차검증 오차를 구한다.

문제 35. [객관식] 표본 수가 n 일 때 Leave-One-Out 교차검증(LOOCV)은 K 를 얼마로 두는 경우인가?

- ① $K=1$
- ② $K=2$
- ③ $K=n/2$
- ④ $K=n$

정답: ④

해설: LOOCV는 매 반복에서 샘플 하나를 검증셋으로 두므로 $K=n$ 인 K-fold의 특수한 경우이다.

문제 36. [객관식] LOOCV와 10-fold 교차검증의 비교로 교재 내용에 부합하는 것은?

- ① LOOCV는 모델을 한 번만 학습하므로 계산량이 가장 작다.
- ② 10-fold는 LOOCV보다 반복 학습 횟수가 적어 계산 시간을 줄일 수 있다.
- ③ 10-fold는 데이터를 검증에 사용하지 않는다.
- ④ LOOCV는 일부 데이터만 사용하므로 데이터 활용률이 낮다.

정답: ②

해설: LOOCV는 샘플 수만큼 모델을 다시 학습해야 하므로 계산량이 크다. 10-fold는 반복 횟수가 훨씬 적다.

문제 37. [객관식] 교차검증에서 각 fold의 구성에 대한 설명으로 옳지 않은 것은?

- ① 원본 데이터를 K개의 부분집합으로 나눈다.
- ② 각 fold는 한 번씩 검증셋 역할을 한다.
- ③ 한 반복의 검증셋을 제외한 나머지 fold들을 훈련에 사용한다.
- ④ 서로 다른 fold에는 동일한 데이터가 중복되어 들어갈 수도 있다.

정답: ④

해설: 원본 데이터를 K개의 겹치지 않는 fold로 분할해야 한다.

문제 38. [단답형] 데이터 100개에 5-fold 교차검증을 적용한다고 하자. 각 반복에서 대략 몇 개를 훈련/검증에 사용하며, 총 몇 번 학습하는지 쓰시오.

정답: 각 반복에서 약 80개(4개 fold)를 훈련에, 20개(1개 fold)를 검증에 사용하며 총 5번 학습한다.

해설: 5개 fold가 한 번씩 검증셋이 되므로 5회 반복한다.

AI & 기계학습 기초 4 - 비지도 학습은 무엇인가?

문제 39. [객관식] 비지도학습(Unsupervised Learning)에 대한 설명으로 옳은 것은?

- ① 정답 Label이 있는 데이터만 사용할 수 있다.
- ② 정답 없이 데이터의 구조·패턴·집단 등을 찾아내는 학습이다.
- ③ 회귀 문제만 해결하기 위한 학습이다.
- ④ 항상 지도학습보다 정확도가 높다.

정답: ②

해설: 교재는 비지도학습을 정답이 없는 데이터에서 구조, 패턴, 집단 등을 찾는 학습으로 설명한다.

문제 40. [객관식] 교재에서 비지도학습의 대표 과제로 언급된 것만을 고른 것은?

- ① 클러스터링, 차원축소(PCA), 밀도추정/이상치 탐지
- ② 선형회귀, 로지스틱회귀, 정확도 계산
- ③ 스팸 분류, 집값 예측, 혼동행렬
- ④ 정답 라벨 생성, MSE 최소화, Cross Entropy 계산

정답: ①

해설: 비지도학습의 대표 과제로 클러스터링, 차원축소(PCA), 밀도추정/이상치 탐지가 제시된다.

문제 41. [객관식] 지도학습과 비지도학습의 차이를 올바르게 설명한 것은?

- ① 지도학습은 Label을 이용하고, 비지도학습은 Label 없이 입력 데이터의 구조를 학습한다.
- ② 지도학습은 Feature를 사용하지 않고, 비지도학습만 Feature를 사용한다.
- ③ 비지도학습은 반드시 분류 정확도를 최대화한다.
- ④ 지도학습과 비지도학습은 데이터 사용 방식에 차이가 없다.

정답: ①

해설: 핵심 차이는 정답 Label의 존재 여부와 학습 목표에 있다.

문제 42. [객관식] 클러스터링(Clustering)에 대한 설명으로 가장 적절한 것은?

- ① 데이터 안에서 서로 비슷한 항목은 같은 집단으로, 다른 항목은 다른 집단으로 묶는 방법
- ② 주어진 Label을 사용해 연속값을 예측하는 방법
- ③ 모든 데이터를 하나의 집단으로 만드는 방법
- ④ 오차를 0으로 만드는 회귀 알고리즘

정답: ①

해설: 클러스터링은 유사하거나 가까운 데이터끼리 집단을 형성하는 비지도학습 방법이다.

문제 43. [객관식] 마케팅 세그멘테이션을 클러스터링으로 수행하는 이유로 가장 적절한 것은?

- ① 특성·관심·성향 등이 비슷한 고객을 그룹으로 묶어 차별화된 전략을 세우기 위해
- ② 모든 고객에게 동일한 전략만 적용하기 위해
- ③ 고객 Label을 사람이 미리 정하지 않으면 분석할 수 없기 때문에
- ④ 고객 수를 강제로 절반으로 줄이기 위해

정답: ①

해설: 교재는 마케팅 세그멘테이션을 클러스터링 활용 예로 들며, 비슷한 고객군을 나누어 시장 세분화 전략을 세울 수 있다고 설명한다.

문제 44. [객관식] K-means 클러스터링의 특징으로 옳은 것은?

- ① 클러스터 개수 K를 미리 정해야 한다.
- ② K를 전혀 정하지 않고 덴드로그램만 만든다.
- ③ 중심점(centroid)을 사용하지 않는다.
- ④ 항상 한 번의 계산으로 최적 결과가 보장된다.

정답: ①

해설: K-means는 사용자가 클러스터 수 K를 사전에 지정하고 K개의 중심을 이용해 군집을 만든다.

문제 45. [객관식] K-means의 핵심 최적화 아이디어로 가장 적절한 것은?

- ① 클러스터 내부 변동(Within-Cluster Variation)을 작게 만드는 분할을 찾는다.
- ② 클러스터 사이의 거리를 항상 0으로 만든다.
- ③ 모든 샘플을 서로 다른 클러스터에 둔다.
- ④ 가장 큰 클러스터만 남기고 나머지를 제거한다.

정답: ①

해설: K-means는 각 점을 가장 가까운 중심에 배정하고 중심을 갱신하여 클러스터 내부 변동을 줄이는 방향으로 반복한다.

문제 46. [객관식] K-means 알고리즘의 반복 단계 순서로 옳은 것은?

- ① K개 중심 초기화 → 각 점을 가장 가까운 중심의 클러스터에 배정 → 각 클러스터 중심 재계산 → 배정이 변하지 않을 때까지 반복
- ② 클러스터 수 제거 → 덴드로그램 작성 → Label 예측
- ③ 정답 Label 생성 → MSE 계산 → 중심 삭제
- ④ 모든 점 병합 → 가장 먼 점 분리 → 한 번만 계산

정답: ①

해설: 초기 중심 설정, 할당, 중심 재계산을 반복하는 것이 K-means의 기본 절차이다.

문제 47. [객관식] K-means에서 초기값의 영향을 설명한 것으로 옳은 것은?

- ① 초기 중심과 무관하게 항상 동일한 최적해가 나온다.
- ② 초기 중심에 따라 서로 다른 결과나 local minimum에 수렴할 수 있어 여러 번 시도하는 것이 권장된다.
- ③ 초기값은 K를 자동으로 없애는 역할을 한다.
- ④ 초기값이 다르면 데이터의 Feature가 자동으로 삭제된다.

정답: ②

해설: 교재는 중심 초기화에 따라 결과가 달라질 수 있으므로 여러 초기값으로 반복 실행하는 것을 권장한다.

문제 48. [객관식] 계층적 군집(Hierarchical Clustering)의 특징으로 옳은 것은?

- ① 클러스터 개수 K를 반드시 먼저 고정해야만 시작할 수 있다.
- ② 데이터를 병합하는 과정을 통해 트리 형태의 덴드로그램을 만들 수 있다.
- ③ 중심점 하나만 반복 계산한다.
- ④ 대규모 데이터에서 K-means보다 항상 계산이 더 빠르다.

정답: ②

해설: 교재의 상향식 계층적 군집은 가까운 클러스터부터 병합하고 그 과정을 덴드로그램으로 표현한다. K를 미리 고정하지 않아도 전체 구조를 볼 수 있다.

문제 49. [단답형] 계층적 군집에서 Single, Complete, Average linkage의 클러스터 간 거리 정의를 각각 쓰시오.

정답: Single: 두 클러스터의 점들 사이 거리 중 최솟값 / Complete: 거리 중 최댓값 / Average: 모든 점 쌍 거리의 평균값

해설: 링크 유형에 따라 어떤 두 클러스터를 먼저 합칠지가 달라지고 최종 덴드로그램도 달라질 수 있다.

문제 50. [단답형] K-means와 계층적 군집의 차이를 두 가지 이상 쓰고, 클러스터링 전에 확인할 주의점 한 가지를 쓰시오.

정답: 예: K-means는 K를 미리 정하고 중심점을 반복 갱신하지만, 계층적 군집은 K를 미리 고정하지 않고 병합 과정과 덴드로그램을 제공한다. K-means는 초기값에 따라 결과가 달라질 수 있고 여러 번 시도가 권장된다.
주의점: 거리 기반 방법은 변수 스케일의 영향을 받으므로 표준화/정규화 등 전처리를 고려한다.

해설: 교재의 K-means/계층적 군집 비교와 클러스터링 체크리스트를 종합한 답이다.

서술형 5문제 - 채점 핵심 요소

서술형 1. [기초 1] Feature와 Label이 있는 데이터에서 머신러닝이 미지의 함수 $f(\cdot)$ 를 학습하는 과정을 설명하시오. 답안에는 ① 데이터-모델-학습-평가의 반복 구조, ② 가설공간, ③ 손실 함수(선택 기준), ④ 관측오차 ϵ , ⑤ 1개 Feature에서 복수 Feature로 확장되는 의미를 포함하시오.

채점 핵심 요소

- 데이터-모델-학습-평가의 반복적 개선 흐름 설명
- 가설공간을 후보 함수들의 집합으로 설명
- 손실 함수로 후보 모델의 성능을 비교하고 파라미터를 조정함을 설명
- $Y=f*(X)+\epsilon$ 형태와 ϵ 가 관측오차임을 설명
- 복수 Feature에서 $X \in R$ 로 일반화되고 더 많은 요인의 영향/예측/해석을 다룰 수 있음을 설명

예시 답안 방향: 위 핵심 요소를 서로 연결해 원인-과정-결과가 드러나도록 설명하면 된다. 교재 용어를 정확히 사용하고, 필요한 경우 수식이나 예시를 함께 제시한다.

서술형 2. [기초 2] 회귀와 분류를 비교하여 설명하고, 각각 어떤 출력과 평가/손실 지표를 사용하는지 서술하시오. 특히 MSE, R^2 , Accuracy, Confusion Matrix, Precision/Recall(F1 포함)의 역할과 불균형 데이터에서 Accuracy만 사용했을 때의 문제를 포함하시오.

채점 핵심 요소

- 회귀=연속형 수치, 분류=범주형/이산 출력 구분
- 회귀: MSE(구체적 오차 크기)와 R^2 (평균 대비 상대적 설명력) 설명
- 분류: Accuracy와 Confusion Matrix의 역할 설명
- Precision, Recall(Sensitivity), F1의 의미 또는 공식 제시
- 불균형 데이터에서는 다수 클래스만 예측해도 Accuracy가 높아질 수 있음을 설명

예시 답안 방향: 위 핵심 요소를 서로 연결해 원인-과정-결과가 드러나도록 설명하면 된다. 교재 용어를 정확히 사용하고, 필요한 경우 수식이나 예시를 함께 제시한다.

서술형 3. [기초 2~3] 학습의 목적이 “훈련 오류 최소화”가 아니라 “일반화 성능 확보”인 이유를 설명하시오. 오버피팅, 언더피팅, 훈련 오류/테스트 오류, Bias-Variance Trade-off를 연결하여 서술하시오.

채점 핵심 요소

- 일반화 성능과 테스트 오류의 의미 설명
- 오버피팅: 훈련 오류는 작지만 테스트 오류는 커짐
- 언더피팅: 훈련/테스트 오류가 모두 큼
- 모델이 너무 단순하면 high bias, 너무 복잡하면 high variance가 될 수 있음을 설명
- 적절한 복잡도를 선택해야 테스트 오류를 줄일 수 있음을 설명

예시 답안 방향: 위 핵심 요소를 서로 연결해 원인-과정-결과가 드러나도록 설명하면 된다. 교재 용어를 정확히 사용하고, 필요한 경우 수식이나 예시를 함께 제시한다.

서술형 4. [기초 3] Hold-out 검증, K-fold 교차검증, LOOCV를 비교하여 설명하시오. 각각의 절차와 장단점을 쓰고, 왜 모델 선택이나 일반화 성능 추정에 검증 절차가 필요한지 서술하시오.

채점 핵심 요소

- Hold-out: 훈련/검증 분할 및 분할에 따른 변동성/훈련 데이터 감소 설명
- K-fold: K개 겹치지 않는 fold, 각 fold가 한 번씩 검증, 평균 오차 사용
- LOOCV: $K=n$, 하나씩 검증하는 방식 설명
- LOOCV는 계산량이 크고 10-fold 등은 반복 횟수를 줄일 수 있음을 설명
- 검증을 통해 새로운 데이터에서의 오류를 추정하고 모델/복잡도를 선택한다는 목적 설명

예시 답안 방향: 위 핵심 요소를 서로 연결해 원인-과정-결과가 드러나도록 설명하면 된다. 교재 용어를 정확히 사용하고, 필요한 경우 수식이나 예시를 함께 제시한다.

서술형 5. [기초 4] K-means와 계층적 군집을 비교하여 설명하시오. K-means의 반복 절차와 초기값 문제, 계층적 군집의 상향식 병합과 덴드로그램, Single/Complete/Average linkage의 차이, 그리고 거리 기반 클러스터링에서의 전처리 주의점을 포함하시오.

채점 핵심 요소

- K-means는 K를 사전 지정하고 중심점을 사용하는 방식임을 설명
- 초기 중심→가까운 중심에 배정→중심 재계산 반복 절차 설명
- 초기값에 따라 local minimum/결과가 달라질 수 있어 여러 번 시도 필요
- 계층적 군집은 가까운 군집을 반복 병합하고 덴드로그램을 제공함을 설명
- Single=min, Complete=max, Average=평균 거리 및 스케일의 영향/표준화 주의 설명

예시 답안 방향: 위 핵심 요소를 서로 연결해 원인-과정-결과가 드러나도록 설명하면 된다. 교재 용어를 정확히 사용하고, 필요한 경우 수식이나 예시를 함께 제시한다.