

AI & 기계학습 방법론

시험 전 복습 문제 - 정답 및 해설

교재 기반 | 제공된 Markdown 문제 형식·난이도 참고

문항 구성 및 분포

대목차	주요 범위	문항 수	문항 번호
AI & 기계학습 방법론 1	선형회귀(Linear Regression)	13	1-13
AI & 기계학습 방법론 2	분류와 로지스틱 회귀(Logistic Regression)	12	14-25
AI & 기계학습 방법론 3	신경망 모델(Neural Network)	13	26-38
AI & 기계학습 방법론 4	신경망 적합(Fitting)·경사하강법·역전파	12	39-50
합계	객관식 42 + 단답형 8	50 문제	+ 서술형 5 문제

※ 서술형 5 문제는 네 대목차의 핵심 개념을 모두 포함하며, 마지막 문항은 학습 전체 흐름을 묻는 통합형입니다.

객관식 빠른 정답표

번호	정답	번호	정답	번호	정답	번호
1	2	2	1	3	1	
4	2	5	2	6	1	
7	2	8	1	9	2	
10	3	11	2	14	2	
15	2	16	3	17	1	
18	2	19	1	20	1	
21	1	22	2	23	2	
26	2	27	1	28	1	
29	1	30	1	31	1	
32	1	33	1	34	1	
35	1	36	1	39	1	
40	1	41	1	42	1	
43	1	44	1	45	1	
46	4	47	1	48	1	

AI & 기계학습 방법론 1 - 선형회귀(Linear Regression)

문제 1. 선형회귀(Linear Regression)에 대한 설명으로 가장 적절한 것은?

- 정답이 없는 데이터를 군집으로 나누는 비지도학습 방법이다.
- 입력과 출력 사이의 선형 관계를 학습하는 지도학습의 기초적인 방법이다.
- 출력을 반드시 0 과 1 사이의 확률로 제한하는 분류 모델이다.
- 여러 은닉층을 이용해 비선형 함수를 근사하는 딥러닝 모델이다.

정답: 2

해설: 교재에서는 선형회귀를 지도학습의 가장 기초적인 방법으로 소개하며, 입력과 출력의 선형 관계를 학습한다고 설명한다.

문제 2. 단순선형회귀 모형의 식으로 옳은 것은?

- $Y = \beta_0 + \beta_1 X + \epsilon$
- $Y = \beta_0 \beta_1 X$
- $Y = 1 / (1 + e^{-x})$
- $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3$ 만 가능하다.

정답: 1

해설: 단순선형회귀의 기본 모형은 $Y = \beta_0 + \beta_1 X + \epsilon$ 이며, β_0 는 절편, β_1 은 기울기, ϵ 는 측정오차를 의미한다.

문제 3. 단순선형회귀에서 β_1 의 의미로 가장 적절한 것은?

- X가 1 증가할 때 Y가 평균적으로 β_1 만큼 변화하는 정도
- X가 0일 때의 Y 예측값

3. 관측값과 예측값의 차이
4. 모델이 설명하지 못한 측정오차의 분산

정답: 1

해설: β_1 은 기울기로서 X 가 한 단위 증가할 때 Y 가 평균적으로 얼마나 변하는지를 나타낸다.

문제 4. 잔차(Residual)에 대한 설명으로 옳은 것은?

1. 예측값 - 실제값으로만 정의된다.
2. 실제값과 예측값의 차이로, 모델이 설명하지 못한 부분을 나타낸다.
3. 항상 0 보다 큰 값만 가진다.
4. 독립변수 사이의 상관계수를 의미한다.

정답: 2

해설: 잔차는 관측값과 회귀모형의 예측값 사이의 차이이며, 모델이 설명하지 못한 부분을 나타낸다.

문제 5. 최소제곱법(Least Squares)의 핵심 아이디어는?

1. 계수의 절댓값 합을 최대화한다.
2. 잔차 제곱의 합(RSS)을 최소화하는 계수를 찾는다.
3. 훈련 데이터의 개수를 최소화한다.
4. 모든 설명변수의 상관관계를 0 으로 만든다.

정답: 2

해설: 최소제곱법은 관측값과 회귀선의 차이를 제곱해 합한 RSS 를 최소화하는 계수를 찾는 방법이다.

문제 6. 다중선형회귀 모형으로 옳은 것은?

1. $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$
2. $Y = \beta_0 + \varepsilon$ 만 사용한다.
3. $Y = \text{sigmoid}(X)$ 만 사용한다.
4. Y 는 반드시 범주형이어야 한다.

정답: 1

해설: 다중선형회귀는 여러 설명변수 $X_1, \dots, X_p$ 를 사용하여 Y 를 선형 결합으로 설명한다.

문제 7. 다중선형회귀에서 특정 계수 β_j 를 해석하는 방법으로 옳은 것은?

1. 다른 설명변수는 무시하고 X_j 만 본다.
2. 다른 설명변수들을 고정했을 때 X_j 가 1 증가하면 Y 가 평균적으로 β_j 만큼 변한다고 해석한다.
3. β_j 는 항상 변수 X_j 와 Y 의 단순 상관계수와 같다.
4. β_j 가 양수이면 인과관계가 반드시 성립한다.

정답: 2

해설: 다중회귀 계수는 다른 설명변수들의 값을 고정한 조건에서 해당 변수의 변화가 Y 에 미치는 평균적 변화를 뜻한다.

문제 8. 다중선형회귀의 최소제곱 해를 구할 때 교재에서 제시한 행렬 형태와 가장 관련이 깊은 것은?

1. 정규방정식(Normal Equation)
2. 소프트맥스(Softmax)
3. 역전파(Backpropagation)
4. K-means 업데이트

정답: 1

해설: 교재에서는 RSS 최소화 문제를 행렬로 표현하고, 정규방정식을 통해 계수를 구할 수 있음을 다룬다.

문제 9. 다중선형회귀의 예측 결과를 기하학적으로 표현한 것으로 가장 적절한 것은?

1. 덴드로그램
2. 평면 또는 고차원의 초평면(hyperplane)
3. 확률 질량 함수
4. 원형 클러스터

정답: 2

해설: 설명변수가 여러 개인 선형회귀는 입력 공간에서 평면 또는 더 높은 차원의 초평면으로 표현할 수 있다.

문제 10. 교재의 광고 데이터 다중선형회귀 결과에 대한 설명으로 옳은 것은?

1. TV 와 라디오 광고비는 매출과 유의한 관계가 없었다.

- 신문 광고비는 p-value 가 매우 작아 가장 유의했다.
- TV 와 라디오는 유의한 관계를 보였고, 신문 광고비는 통계적으로 유의하지 않았다.
- 다중회귀의 R^2 는 단순회귀보다 반드시 작아야 한다.

정답: 3

해설: 교재 예시에서는 TV 와 radio 의 p-value 가 매우 작아 유의했고, newspaper 는 p-value=0.8599 로 유의하지 않았다.

문제 11. 선형회귀 모델을 훈련 데이터만으로 평가할 때 생길 수 있는 문제를 보완하는 방법은?

- 훈련 데이터에만 계속 맞춘다.
- 검증/테스트셋을 따로 두어 새로운 데이터에서 성능을 확인한다.
- 설명변수를 모두 제거한다.
- 항상 R^2 를 1 로 만든다.

정답: 2

해설: 훈련 데이터에 기반한 성능만으로는 일반화 성능을 확인하기 어려우므로 검증/테스트셋을 사용하는 것이 필요하다.

문제 12. RSS 의 영문 전체 이름과 의미를 간단히 쓰시오.

모범 답안: Residual Sum of Squares. 각 데이터의 잔차(실제값-예측값)를 제곱한 뒤 모두 더한 값으로, 최소제곱법에서는 이를 최소화한다.

해설: 교재의 단순·다중선형회귀 학습에서 RSS 최소화가 핵심이다.

문제 13. 다중공선성(multicollinearity)이 심할 때 나타날 수 있는 문제 두 가지를 쓰시오.

모범 답안: 예: 회귀계수 해석이 어려워지고, 계수 추정치의 분산이 커져 추정이 불안정해질 수 있다.

해설: 교재의 선형회귀 주의사항에서 변수 간 높은 상관으로 계수 해석이 어려워지고 분산이 증가할 수 있다고 설명한다.

AI & 기계학습 방법론 2 - 분류와 로지스틱 회귀(Logistic Regression)

문제 14. 분류(Classification) 문제의 출력에 대한 설명으로 가장 적절한 것은?

- 연속적인 실수값만 출력한다.
- 질적(범주형) 값을 예측한다.
- 입력 데이터의 차원을 줄이는 것이 목적이다.
- 정답 없이 데이터 구조를 찾는다.

정답: 2

해설: 분류는 출력 Y 가 범주(category)를 가지는 질적 변수인 예측 문제이다.

문제 15. 이진 분류 문제에 선형회귀를 그대로 사용하는 것이 부적절한 이유로 가장 적절한 것은?

- 선형회귀는 입력변수를 하나만 받을 수 있기 때문이다.
- 선형회귀 예측값은 0 보다 작거나 1 보다 클 수 있어 확률로 해석하기 어렵기 때문이다.
- 선형회귀는 계수를 학습할 수 없기 때문이다.
- 선형회귀는 항상 정답률이 0%이기 때문이다.

정답: 2

해설: 분류 확률은 0 과 1 사이여야 하지만 선형회귀 출력은 그 범위를 벗어날 수 있어 확률 모델로 부적절하다.

문제 16. 로지스틱 함수(sigmoid)의 출력 범위로 옳은 것은?

- $(-\infty, +\infty)$
- $[0, 1]$ 의 끝점까지 정확히 포함
- $(0, 1)$
- $\{0, 1\}$ 두 값만 출력

정답: 3

해설: sigmoid 함수는 모든 유한한 입력에 대해 0 보다 크고 1 보다 작은 값을 출력한다.

문제 17. 확률 p 에 대한 odds 의 정의로 옳은 것은?

- $p/(1-p)$
- $(1-p)/p$
- $\log(p)$
- $1/p$

정답: 1

해설: odds 는 사건이 일어날 확률과 일어나지 않을 확률의 비로 $p/(1-p)$ 이다.

문제 18. 로짓(logit)에 대한 설명으로 옳은 것은?

1. p 자체를 의미한다.
2. $\log(p/(1-p))$ 로 정의되는 log-odds 이다.
3. 항상 0 과 1 사이의 값이다.
4. RSS 와 같은 의미이다.

정답: 2

해설: 로짓은 odds 에 로그를 취한 log-odds 이며, 로지스틱 회귀에서 선형 예측자와 연결된다.

문제 19. 로지스틱 회귀의 모수 추정에 표준적으로 사용하는 방법은?

1. 최대우도추정(MLE)
2. K-means
3. 주성분분석(PCA)
4. 최소 신장 트리

정답: 1

해설: 교재에서는 로지스틱 회귀의 계수를 최대우도추정(Maximum Likelihood Estimation)으로 추정한다.

문제 20. 우도(likelihood)에 대한 설명으로 가장 적절한 것은?

1. 현재 모수가 관측된 데이터를 얼마나 그럴듯하게 설명하는지를 나타낸다.
2. 설명변수 간 상관계수를 뜻한다.
3. 분류 클래스의 개수이다.
4. 항상 잔차제곱합과 동일하다.

정답: 1

해설: 우도는 주어진 모수에서 현재 관측 데이터가 나타날 가능성의 정도를 나타내며 MLE 는 이를 최대화한다.

문제 21. 독립인 여러 관측값에 대한 전체 우도는 일반적으로 어떻게 구성되는가?

1. 각 관측의 확률을 곱한다.
2. 각 관측의 확률을 무조건 뺀다.
3. 가장 큰 확률 하나만 사용한다.
4. 각 관측의 확률을 제공한 뒤 0 으로 만든다.

정답: 1

해설: 독립 표본의 결합우도는 각 관측이 발생할 확률의 곱으로 구성된다.

문제 22. 로그우도(log-likelihood)를 사용하는 이유로 가장 적절한 것은?

1. 로그를 취하면 최대값의 위치가 달라지기 때문이다.
2. 곱으로 된 우도를 합 형태로 바꾸어 계산을 편리하게 하면서 최대화 문제의 해를 유지할 수 있기 때문이다.
3. 확률을 항상 0 으로 만들기 때문이다.
4. 선형회귀의 RSS 와 완전히 같은 식이 되기 때문이다.

정답: 2

해설: 로그는 단조증가함수이므로 우도 최대화와 로그우도 최대화의 최적점이 같고, 곱이 합으로 바뀌어 계산이 편리해진다.

문제 23. 다음 중 로지스틱 회귀와 선형회귀의 차이에 대한 설명으로 옳은 것은?

1. 두 모델 모두 계수 추정에 반드시 RSS 최소화만 사용한다.
2. 로지스틱 회귀는 선형 결합을 sigmoid 로 변환해 확률을 만든다.
3. 선형회귀는 반드시 범주형 출력을 만든다.
4. 로지스틱 회귀의 출력은 $-\infty$ 에서 $+\infty$ 까지이다.

정답: 2

해설: 로지스틱 회귀는 선형 예측자를 sigmoid 에 통과시켜 0 과 1 사이의 확률을 모델링한다.

문제 24. 로지스틱 함수 $p(X)$ 를 식으로 쓰시오. ($z = \beta_0 + \beta_1 X$ 라고 두어도 됨)

모범 답안: $p(X) = 1 / (1 + e^{(-z)})$, $z = \beta_0 + \beta_1 X$.

해설: 교재에서 로지스틱 회귀는 선형 예측자를 sigmoid 함수에 통과시키는 형태로 제시된다.

문제 25. 최대우도추정(MLE)의 목적을 한 문장으로 설명하시오.

모범 답안: 관측된 데이터가 가장 그럴듯하게 나타나도록 하는 모수(계수)를 찾아 우도 또는 로그우도를 최대화하는 것이다.

해설: 로지스틱 회귀의 계수는 관측 데이터의 우도를 최대화하는 방향으로 추정한다.

AI & 기계학습 방법론 3 - 신경망 모델(Neural Network)

문제 26. Shallow 네트워크의 일반적인 특징으로 가장 적절한 것은?

1. 은닉층이 전혀 없는 모델만 의미한다.
2. 입력층과 출력층 사이에 하나의 은닉층을 두고 여러 hidden unit 을 사용하는 구조로 볼 수 있다.
3. 항상 100 개 이상의 은닉층을 사용한다.
4. 비선형 활성화 함수는 사용할 수 없다.

정답: 2

해설: 교재의 Shallow 네트워크는 입력과 출력 사이에 한 층의 hidden units 를 두고 각 유닛의 출력을 조합하는 구조로 설명된다.

문제 27. ReLU 활성화 함수에 대한 설명으로 옳은 것은?

1. 입력이 음수이면 0, 양수이면 입력값을 그대로 내보내는 형태이다.
2. 모든 입력을 0.5 로 바꾼다.
3. 출력 범위가 반드시 -1 과 1 사이이다.
4. 항상 선형회귀와 동일한 결과를 낸다.

정답: 1

해설: 교재의 shallow network 예시에서 ReLU(Rectified Linear Unit)는 $a(z)=\max(0,z)$ 형태의 활성화 함수로 사용된다.

문제 28. Shallow 네트워크에서 hidden unit 의 역할로 가장 적절한 것은?

1. 각각 입력의 선형변환에 활성화 함수를 적용해 중간 특징을 만든다.
2. 훈련 데이터를 삭제한다.
3. 출력을 무조건 정수로 반올림한다.
4. 학습률을 자동으로 0 으로 만든다.

정답: 1

해설: 각 hidden unit 은 입력의 가중합과 bias 에 활성화 함수를 적용해 중간 표현을 만들고, 출력층이 이를 조합한다.

문제 29. ReLU hidden unit 여러 개를 조합한 shallow network 가 표현할 수 있는 함수의 특징으로 교재에서 강조한 것은?

1. piecewise linear 함수
2. 항상 하나의 직선
3. 항상 주기함수
4. 항상 상수함수

정답: 1

해설: ReLU 유닛의 조합으로 여러 선형 구간이 이어진 piecewise linear 형태의 함수를 표현할 수 있다.

문제 30. Shallow 네트워크의 모수(parameter)에 포함되는 것은?

1. 가중치(weight)와 편향(bias)
2. 훈련 데이터의 행 번호만
3. 출력 클래스 이름만
4. 이미 정해진 그래프의 축 범위만

정답: 1

해설: 네트워크가 학습하는 모수는 각 연결의 가중치와 각 유닛의 bias 등이다.

문제 31. Hidden unit 의 수를 늘렸을 때 일반적으로 기대할 수 있는 변화는?

1. 표현할 수 있는 함수의 복잡성이 커질 수 있다.
2. 모델의 표현력이 항상 감소한다.
3. 모수가 자동으로 0 개가 된다.
4. 입력 차원이 반드시 1 로 줄어든다.

정답: 1

해설: hidden unit 수가 늘어나면 더 많은 선형 구간과 복잡한 형태를 조합할 수 있어 표현력이 증가할 수 있다.

문제 32. 교재에서 소개한 보편적 근사 정리(Universal Approximation Theorem)의 취지로 가장 가까운 것은?

1. 충분한 hidden unit 을 가진 신경망은 다양한 연속 함수를 원하는 수준으로 근사할 수 있다.
2. 모든 신경망은 학습 없이 정답을 정확히 맞힌다.
3. 은닉층이 깊을수록 항상 오차가 0 이 된다.
4. 선형함수만 근사할 수 있다.

정답: 1

해설: 교재는 hidden units 를 충분히 두면 shallow network 도 매우 다양한 함수 형태를 근사할 수 있다는 보편적 근사 관점을 소개한다.

문제 33. 여러 개의 출력을 갖는 신경망에 대한 설명으로 옳은 것은?

1. 출력마다 hidden unit 들의 조합을 이용해 서로 다른 값을 만들 수 있다.
2. 출력은 반드시 하나만 가능하다.
3. 출력이 두 개면 입력도 반드시 두 개여야 한다.
4. 출력 개수와 모수는 전혀 관계가 없다.

정답: 1

해설: 교재의 다중 출력 네트워크에서는 같은 hidden 표현을 이용해 여러 출력 노드가 각기 가중합을 계산한다.

문제 34. 여러 개의 입력을 갖는 신경망에서 hidden unit 은 일반적으로 어떻게 계산되는가?

1. 여러 입력의 가중합에 bias 를 더한 뒤 활성화 함수를 적용한다.
2. 입력 중 하나를 무작위로 버린다.
3. 입력값을 모두 같은 숫자로 바꾼다.
4. 항상 입력의 평균만 사용한다.

정답: 1

해설: 다중 입력 네트워크의 hidden unit 은 여러 입력에 대한 선형 결합과 bias 를 계산한 후 활성화 함수를 적용한다.

문제 35. Deep 네트워크에 대한 설명으로 가장 적절한 것은?

1. 여러 층의 신경망을 합성(composition)하여 더 복잡한 함수를 표현한다.
2. 항상 단일 직선만 표현한다.
3. hidden layer 가 하나뿐인 모델만 의미한다.
4. 활성화 함수가 없어야 한다.

정답: 1

해설: 교재에서는 deep network 를 여러 네트워크/층을 연속적으로 합성하여 계층적 표현을 만드는 구조로 설명한다.

문제 36. Shallow 네트워크와 Deep 네트워크의 비교에 대한 설명으로 옳은 것은?

1. 특정 함수를 표현할 때 깊이를 늘리면 필요한 hidden unit 수를 줄여 더 효율적으로 표현할 수 있는 경우가 있다.
2. Deep 네트워크는 항상 shallow 네트워크보다 모수가 많아야 한다.
3. Shallow 네트워크는 비선형 함수를 절대 표현할 수 없다.
4. 두 구조는 언제나 동일한 모수 수를 가진다.

정답: 1

해설: 교재는 어떤 함수에 대해서는 깊은 합성 구조가 shallow 구조보다 적은 유닛/모수로 효율적으로 표현할 수 있음을 보여준다.

문제 37. hidden unit 이 무엇인지, 입력에서 출력까지 어떤 역할을 하는지 간단히 설명하시오.

모범 답안: hidden unit 은 입력의 가중합과 bias 에 활성화 함수를 적용해 중간 표현을 만드는 계산 단위이며, 출력층은 여러 hidden unit 의 결과를 다시 조합해 최종 출력을 만든다.

해설: Shallow 네트워크의 핵심은 여러 hidden unit 이 서로 다른 비선형 중간 특징을 만든 뒤 이를 조합하는 것이다.

문제 38. 보편적 근사 정리(Universal Approximation Theorem)가 신경망의 표현력과 관련해 말하는 핵심을 쓰시오.

모범 답안: 충분한 수의 hidden unit 을 가진 신경망은 매우 다양한 연속 함수를 임의의 정밀도로 근사할 수 있다는 취지이다.

해설: 교재의 shallow network 표현력 부분에서 hidden units 를 늘리면 복잡한 함수를 근사할 수 있음을 설명한다.

AI & 기계학습 방법론 4 - 신경망 적합(Fitting)·경사하강법·역전파

문제 39. 신경망 적합(fitting)에서 학습의 기본 목적을 가장 잘 나타낸 것은?

1. 손실함수 $L(\phi)$ 를 최소화하는 파라미터 ϕ 를 찾는 것
2. 파라미터를 모두 1 로 고정하는 것

3. 데이터의 순서를 항상 유지하는 것
4. 출력값을 무조건 0으로 만드는 것

정답: 1

해설: 교재의 fitting 개요에서는 학습을 손실함수를 최소화하는 파라미터를 찾는 최적화 문제로 표현한다.

문제 40. 1차원 선형회귀 예시에서 손실함수로 사용한 형태와 가장 가까운 것은?

1. 예측값과 실제값 차이의 제곱합 또는 평균
2. 각 계수의 순위 합
3. 분류 클래스 이름의 길이
4. 입력값의 최대값 하나

정답: 1

해설: 교재의 선형회귀 학습 예시는 예측과 실제의 차이를 제곱해 합/평균한 손실을 최소화하는 형태를 사용한다.

문제 41. 경사하강법(Gradient Descent)에서 gradient 가 의미하는 것은?

1. 각 파라미터 변화에 따른 손실의 변화 방향과 크기
2. 훈련 데이터의 개수
3. 출력 클래스의 이름
4. 모델의 층 수만 나타내는 값

정답: 1

해설: gradient 는 손실함수를 파라미터별로 미분한 벡터로, 손실이 가장 빠르게 증가하는 방향을 나타낸다.

문제 42. 경사하강법의 기본 업데이트 식으로 옳은 것은?

1. $\phi \leftarrow \phi - \alpha \nabla L(\phi)$
2. $\phi \leftarrow \phi + \infty$
3. $\phi \leftarrow L(\phi)$ 만 계산하고 갱신하지 않는다.
4. $\phi \leftarrow 1/\phi$ 만 반복한다.

정답: 1

해설: 손실을 줄이기 위해 gradient 의 반대 방향으로 학습률 α 만큼 파라미터를 이동한다.

문제 43. 학습률(learning rate) α 가 지나치게 큰 경우 발생할 수 있는 현상은?

1. 최솟값을 지나치거나 진동하여 안정적으로 수렴하지 못할 수 있다.
2. 항상 더 정확하게 수렴한다.
3. gradient 가 자동으로 0이 된다.
4. 모델의 입력 차원이 감소한다.

정답: 1

해설: 학습률이 너무 크면 한 번의 이동 폭이 커서 최적점을 넘어가거나 발산/진동할 수 있다.

문제 44. Convex 손실함수와 Non-convex 손실함수에 대한 설명으로 옳은 것은?

1. Convex 문제는 국소 최소와 전역 최소의 구분이 상대적으로 단순하지만, non-convex 문제는 여러 local minima 나 복잡한 지형을 가질 수 있다.
2. Non-convex 문제에는 최소값이 절대 없다.
3. Convex 문제는 미분할 수 없다.
4. 두 경우의 최적화 난이도는 언제나 완전히 같다.

정답: 1

해설: 교재에서는 convex 와 non-convex 손실 지형을 비교하며 신경망 최적화가 non-convex 라 더 어려울 수 있음을 설명한다.

문제 45. 확률적 경사하강법(SGD)이 full-batch 경사하강법과 다른 점으로 가장 적절한 것은?

1. 전체 데이터가 아니라 일부 데이터(미니배치)를 이용해 gradient 를 추정하고 갱신한다.
2. gradient 를 전혀 계산하지 않는다.
3. 항상 한 번만 업데이트한다.
4. 학습률이 필요 없다.

정답: 1

해설: SGD/mini-batch 방식은 전체 데이터 대신 일부 표본으로 gradient 를 계산해 스텝당 계산량을 줄인다.

문제 46. SGD의 특징으로 옳지 않은 것은?

1. 스텝당 계산량을 줄일 수 있다.
2. gradient에 노이즈가 섞일 수 있다.
3. 노이즈가 local minima나 평평한 지형을 벗어나는 데 도움이 될 수 있다.
4. 언제나 full-batch GD보다 더 빠르게 수렴한다고 보장된다.

정답: 4

해설: SGD는 계산 효율성과 탐색 측면의 장점이 있지만, 모든 문제에서 full-batch GD보다 수렴이 빠르다고 보장되지는 않는다.

문제 47. 역전파(Backpropagation)의 핵심 원리로 가장 적절한 것은?

1. 연쇄법칙(chain rule)을 이용해 출력 쪽 손실의 미분을 앞쪽 층의 파라미터까지 전달한다.
2. 훈련 데이터를 역순으로 정렬하기만 한다.
3. 모든 가중치를 같은 값으로 바꾼다.
4. 은닉층의 출력을 삭제한다.

정답: 1

해설: 역전파는 계산 그래프를 따라 연쇄법칙을 적용하여 각 층의 가중치와 bias에 대한 손실의 gradient를 효율적으로 계산한다.

문제 48. 신경망 학습에서 역전파로 계산한 gradient는 이후 무엇에 사용되는가?

1. 경사하강법 등의 옵티마이저가 파라미터를 갱신하는 데 사용된다.
2. 입력 데이터를 삭제하는 데 사용된다.
3. 출력 노드 수를 자동으로 0개로 만든다.
4. 학습이 끝난 뒤에만 그래프를 그리는 데 사용된다.

정답: 1

해설: 역전파는 gradient를 계산하고, 실제 파라미터 변경은 gradient descent/SGD 같은 최적화 규칙이 수행한다.

문제 49. 경사하강법과 확률적 경사하강법(SGD)의 차이를 한 가지 이상 쓰시오.

모범 답안: 경사하강법은 보통 전체 훈련 데이터를 이용해 gradient를 계산하는 반면, SGD/mini-batch 방식은 일부 데이터로 gradient를 근사해 더 자주 갱신한다. SGD는 스텝당 계산량이 작지만 gradient에 노이즈가 생길 수 있다.

해설: 교재의 4장에서는 full-batch GD와 stochastic/mini-batch 방식의 계산량과 노이즈 특성을 비교한다.

문제 50. 역전파에서 연쇄법칙(chain rule)이 필요한 이유를 간단히 설명하시오.

모범 답안: 깊은 신경망의 출력 손실이 여러 중간 함수의 합성으로 이루어져 있으므로, 각 층의 파라미터가 손실에 미치는 영향을 미분하려면 연쇄법칙으로 미분값을 뒤에서 앞으로 연결해야 한다.

해설: 역전파는 합성함수의 미분인 연쇄법칙을 반복 적용해 모든 층의 gradient를 계산한다.

서술형 모범 답안 / 채점 핵심

서술형 1. 단순선형회귀와 다중선형회귀의 차이를 설명하고, 최소제곱법과 RSS의 역할, 다중선형회귀 계수의 해석 방법, 선형회귀 사용 시 주의할 점을 함께 서술하시오.

채점 핵심 요소

단순선형회귀는 하나의 설명변수, 다중선형회귀는 여러 설명변수를 사용한다.
두 경우 모두 관측값과 예측값의 차이인 잔차를 이용하며, 최소제곱법은 RSS를 최소화하는 계수를 찾는다.
다중회귀에서 β_j 는 다른 변수들을 고정했을 때 X_j 1단위 증가에 따른 Y 의 평균 변화량으로 해석한다.
훈련 데이터만으로 성능을 판단하지 말고 검증/테스트셋으로 일반화를 확인해야 한다.
설명변수 간 상관이 지나치게 높으면 다중공선성으로 계수 해석과 추정 안정성이 나빠질 수 있다.

서술형 2. 이진 분류에서 선형회귀보다 로지스틱 회귀가 적절한 이유를 설명하고, sigmoid, odds, log-odds, 최대우도추정(MLE)의 관계를 순서대로 서술하시오.

채점 핵심 요소

선형회귀 출력은 0 미만이나 1 초과가 가능해 확률로 해석하기 어렵다.
로지스틱 회귀는 선형 예측자를 sigmoid에 통과시켜 (0,1) 확률을 만든다.
odds는 $p/(1-p)$, log-odds는 $\log(p/(1-p))$ 이며 로지스틱 회귀에서는 log-odds가 입력의 선형결합으로 표현된다.
모수는 관측 데이터의 우도(또는 로그우도)를 최대화하는 MLE로 추정한다.

서술형 3. Shallow 네트워크가 1차원 선형모델보다 복잡한 함수를 표현할 수 있는 이유를 ReLU hidden unit과 piecewise linear 관점에서 설명하고, hidden unit 수와 표현력, 보편적 근사 정리, Deep 네트워크와의 차이까지 서술하시오.

채점 핵심 요소

각 hidden unit은 입력의 선형변환에 ReLU 같은 비선형 활성화를 적용한다.
여러 hidden unit의 결과를 조합하면 여러 선형 구간이 이어진 piecewise linear 함수를 만들 수 있다.
hidden unit 수가 늘면 더 복잡한 함수 형태를 표현할 수 있다.
보편적 근사 정리는 충분한 hidden unit을 가진 네트워크가 다양한 연속 함수를 근사할 수 있다는 취지이다.
Deep 네트워크는 여러 층의 함수를 합성하여 계층적으로 표현하며, 일부 함수는 깊이를 이용할 때 더 적은 유닛/모수로 효율적으로 표현할 수 있다.

서술형 4. 경사하강법의 동작 원리를 손실함수, gradient, 학습률을 이용해 설명하고, convex/non-convex 문제에서의 최적화 난이도와 SGD의 장단점을 함께 서술하시오.

채점 핵심 요소

학습은 손실함수 $L(\phi)$ 를 최소화하는 파라미터를 찾는 문제이다.
gradient는 손실이 증가하는 방향이므로 $\phi \leftarrow \phi - \alpha \nabla L(\phi)$ 처럼 반대 방향으로 갱신한다.
학습률이 너무 크면 진동/발산할 수 있고 너무 작으면 수렴이 느리다.
convex 문제는 최적화 지형이 단순한 반면, non-convex 문제는 여러 local minima나 복잡한 지형을 가질 수 있다.
SGD는 일부 데이터로 gradient를 계산해 스텝당 비용이 작지만 노이즈가 생기며, 그 노이즈가 탐색에 도움이 될 수 있으나 항상 더 빠른 수렴을 보장하지는 않는다.

서술형 5. 신경망 학습에서 순전파(forward computation), 손실 계산, 역전파(backpropagation), 파라미터 갱신이 어떻게 연결되는지 연쇄법칙을 포함하여 전체 학습 흐름을 서술하시오.

채점 핵심 요소

순전파에서 입력이 각 층의 가중치, bias, 활성화 함수를 거쳐 출력으로 계산된다.
출력과 정답을 비교하여 손실함수를 계산한다.
역전파에서는 연쇄법칙을 이용해 출력 쪽 손실의 미분을 뒤에서 앞으로 전달하며 각 파라미터의 gradient를 계산한다.
계산된 gradient를 경사하강법/SGD 등의 업데이트 식에 사용해 파라미터를 변경한다.
이 과정을 여러 번 반복하여 손실을 줄이는 방향으로 네트워크를 적합한다.