

딥러닝과 영상 모델

시험 전 복습 문제 - 정답 및 해설

구성	객관식 42문제 + 단답형 8문제 + 서술형 5문제
대목차 분포	이미지 딥러닝 모델 17 / 다양한 신경망 모델 17 / 이미지 모델 학습 전략 16
출제 기준	제공 교재의 개념·계산·비교·응용 내용을 중심으로 구성

※ 객관식 정답과 해설, 단답형 정답, 서술형 모범답안의 핵심 채점 요소를 포함합니다.

빠른 정답표 - 객관식 1~42

1	2	3	4	5	6	7
①	②	③	④	①	②	①
8	9	10	11	12	13	14
③	③	④	②	①	②	①
15	16	17	18	19	20	21
②	②	②	①	②	②	①
22	23	24	25	26	27	28
①	①	①	①	①	①	③
29	30	31	32	33	34	35
①	②	①	②	①	①	①
36	37	38	39	40	41	42
①	①	②	①	①	①	②

단답형 정답: 43) 32×32 44) 448개 45) Hidden state 46) Forget/Input/Output gate 47) Positional Encoding 48) He initialization 49) Dropout 50) Grid Search, Random Search

1. 객관식 해설 - 이미지 딥러닝 모델

1. 정답 ①

해설: CNN은 이미지의 2차원 공간 구조를 보존하면서 지역적 패턴을 추출하고, 동일한 필터를 여러 위치에 공유한다. 이 때문에 FCN보다 이미지 처리에서 파라미터 효율성이 높다.

2. 정답 ②

해설: 합성곱 계층의 각 필터가 하나의 출력 feature map을 만들므로 출력 채널 수는 필터 개수와 같다.

3. 정답 ③

해설: 출력 크기는 $(W-K+2P)/S+1 = (32-3+2)/1+1 = 32$ 이므로 32×32 이다.

4. 정답 ④

해설: Pooling은 대표적으로 차원 축소와 지역 특징 요약에 사용되며, 연산 자체에 학습 파라미터가 없는 경우가 일반적이다.

5. 정답 ①

해설: 여러 합성곱 계층을 거치면 뒤쪽 뉴런 하나가 간접적으로 참조하는 원본 입력 범위가 넓어진다.

6. 정답 ②

해설: Stride가 커지면 필터의 이동 간격이 넓어져 출력 feature map의 공간 크기가 작아진다.

7. 정답 ①

해설: 공간 크기는 $(227-11)/4+1=55$ 이고 출력 채널은 필터 수인 96이므로 $55 \times 55 \times 96$ 이다.

8. 정답 ③

해설: 파라미터 수는 $96 \times 3 \times 11 \times 11 + 96 = 34,944$ 개이다.

9. 정답 ③

해설: 출력 원소는 $55 \times 55 \times 96 = 290,400$ 개이고, 4 Byte씩 저장하면 1,161,600 Byte로 약 1,134 KB이다.

10. 정답 ④

해설: 교재의 계산은 $(55 \times 55) \times (3 \times 11 \times 11 \times 96) \times 2 =$ 약 105.4M FLOPs이다.

11. 정답 ②

해설: VGG 계열은 3×3 의 작은 합성곱 필터를 반복적으로 쌓아 깊이를 늘리는 단순하고 규칙적인 구조가 특징이다.

12. 정답 ①

해설: 이름에서 드러나듯 VGG19가 VGG16보다 더 깊은 네트워크 구성을 사용한다.

13. 정답 ②

해설: ResNet은 입력을 우회 경로로 더하는 residual 구조를 통해 매우 깊은 네트워크를 안정적으로 학습할 수 있도록 한다.

14. 정답 ①

해설: MobileNet은 Depthwise convolution과 Pointwise(1×1) convolution을 분리해 계산량과 파라미터를 줄인다.

15. 정답 ②

해설: 교재의 모델 변천 흐름은 AlexNet(2012) → VGG 계열(2014) → ResNet(2015) → MobileNet(2017)의 순서로 이해할 수 있다.

II. 객관식 해설 - 다양한 신경망 모델

16. 정답 ②

해설: CNN은 지역적 특징 추출에 강하지만 순서가 중요한 시퀀스나 멀리 떨어진 요소 간 의존성을 직접 모델링하는 데 한계가 있다.

17. 정답 ②

해설: RNN은 각 시점의 입력과 이전 hidden state를 이용해 현재 hidden state를 계산함으로써 과거 정보를 전달한다.

18. 정답 ①

해설: 시간 순서대로 hidden state가 이어지므로 일반적인 RNN은 시점 간 계산을 완전히 병렬로 처리하기 어렵다.

19. 정답 ②

해설: 여러 시점의 입력을 누적해 마지막에 하나의 분류 결과를 내는 형태가 Many-to-One이다.

20. 정답 ②

해설: RNN은 시간축으로 펼쳐 표현해도 같은 파라미터가 각 시점에 반복 적용되는 구조이다.

21. 정답 ①

해설: 시간 역전파 과정에서 미분값이 반복적으로 곱해지면서 기울기가 지나치게 작아지거나 커질 수 있다.

22. 정답 ①

해설: LSTM은 cell state와 forget/input/output gate를 사용해 정보를 선택적으로 유지·삭제·출력한다.

23. 정답 ①

해설: LSTM은 forget gate, input gate, output gate를 통해 정보 흐름을 제어한다.

24. 정답 ①

해설: Attention은 현재 질의와 관련 있는 위치에 높은 가중치를 주어 먼 위치의 정보도 직접 활용할 수 있게 한다.

25. 정답 ①

해설: Self-Attention은 같은 시퀀스 또는 같은 패치 집합 안에서 각 요소가 다른 요소를 참조하도록 관련도를 계산한다.

26. 정답 ①

해설: Attention은 Query와 Key의 유사도를 바탕으로 가중치를 계산하고, 그 가중치로 Value를 가중합한다.

27. 정답 ①

해설: ViT는 이미지를 일정 크기의 패치로 분할해 토큰처럼 임베딩하고, 패치 위치를 알려주기 위해 위치 인코딩을 사용한다.

28. 정답 ③

해설: ViT는 대규모 데이터에서 강력하지만, 데이터가 적은 상황에서 항상 CNN보다 우수한 것은 아니다.

29. 정답 ①

해설: Knowledge Distillation은 성능이 좋은 teacher의 예측 정보나 표현을 student가 학습해 성능 향상에 도움을 주는 방식이다.

III. 객관식 해설 - 이미지 모델 학습 전략

30. 정답 ②

해설: 좋은 아키텍처를 선택하더라도 학습 전략이 잘못되면 수렴이 불안정하거나 성능이 낮을 수 있다.

31. 정답 ①

해설: 선형층만 반복하면 전체도 선형 변환에 머무르므로, 활성화 함수가 비선형 표현 능력을 부여한다.

32. 정답 ②

해설: Sigmoid는 입력 절댓값이 큰 구간에서 출력이 0 또는 1에 가까워지며 기울기가 작아져 깊은 네트워크 학습을 어렵게 할 수 있다.

33. 정답 ①

해설: Tanh는 0을 중심으로 한 출력 범위를 갖지만 큰 절댓값의 입력에서는 포화되어 기울기가 작아질 수 있다.

34. 정답 ①

해설: ReLU는 $\max(0, x)$ 형태로 양수 영역의 기울기를 유지해 학습이 쉽지만, 음수 영역이 계속되면 dead ReLU 문제가 생길 수 있다.

35. 정답 ①

해설: Leaky ReLU는 음수 영역을 완전히 0으로 만들지 않고 작은 기울기를 유지해 dead ReLU 현상을 완화한다.

36. 정답 ①

해설: 크기 조정, 텐서 변환, 정규화 등은 모델이 학습·추론 때 일관된 입력 분포를 받도록 한다.

37. 정답 ①

해설: 동일한 값으로 초기화하면 같은 층의 뉴런들이 같은 기울기를 받아 서로 다른 특징을 학습하기 어렵다.

38. 정답 ②

해설: He 초기화는 ReLU 계열에서 층을 지날 때 활성값과 기울기 분산을 비교적 안정적으로 유지하도록 설계되었다.

39. 정답 ①

해설: Weight Decay는 손실에 가중치 크기와 관련된 규제항을 추가해 과적합 완화에 도움을 준다.

40. 정답 ①

해설: Dropout은 학습 중 일부 뉴런을 무작위로 비활성화해 특정 뉴런 조합에 과도하게 의존하는 것을 줄인다.

41. 정답 ①

해설: 초기에는 비교적 큰 학습률로 빠르게 탐색하고 후반에는 더 작은 학습률로 안정적으로 수렴하도록 조절할 수 있다.

42. 정답 ②

해설: 하이퍼파라미터는 학습률·배치 크기·정규화 강도 등 사용자가 정하거나 탐색해야 하는 학습 설정값이다.

IV. 단답형 정답 및 해설

43. 입력 크기 63×63 , 커널 3×3 , $\text{stride}=2$, $\text{padding}=1$ 인 합성곱 계층의 출력 공간 크기($H \times W$)를 구하시오.

정답: 32×32

해설: $(63 - 3 + 2 \times 1) / 2 + 1 = 32$ 이므로 출력 공간 크기는 32×32 이다.

44. 입력 채널 3, 출력 채널 16, 커널 3×3 인 Conv 계층의 파라미터 수(가중치+편향)를 구하시오.

정답: 448개

해설: $16 \times 3 \times 3 \times 3 + 16 = 448$ 개이다.

45. RNN에서 이전 시점의 정보를 다음 시점으로 전달하는 상태의 이름을 쓰시오.

정답: Hidden state(은닉 상태)

해설: RNN은 hidden state를 통해 과거 정보를 다음 시점 계산에 전달한다.

46. LSTM의 세 가지 대표 gate 이름을 모두 쓰시오.

정답: Forget gate, Input gate, Output gate

해설: LSTM은 세 gate를 통해 cell state에 저장할 정보, 삭제할 정보, 출력할 정보를 조절한다.

47. ViT에서 이미지 패치의 순서·위치 정보를 모델에 알려주기 위해 추가하는 정보를 쓰시오.

정답: Positional Encoding(위치 인코딩)

해설: Self-Attention 자체는 위치 순서를 자동으로 알지 못하므로 패치 임베딩에 위치 정보를 추가한다.

48. ReLU 계열 활성화 함수와 함께 사용하기 적합한 대표 가중치 초기화 방법을 쓰시오.

정답: He initialization(He 초기화)

해설: He 초기화는 ReLU 계열에서 분산을 안정적으로 유지하도록 설계된 대표 초기화 방법이다.

49. 학습 중 일부 뉴런을 확률적으로 비활성화하여 과적합을 줄이는 방법을 쓰시오.

정답: Dropout(드롭아웃)

해설: Dropout은 특정 뉴런 조합에 대한 의존을 줄여 일반화 성능 향상을 노린다.

50. 하이퍼파라미터 탐색의 대표적인 두 가지 방법을 쓰시오.

정답: Grid Search(그리드 탐색), Random Search(랜덤 탐색)

해설: 교재에서 대표적인 하이퍼파라미터 선택 방식으로 격자 형태의 조합을 모두 확인하는 Grid Search와 무작위로 후보를 탐색하는 Random Search를 다룬다.

V. 서술형 모범답안 핵심 요소

51. CNN에서 합성곱, stride, pooling, 수용영역(receptive field)이 각각 어떤 역할을 하는지 설명하고, 이 요소들이 이미지 모델의 연산량과 특징 추출에 어떤 영향을 주는지 서술하시오.

채점 핵심 요소

- 합성곱은 지역 영역에서 필터를 공유해 특징을 추출함
- stride가 커질수록 출력 공간 해상도가 줄어듦
- pooling은 지역 특징을 요약하며 해상도·연산량을 줄임
- 층이 깊어질수록 수용영역이 커져 더 넓은 문맥을 반영함
- 지역 특징→더 추상적 특징으로 계층적 표현이 형성됨

채점 가이드: 핵심 요소를 정확한 용어로 설명하고, 항목 사이의 원인·결과 또는 비교 관계를 연결하면 높은 점수를 부여할 수 있다.

52. AlexNet, VGGNet, ResNet, MobileNet의 핵심 설계 아이디어를 비교하고, 모델 구조가 발전하면서 해결하려 한 문제를 흐름에 따라 설명하시오.

채점 핵심 요소

- AlexNet: 초기 대규모 CNN 성공 사례와 깊은 합성곱 모델의 확산
- VGG: 작은 3×3 필터를 반복해 단순하고 깊은 구조 구성
- ResNet: residual/skip connection으로 매우 깊은 네트워크의 최적화 문제 완화
- MobileNet: depthwise separable convolution으로 계산량·파라미터를 줄여 모바일 효율성 확보
- 성능 향상뿐 아니라 깊이 학습 안정성과 계산 효율성을 함께 개선하는 흐름

채점 가이드: 핵심 요소를 정확한 용어로 설명하고, 항목 사이의 원인·결과 또는 비교 관계를 연결하면 높은 점수를 부여할 수 있다.

53. 단순 RNN, LSTM, Attention, ViT를 장기 의존성 처리와 병렬화 관점에서 비교하여 설명하시오.

채점 핵심 요소

- RNN: hidden state를 순차 전달해 순서 정보 반영하지만 병렬화가 어렵고 장기 의존성에 취약
- LSTM: cell state와 gate로 장기 정보 유지 개선
- Attention: 필요한 위치를 직접 참조하여 장거리 의존성 완화
- Self-Attention은 시퀀스/패치 내부 관계를 직접 계산
- ViT는 이미지 패치를 토큰화하고 self-attention으로 전역 관계를 학습하며 위치 인코딩 사용

채점 가이드: 핵심 요소를 정확한 용어로 설명하고, 항목 사이의 원인·결과 또는 비교 관계를 연결하면 높은 점수를 부여할 수 있다.

54. 좋은 모델 구조를 선택했음에도 학습이 실패하거나 성능이 낮을 수 있는 이유를 활성화 함수, 데이터 전처리, 가중치 초기화, 정규화 관점에서 설명하시오.

채점 핵심 요소

- 부적절한 활성화 함수는 기울기 소실·dead neuron 등을 유발 가능
- 전처리 불일치는 입력 분포를 흔들어 학습/추론 성능 저하
- 0 초기화는 대칭성 문제를 만들며 Xavier/He 등 적절한 초기화 필요
- Weight Decay/Dropout 등 정규화는 과적합 완화에 활용
- 구조와 학습 전략을 함께 맞춰야 안정적 수렴과 일반화 가능

채점 가이드: 핵심 요소를 정확한 용어로 설명하고, 항목 사이의 원인·결과 또는 비교 관계를 연결하면 높은 점수를 부여할 수 있다.

55. 훈련 손실은 감소하지만 검증 성능이 더 이상 좋아지지 않고, 후반 학습이 불안정한 이미지 분류 모델이 있다고 하자. 학습률 스케줄, 정규화, 하이퍼파라미터 탐색, 학습 종료 판단을 이용해 개선 전략을 서술하시오.

채점 핵심 요소

- 후반에는 학습률을 낮추는 step/cosine/linear 등의 스케줄 고려
- Weight Decay 또는 Dropout으로 과적합 완화
- 학습률·배치 크기·정규화 강도 등을 Grid/Random Search로 탐색
- 훈련/검증 곡선을 함께 관찰해 과적합 여부 판단
- 검증 성능이 개선되지 않으면 적절한 시점에 학습을 종료(early stopping 관점)
- 단일 설정을 고정하기보다 실험 결과에 따라 조정

채점 가이드: 핵심 요소를 정확한 용어로 설명하고, 항목 사이의 원인·결과 또는 비교 관계를 연결하면 높은 점수를 부여할 수 있다.