

이미지 파운데이션 모델

정답 및 해설

교재 기반 · Markdown 문제 형식/난이도 참고

구분	대목차	문항 수
1	AI 파운데이션 모델 개념 및 대표 모델	13
2	Vision-Language Model (VLM)	12
3	Small VLM과 파운데이션 모델들 소개	13
4	개인화, 합성데이터 활용 사례	12
	객관식 + 단답형	50
	서술형	5

각 문항의 정답, 핵심 해설, 교재 참고 페이지를 포함합니다.

빠른 정답표

문제	정답	문제	정답	문제	정답	문제	정답	문제	정답
1	②	11	①	21	①	31	①	41	①
2	②	12	Adaptation	22	②	32	④	42	①
3	②	13	멀티모달 임베딩 공간	23	①	33	①	43	①
4	②	14	②	24	M-RoPE	34	②	44	①
5	②	15	④	25	Projection layer	35	②	45	①
6	②	16	①	26	②	36	①	46	①
7	①	17	②	27	①	37	Grounding DINO	47	①
8	②	18	②	28	①	38	Latent space	48	④
9	②	19	①	29	②	39	①	49	PEFT
10	①	20	①	30	①	40	①	50	RAG

1. AI 파운데이션 모델 개념 및 대표 모델

문제 1. 교재에서 설명하는 AI 모델의 특징으로 가장 적절한 것은?

정답: ②

교재는 AI 모델을 입력과 출력을 연결하는 함수로 설명하며, 데이터로부터 형태가 결정되고 학습 때 보지 못한 데이터에 대해서도 작동해야 한다고 설명한다.

참고: 교재 p.9

문제 2. Representation Learning에 대한 설명으로 옳은 것은?

정답: ②

교재는 학습을 데이터의 패턴화와 압축으로 설명하며, 비슷함과 다름을 파악하고 새로운 데이터에 일반화하는 능력을 Representation Learning과 연결한다.

참고: 교재 p.12

문제 3. 파운데이션 모델 기반 개발 프로세스의 순서로 가장 적절한 것은?

정답: ②

교재 그림의 파운데이션 모델 개발 흐름은 Data Creation, Data Curation, Training, Adaptation, Deployment 순서이다.

참고: 교재 p.15

문제 4. 파운데이션 모델 등장 이전의 일반적인 AI 개발 방식에 대한 설명으로 옳은 것은?

정답: ②

제공된 문제 스타일과 교재의 파운데이션 모델 도입 맥락에서는 기존 방식이 작업별로 별도 학습을 수행하는 형태로 설명된다.

참고: 교재 1차시 도입부

문제 5. CLIP의 핵심 학습 목표로 가장 적절한 것은?

정답: ②

CLIP은 이미지와 텍스트를 각각 인코딩한 뒤, 두 모달리티의 대응 관계와 유사도를 학습한다.

참고: 교재 p.27

문제 6. CLIP의 기본 구조에 대한 설명으로 옳은 것은?

정답: ②

CLIP은 Text Encoder와 Image Encoder로 각 모달리티를 임베딩하고 공통 공간에서 유사도를 비교한다.

참고: 교재 p.27

문제 7. 교재의 CLIP 구조 설명에서 텍스트 인코더로 제시된 구조는?

정답: ①

CLIP의 텍스트 인코더 설명에서는 Transformer의 Encoder 구조를 사용한다고 제시한다.

참고: 교재 p.30

문제 8. Vision Transformer(ViT)의 이미지 처리 방식으로 옳은 것은?

정답: ②

교재는 ViT가 이미지를 작은 패치(예: 16×16×3)로 나눈 뒤 patch/position embedding과 Transformer Encoder를 사용하는 구조로 설명한다.

참고: 교재 p.33

문제 9. CLIP의 대조학습(Contrastive Learning)에 대한 설명으로 가장 적절한 것은?

정답: ②

CLIP의 대조학습은 정답 이미지-텍스트 쌍의 유사도를 높이고, 비대응 쌍의 유사도를 낮추는 방향으로 학습한다.

참고: 교재 p.42

문제 10. 교재에서 CLIP의 대조 손실과 연결해 설명하는 확률 정규화 방식은?

정답: ①

교재는 CLIP의 Image→Text, Text→Image 대조 손실을 Softmax와 연결해 설명한다.

참고: 교재 p.42

문제 11. SigLIP에 대한 설명으로 옳은 것은?

정답: ①

SigLIP은 CLIP의 Softmax 기반 대조 손실 대신 Sigmoid loss를 채택하며, 교재에서는 노이즈가 증가한 상황에서 안정적인 성능을 보이는 예를 제시한다.

참고: 교재 p.51

문제 12. 파운데이션 모델 개발 프로세스에서 사전학습된 모델을 특정 목적이나 작업에 맞게 조정하는 단계를 영어 한 단어로 쓰시오.

정답: Adaptation

교재의 개발 프로세스는 Data Creation → Data Curation → Training → Adaptation → Deployment로 제시된다.

참고: 교재 p.15

문제 13. 이미지와 텍스트처럼 서로 다른 모달리티의 표현을 서로 비교할 수 있도록 정렬하는 공통 표현 공간을 무엇이라 하는가?

정답: 멀티모달 임베딩 공간(공통 임베딩 공간, joint multimodal embedding space)

CLIP 계열은 이미지와 텍스트 표현을 공통 임베딩 공간에 정렬하여 유사도와 대응 관계를 다룬다.

참고: 교재 p.42, p.57

2. Vision-Language Model (VLM)

문제 14. Vision-Language Model(VLM)에 대한 설명으로 가장 적절한 것은?

정답: ②

VLM은 비전 인코더와 언어 모델을 연결해 이미지와 텍스트를 함께 이해하고 언어 응답을 생성하는 모델 계열이다.

참고: 교재 p.66~69

문제 15. LLaVA의 대표적인 활용 예로 교재에 제시되지 않은 것은?

정답: ④

LLaVA는 이미지 기반 질문응답, 이미지 설명 생성, 시각 정보 기반 대화 등의 VLM 과업에 활용된다.

참고: 교재 p.69

문제 16. LLaVA 구조의 핵심 구성요소 조합으로 옳은 것은?

정답: ①

LLaVA는 Vision Encoder가 만든 시각 표현을 Projection W로 언어 모델의 표현 공간에 연결하고 Language Model이 응답을 생성한다.

참고: 교재 p.69

문제 17. LLaVA의 Step 1 사전학습(Pre-training)에 대한 설명으로 옳은 것은?

정답: ②

교재의 Step 1에서는 Vision Encoder와 Language Model을 고정하고 Projection W를 학습하여 이미지 표현을 언어 모델 표현에 맞춘다.

참고: 교재 p.71

문제 18. LLaVA의 Step 2 Fine-tuning에 대한 설명으로 가장 적절한 것은?

정답: ②

교재 Step 2 그림에서는 Language Model과 Projection W가 학습 대상이고 Vision Encoder는 동결된 상태로 표시된다.

참고: 교재 p.72

문제 19. LLaVA의 시각 지시 데이터(visual instruction data) 생성에 대한 설명으로 옳은 것은?

정답: ①

교재는 COCO의 이미지와 라벨 정보를 바탕으로 ChatGPT가 시각 지시 데이터를 자동 생성하는 LLaVA 학습 데이터 구성을 설명한다.

참고: 교재 p.73

문제 20. LLaVA 학습 데이터의 응답 유형으로 교재에 제시된 조합은?

정답: ①

LLaVA 시각 지시 데이터는 대화, 자세한 설명, 복잡한 추론 유형으로 구성될 수 있다고 제시된다.

참고: 교재 p.73

문제 21. Qwen2-VL의 M-RoPE(Multimodal Rotary Position Embedding)에 대한 설명으로 옳은 것은?

정답: ①

교재는 M-RoPE가 1D 텍스트, 2D 시각, 3D 비디오의 위치 민감 정보를 부여할 수 있다고 설명한다.

참고: 교재 p.79

문제 22. Qwen2.5-Omni의 “Omni” 특성을 가장 잘 설명한 것은?

정답: ②

교재는 Qwen2.5-Omni를 Text/Image/Audio/Video 등 여러 모달리티를 다루며 읽고·쓰고·보고·듣고·말하는 모델로 소개한다.

참고: 교재 p.81

문제 23. 의료 도메인 특화 파운데이션 모델에 대한 설명으로 옳은 것은?

정답: ①

교재는 의료 이미지와 텍스트를 연결하는 BiomedCLIP 계열과 LLaVA-Med 사례를 통해 진단, 분류, 설명 등의 태스크를 소개한다.

참고: 교재 p.89~91

문제 24. Qwen2-VL에서 1D 텍스트·2D 이미지·3D 비디오의 위치 정보를 다루기 위해 사용하는 위치 임베딩 기법의 약어를 쓰시오.

정답: M-RoPE

M-RoPE는 Multimodal Rotary Position Embedding의 약어이다.

참고: 교재 p.79

문제 25. LLaVA에서 Vision Encoder의 시각 표현을 Language Model이 사용할 수 있는 표현으로 연결해 주는 학습 가능한 층의 이름을 쓰시오.

정답: Projection layer(Projection W, 선형 투영층)

LLaVA의 Projection W는 시각 임베딩을 언어 모델 입력 표현으로 맞추는 연결 역할을 한다.

참고: 교재 p.69~72

3. Small VLM과 파운데이션 모델들 소개

문제 26. Small VLM(sVLM)이 필요한 주요 이유로 가장 적절한 것은?

정답: ②

교재 3차시는 대형 VLM의 서버 비용 문제를 제시하고, 로컬·모바일 환경에서 실행 가능한 경량 VLM을 다룬다.

참고: 교재 p.97~103

문제 27. SmolVLM에 대한 설명으로 옳은 것은?

정답: ①

교재는 SmolVLM을 Hugging Face가 개발한 sVLM으로 소개하고 다른 VLM 대비 낮은 추론 GPU 메모리 사용 예를 제시한다.

참고: 교재 p.103

문제 28. Moondream 0.5B의 양자화 예시가 시사하는 바와 가장 가까운 것은?

정답: ①

교재는 Moondream 0.5B에서 8비트와 4비트 양자화 시 모델 파일과 실행 메모리가 감소하는 예를 제시한다.

참고: 교재 p.106

문제 29. 한국어 sVLM을 별도로 고려할 필요성이 있는 이유로 교재에서 강조하는 것은?

정답: ②

교재는 영어 중심 토큰라이저에서 같은 의미라도 언어별 토큰 길이가 크게 달라질 수 있고, 비영어권 언어에서 컨텍스트 효율이 낮아질 수 있음을 설명한다.

참고: 교재 p.112

문제 30. Set of Mark(SoM) prompting의 핵심 아이디어로 가장 적절한 것은?

정답: ①

교재는 세그멘테이션 모델을 결합해 이미지의 대상에 마크와 번호를 부여하면 VLM의 위치·대상 이해 성능을 높일 수 있음을 보여준다.

참고: 교재 p.121

문제 31. Grounding DINO에 대한 설명으로 옳은 것은?

정답: ①

Grounding DINO는 텍스트 입력으로 이미지 속 대상의 위치를 탐지하고, 다양한 물체에 대한 일반화 성능을 강조하는 모델로 소개된다.

참고: 교재 p.124

문제 32. 다음 중 이미지 생성(text-to-image) 모델이 아닌 것은?

정답: ④

SAM은 이미지 세그멘테이션 모델이며 텍스트-이미지 생성 모델이 아니다.

참고: 제공 Markdown 출제 기준 및 교재 3차시

문제 33. 생성 모델링의 목표를 교재의 표기와 가장 가깝게 나타낸 것은?

정답: ①

교재는 실제 데이터 분포 $p_{\text{data}}(x)$ 를 직접 알 수 없으므로, 생성 모델 $p_{\text{model}}(x)$ 가 이를 근사하도록 학습하는 것을 목표로 설명한다.

참고: 교재 p.130

문제 34. Latent Diffusion Model(LDM)의 특징으로 옳은 것은?

정답: ②

LDM은 픽셀 공간 대신 압축된 latent 공간에서 diffusion을 수행하여 연산 효율과 생성 품질을 높이는 방식으로 설명된다.

참고: 교재 p.133

문제 35. 교재와 제공된 문제 기준에서 “오픈” 이미지 생성 모델에 해당하는 조합은?

정답: ②

제공된 Markdown 문제 기준에서는 Stable Diffusion과 Latent Diffusion Model을 오픈 이미지 생성 모델로 분류한다.

참고: 제공 Markdown 3-2 문제 51

문제 36. ControlNet의 역할로 가장 적절한 것은?

정답: ①

ControlNet은 스케치, depth, edge, segmentation, human pose 등의 조건 신호를 입력하여 이미지 생성 결과를 제어하는 모델로 소개된다.

참고: 교재 p.142

문제 37. 텍스트로 “판다”, “달리는 소녀” 등의 대상을 지정해 이미지에서 해당 물체를 탐지하는 모델 이름을 쓰시오.

정답: Grounding DINO

Grounding DINO는 텍스트 조건 기반 open-set object detection 모델로 설명된다.

참고: 교재 p.124

문제 38. Latent Diffusion Model에서 픽셀 공간 대신 diffusion 연산을 수행하는 압축된 저차원 표현 공간을 무엇이라 하는가?

정답: Latent space(잠재 공간, latent embedding 공간)

LDM은 인코더로 이미지 정보를 latent embedding으로 압축한 후 latent space에서 확산·복원 과정을 수행한다.

참고: 교재 p.133

4. 개인화, 합성데이터 활용 사례

문제 39. 개인화가 필요한 상황으로 교재의 학습 시작 예시와 가장 가까운 것은?

정답: ①

교재 4차시는 범용 파운데이션 모델이 특정 도메인에 바로 맞지 않을 때 개인화·적응이 필요하다는 문제의식에서 시작한다.

참고: 교재 p.163

문제 40. 프롬프트 디자인(prompt design)의 장점과 단점을 올바르게 묶은 것은?

정답: ①

교재는 프롬프트 디자인이 추가 학습 없이 사전학습 모델의 성능을 활용할 수 있지만, 사람이 직접 설계해야 하고 항상 폭이 제한적일 수 있다고 설명한다.

참고: 교재 p.179

문제 41. 프롬프트 튜닝(prompt tuning)의 특징으로 옳은 것은?

정답: ①

교재의 비교 그림에서 prompt tuning은 사전학습 모델을 고정한 채 학습 가능한 프롬프트를 추가해 최적화하는 방식으로 제시된다.

참고: 교재 p.181

문제 42. 교재의 “모델 튜닝-프롬프트 튜닝-프롬프트 디자인” 비교에서 가장 적절한 설명은?

정답: ①

교재는 모델 튜닝을 높은 성능, prompt tuning과 prompt design을 상대적으로 높은 효율 측면에서 비교한다.

참고: 교재 p.181

문제 43. DreamBooth의 개인화 활용에 대한 설명으로 가장 적절한 것은?

정답: ①

교재는 특정 강아지의 여러 입력 이미지를 이용해 아크로폴리스, 수영, 미용 등 새로운 상황의 이미지를 생성하는 DreamBooth 개인화 예를 제시한다.

참고: 교재 p.183

문제 44. 합성데이터 활용에서 Knowledge Distillation(Teacher-Student 학습)의 핵심 아이디어로 가장 적절한 것은?

정답: ①

교재는 사전학습된 고성능 모델의 지식을 타겟 모델로 전달하는 형태를 합성데이터 활용 및 Knowledge Distillation 맥락에서 소개한다.

참고: 교재 p.187 전후

문제 45. InstructPix2Pix에서 지도학습용 데이터셋의 핵심 구성으로 가장 적절한 것은?

정답: ①

교재는 instruction 기반 이미지 편집을 위해 {편집 지시, 편집 전 이미지, 편집 후 이미지} 형태의 학습 쌍을 구성한다고 설명한다.

참고: 교재 p.191

문제 46. 합성데이터를 사용하는 이유로 교재의 문제의식과 가장 가까운 것은?

정답: ①

교재는 의료·3D·움직임 등 현실 데이터가 개인정보, 비용, 장비 제약 때문에 부족할 수 있으며 합성데이터가 이를 보완할 수 있음을 다룬다.

참고: 교재 p.163, p.187~203

문제 47. Sora 사례와 관련해 교재가 제시하는 응용 방향으로 옳은 것은?

정답: ①

교재는 Sora의 텍스트-비디오 생성 예와 함께 비디오 생성 기반 3D 장면 복원 가능성을 응용 사례로 제시한다.

참고: 교재 p.207

문제 48. RAG(Retrieval Augmented Generation)의 장점으로 교재에 제시되지 않은 것은?

정답: ④

교재는 RAG의 유연성, 개인화, 정확성/verification을 장점으로 들며 외부 검색을 이용하는 방식이다.

참고: 교재 p.211

문제 49. 사전학습 모델 전체가 아니라 일부 파라미터나 프롬프트 등 제한된 요소를 조정하여 효율적으로 미세 조정하는 방법을 통칭하는 약어를 쓰시오.

정답: PEFT

PEFT는 Parameter-Efficient Fine-Tuning의 약어이다.

참고: 교재 p.179~181

문제 50. 검색 결과를 언어 모델의 생성에 결합하여 최신 정보·개인화·검증을 지원하는 기법의 약어를 쓰시오.

정답: RAG

RAG는 Retrieval Augmented Generation의 약어이다.

참고: 교재 p.211

서술형 모범 답안 및 채점 포인트

문제 51. 파운데이션 모델의 개념과 Representation Learning을 설명하고, 파운데이션 모델 기반 개발 프로세스(Data Creation부터 Deployment까지)를 순서대로 서술하시오. 이어서 CLIP과 SigLIP의 학습 방식 차이를 함께 설명하시오.

모범 답안

파운데이션 모델은 대규모 데이터에서 일반적인 표현을 학습한 뒤 다양한 작업에 적응시키는 기반 모델이다. 학습 과정에서는 데이터의 패턴과 유사성·차이를 압축된 표현으로 학습하는 Representation Learning이 중요하다. 교재의 개발 흐름은 Data Creation → Data Curation → Training → Adaptation → Deployment이다. CLIP은 이미지 인코더와 텍스트 인코더의 표현을 공통 임베딩 공간에 정렬하고 대조학습으로 대응 쌍의 유사도를 높인다. 교재에서는 CLIP을 Softmax 기반 대조 손실로 설명하며, SigLIP은 이를 Sigmoid loss로 바꾼 모델로 소개한다.

채점 핵심 요소

- AI 모델은 데이터로부터 형태를 학습하고 보지 못한 데이터에도 일반화하도록 요구됨
- Representation Learning: 패턴·유사성/차이를 학습해 압축된 표현을 형성
- Data Creation → Data Curation → Training → Adaptation → Deployment
- CLIP: 이미지·텍스트 공통 임베딩 및 대조학습, Softmax 기반 손실로 설명
- SigLIP: Sigmoid loss를 사용하며 교재에서 노이즈 상황의 안정적 성능을 강조

문제 52. LLaVA를 예로 들어 VLM의 기본 구조를 설명하고, LLaVA의 Step 1 사전학습과 Step 2 Fine-tuning에서 어떤 구성요소를 학습/고정하는지 비교하여 서술하시오. 또한 시각 지시 데이터가 어떻게 만들어지는지도 설명하시오.

모범 답안

LLaVA는 Vision Encoder, Projection W, Language Model을 결합한 VLM이다. Vision Encoder가 이미지 특징을 만들고 Projection W가 이를 Language Model이 사용할 수 있는 표현으로 변환한다. Step 1에서는 기존 Vision Encoder와 Language Model을 고정하고 Projection을 학습해 두 표현 공간을 연결한다. Step 2에서는 Vision Encoder는 고정한 채 Projection과 Language Model을 특정 작업에 맞게 미세 조정한다. 학습 데이터는 COCO의 이미지·캡션·바운딩박스 정보 등을 활용하고 ChatGPT로 대화, 상세 설명, 복잡한 추론 형태의 visual instruction data를 생성하는 방식이 제시된다.

채점 핵심 요소

- Vision Encoder + Projection W + Language Model 구조
- Vision Encoder가 시각 표현 생성, Projection이 언어 모델 입력 표현으로 연결
- Step 1: Vision Encoder와 Language Model 고정, Projection 중심 학습
- Step 2: Vision Encoder는 고정, Projection과 Language Model 등 필요한 부분 미세조정
- COCO 이미지·캡션·바운딩박스 등을 바탕으로 ChatGPT가 conversation/detailed description/complex reasoning 지시 데이터를 생성

문제 53. Small VLM이 필요한 이유를 설명하고, SmolVLM·Moondream과 같은 경량 모델에서 메모리 효율이 왜 중요한지 서술하시오. 이어서 영어 중심 토큰라이저가 한국어 등 비영어권 언어에 불리할 수 있는 이유를 토큰 정보 밀도 관점에서 설명하시오.

모범 답안

Small VLM은 대형 VLM의 서버 비용과 메모리 부담을 줄이고 개인 PC, 스마트폰 같은 제한된 환경에서 실행하기 위해 필요하다. SmolVLM은 비교적 낮은 추론 GPU 메모리 사용을 목표로 하고, Moondream은 8비트·4비트 양자화를 통해 모델 크기와 실행 메모리를 줄이는 예가 제시된다. 또한 영어 중심 토큰라이저는 영어 문장보다 한국어 등 비영어권 문장을 더 많은 토큰으로 분할할 수 있어 동일한 컨텍스트 길이에서 담을 수 있는 정보량이 줄어드는 비효율이 발생할 수 있다.

채점 핵심 요소

- 대형 VLM은 서버/GPU 비용과 메모리 부담이 큼
- 개인 PC·스마트폰·엣지 환경에서는 경량화가 중요
- SmolVLM은 낮은 GPU 메모리 사용 사례로 소개

- Moondream은 저비트 양자화로 파일·실행 메모리 감소 사례
- 영어 중심 토크나이저는 비영어권에서 동일 의미 표현 시 더 많은 토큰을 소비할 수 있어 컨텍스트 효율 저하

문제 54. 다음 네 모델의 역할을 서로 비교하여 서술하시오: SAM, Grounding DINO, Latent Diffusion Model(LDM), ControlNet. 각 모델이 어떤 입력과 결과를 다루는지 중심으로 설명하시오.

모범 답안

SAM은 이미지에서 대상 영역을 분할하는 세그멘테이션 모델이다. Grounding DINO는 “판다”, “달리는 소녀” 같은 텍스트 조건으로 이미지 내 해당 객체의 위치를 탐지한다. LDM은 이미지를 latent embedding으로 압축한 뒤 저차원 잠재 공간에서 diffusion을 수행하여 이미지를 생성한다. ControlNet은 LDM 계열 이미지 생성에 스케치, depth map, edge, segmentation, human pose 같은 제어 조건을 추가해 원하는 구조의 생성 결과를 유도한다.

채점 핵심 요소

- SAM: 이미지 세그멘테이션/영역 분할 모델, text-to-image 생성 모델이 아님
- Grounding DINO: 텍스트 조건으로 이미지 내 객체를 탐지
- LDM: 저차원 latent space에서 diffusion을 수행하는 이미지 생성 모델
- ControlNet: sketch/depth/edge/pose 등 조건 신호로 생성 결과를 제어
- 탐지-분할-생성-조건제어 역할의 차이를 명확히 구분

문제 55. 파운데이션 모델을 특정 사용자나 도메인에 맞게 활용하는 방법을 프롬프트 디자인, 프롬프트 튜닝, 모델 미세조정 관점에서 비교하시오. DreamBooth 개인화와 합성데이터(InstructPix2Pix), RAG가 어떤 문제를 해결하는지도 함께 설명하시오.

모범 답안

프롬프트 디자인은 모델을 추가 학습하지 않고 입력 문구를 사람이 설계하는 가장 가벼운 방법이지만 성능 항상 폭이 제한될 수 있다. 프롬프트 튜닝은 사전학습 모델을 고정하고 학습 가능한 프롬프트만 최적화한다. 모델 미세조정은 더 많은 파라미터를 실제로 조정해 높은 성능을 기대할 수 있지만 비용이 커진다. DreamBooth는 소수의 특정 대상 이미지를 이용해 그 대상을 새로운 장면으로 생성하는 개인화 방법이다. InstructPix2Pix는 편집 지시, 편집 전 이미지, 편집 후 이미지 형태의 학습 데이터를 구성해 지시 기반 편집을 학습한다. RAG는 외부 검색을 생성 과정에 결합해 추가 학습 없이 최신 정보를 활용하고, 개인화와 verification을 통해 환각을 줄이는 데 도움을 준다.

채점 핵심 요소

- Prompt design: 추가 학습 없음, 사람이 설계, 효율적이나 성능 항상 제한 가능
- Prompt tuning: 모델은 고정하고 학습 가능한 프롬프트를 최적화
- Model fine-tuning: 더 많은 모델 파라미터를 조정해 높은 성능 가능하지만 비용 증가
- DreamBooth: 특정 대상의 소수 이미지로 새로운 장면의 개인화 생성
- InstructPix2Pix: 편집 지시+편집 전+편집 후 이미지 형태의 데이터로 instruction 기반 편집 학습
- RAG: 외부 검색으로 최신 정보, 개인화, verification을 통한 환각 감소에 도움