

자연어 처리 기본

복습 문제 - 정답 및 해설

시험 전 복습 · 개념 확인용

범위

워드 임베딩과 순환신경망 기반 모델

자연어 생성 모델

Transformer

사전 학습 기반 언어 모델

문항 구성 및 분포

총 50 문제(객관식 42 + 단답형 8) + 서술형 5 문제

대목차	문항 범위	문항 수
I. 워드 임베딩과 순환신경망 기반 모델	Q1-Q13	13
II. 자연어 생성 모델	Q14-Q26	13
III. Transformer	Q27-Q38	12
IV. 사전 학습 기반 언어 모델	Q39-Q50	12

정답지 구성: 객관식·단답형은 정답과 핵심 해설을, 서술형은 모범 답안에 포함되어야 할 핵심 요소를 제시합니다.

I. 워드 임베딩과 순환신경망 기반 모델

문제 1. 원-핫 인코딩(One-hot Encoding)의 한계에 대한 설명으로 옳지 않은 것은?

- ① 어휘 수가 커질수록 벡터 차원이 커진다.
- ② 대부분의 원소가 0 이어서 희소한 표현이 된다.
- ③ 서로 다른 단어 사이의 의미적 유사성을 자연스럽게 반영한다.
- ④ 서로 다른 단어의 원-핫 벡터는 직교하는 형태가 된다.

정답: ③

해설: 원-핫 벡터는 단어를 구분하기는 쉽지만 의미적 관계를 담지 못한다. 교재에서는 차원의 저주, 의미적 유사성 부족, 직교 문제를 주요 한계로 정리한다.

문제 2. 워드 임베딩(Word Embedding)에 대한 설명으로 가장 적절한 것은?

- ① 각 단어를 어휘 크기와 동일한 희소 이진 벡터로만 표현한다.
- ② 단어를 밀집된 실수 벡터로 표현하여 의미적 관계를 반영할 수 있다.
- ③ 단어의 순서를 제거하기 위해 사용하는 규칙 기반 전처리이다.
- ④ 문장 전체를 하나의 범주형 라벨로 변환하는 방법이다.

정답: ②

해설: 워드 임베딩은 단어를 비교적 낮은 차원의 밀집 실수 벡터로 표현하고, 학습 과정에서 단어 간 의미적 관계가 벡터 공간에 반영되도록 한다.

문제 3. Word2Vec의 핵심 아이디어에 가장 가까운 설명은?

- ① 단어와 주변 단어의 관계를 예측하는 방식으로 단어 표현을 학습한다.
- ② 모든 단어를 사전에 정의된 정수 하나로만 표현한다.
- ③ 문장 전체의 길이를 고정한 뒤 이미지처럼 합성곱한다.
- ④ 정답 라벨 없이 단어의 등장 횟수만 저장한다.

정답: ①

해설: 교재는 Word2Vec을 단어와 주변 단어의 관계를 예측하면서 의미적 임베딩을 학습하는 방법으로 설명한다.

문제 4. CBOW와 Skip-gram의 예측 방향을 올바르게 연결한 것은?

- ① CBOW: 중심 단어→주변 단어 / Skip-gram: 주변 단어→중심 단어
- ② CBOW: 주변 단어→중심 단어 / Skip-gram: 중심 단어→주변 단어
- ③ 두 방법 모두 중심 단어→문장 전체를 예측한다.
- ④ 두 방법 모두 주변 단어의 순서를 직접 예측한다.

정답: ②

해설: CBOW는 주변 단어(Context)를 이용해 중심 단어(Target)를 예측하고, Skip-gram은 중심 단어로 주변 단어를 예측한다.

문제 5. 교재에서 설명한 CBOW와 Skip-gram의 일반적인 특성으로 옳은 것은?

- ① CBOW는 학습이 비교적 빠르고 빈출 단어에 강한 편이다.
- ② CBOW는 희귀 단어 학습에 항상 Skip-gram보다 강하다.
- ③ Skip-gram은 주변 단어를 입력으로 중심 단어를 예측한다.
- ④ Skip-gram은 지도학습이고 CBOW는 비지도학습이다.

정답: ①

해설: 교재의 확인문제에서는 CBOW가 비교적 빠르고 데이터가 적을 때 효율적인 편이며, Skip-gram은 희귀 단어 학습에 더 효과적인 경향을 강조한다.

문제 6. 순차적 데이터(Sequential Data)의 특징으로 가장 적절한 것은?

- ① 데이터의 순서를 바꾸어도 의미가 항상 동일하다.
- ② 현재 요소가 이전 요소들과의 관계에 영향을 받을 수 있다.
- ③ 입력 길이는 항상 고정되어야 한다.
- ④ 시간적 의존성은 학습 대상이 아니다.

정답: ②**해설:** 언어와 같은 순차적 데이터는 순서가 중요하고 장기 의존성이 존재할 수 있으며 가변 길이 처리가 필요하다.**문제 7. RNN 이 FNN 이나 일반적인 CNN 과 구별되는 핵심 특징은?**

- ① 은닉 상태를 다음 시점으로 전달하는 순환 구조를 가진다.
- ② 입력 데이터를 항상 고정 길이의 1 차원 벡터로만 받는다.
- ③ 순서 정보가 모델에 들어오지 않는다.
- ④ 학습 가능한 파라미터가 존재하지 않는다.

정답: ①**해설:** RNN 은 이전 시점의 hidden state 를 다음 시점 계산에 사용하여 순차 데이터의 시간적 의존성을 반영한다.**문제 8. RNN 의 hidden state 에 대한 설명으로 옳은 것은?**

- ① 각 시점에서 이전 정보와 현재 입력을 반영한 내부 상태이다.
- ② 시간이 지날수록 차원이 반드시 계속 증가한다.
- ③ 출력과 무관한 고정된 임의 벡터이다.
- ④ 첫 시점에서만 사용되고 이후에는 폐기된다.

정답: ①**해설:** hidden state 는 이전 시점의 정보를 요약해 다음 시점으로 전달하는 내부 상태이며, 차원은 일반적으로 고정된다.**문제 9. 기본 RNN 이 긴 문맥의 장기 의존성을 학습하기 어려운 대표적 이유는?**

- ① 모든 입력이 원-핫 벡터이기 때문이다.
- ② 역전파 과정에서 기울기 소실이 발생할 수 있기 때문이다.
- ③ 은닉 상태를 사용하지 않기 때문이다.
- ④ 항상 병렬 연산만 수행하기 때문이다.

정답: ②**해설:** RNN 은 긴 시퀀스에서 반복적인 연산과 역전파로 인해 기울기 소실/폭발 문제가 발생할 수 있으며, 특히 기울기 소실은 장기 의존성 학습을 어렵게 한다.**문제 10. LSTM 이 기본 RNN 에 비해 장기 정보를 더 잘 유지하도록 도입한 핵심 요소는?**

- ① Convolution filter
- ② Cell state 와 게이트 구조
- ③ Pooling layer
- ④ One-hot decoder

정답: ②**해설:** LSTM 은 cell state 라는 정보 통로와 여러 게이트를 사용해 정보의 보존·삭제·출력을 조절한다.**문제 11. LSTM 의 게이트와 역할에 대한 연결로 가장 적절한 것은?**

- ① Forget gate: 유지하거나 버릴 정보를 조절한다.
- ② Input gate: 항상 모든 과거 정보를 삭제한다.
- ③ Output gate: 입력 문장을 원-핫 벡터로 바꾼다.
- ④ 세 게이트는 학습 과정에서 사용되지 않는다.

정답: ①

해설: Forget gate 는 기존 cell state 에서 무엇을 잊을지, Input gate 는 새 정보를 얼마나 반영할지, Output gate 는 현재 cell state 에서 출력할 정보를 조절한다.

문제 12. LSTM 에서 정보의 흐름을 조절하는 세 가지 게이트의 이름을 모두 쓰시오.

정답: Forget gate, Input gate, Output gate

해설: 교재는 LSTM 의 핵심을 Cell state 와 Forget/Input/Output 세 게이트의 정보 흐름 제어로 정리한다.

문제 13. CBOW 와 Skip-gram 의 예측 방향을 각각 한 문장으로 쓰시오.

정답: CBOW: 주변 단어로 중심 단어를 예측 / Skip-gram: 중심 단어로 주변 단어를 예측

해설: 두 방법의 가장 큰 차이는 입력과 예측 대상의 방향에 있다.

II. 자연어 생성 모델

문제 14. 언어 모델(Language Model)의 역할로 가장 적절한 것은?

- ① 주어진 문맥을 바탕으로 다음 단어(토큰)의 확률을 예측한다.
- ② 모든 문장을 고정 길이 이미지로 변환한다.
- ③ 문장 안의 모든 단어를 동시에 삭제한다.
- ④ 입력 문장의 클래스 라벨만 출력한다.

정답: ①

해설: 교재에서는 언어 모델을 주어진 문맥에서 다음 단어의 확률을 예측하여 추론하는 모델로 설명한다.

문제 15. 교재의 N-gram 언어 모델 설명으로 옳은 것은?

- ① 항상 문서 전체를 고려해 다음 단어를 예측한다.
- ② 직전 N 개의 단어만 고려하여 다음 단어를 예측한다.
- ③ 단어 순서를 전혀 사용하지 않는다.
- ④ 이미지 패치의 확률을 예측하는 모델이다.

정답: ②

해설: 교재의 강의 정리에서는 N-gram 언어 모델이 직전 N 개의 단어만 고려해 다음 단어를 예측한다고 설명한다.

문제 16. Seq2Seq의 기본 구조에 대한 설명으로 옳은 것은?

- ① 인코더가 입력 시퀀스를 처리하고, 디코더가 출력 시퀀스를 생성한다.
- ② 디코더가 입력 시퀀스를 처리하고, 인코더가 출력 시퀀스를 생성한다.
- ③ 인코더와 디코더는 서로 독립적으로 학습되어야 한다.
- ④ 입력과 출력의 길이는 반드시 같아야 한다.

정답: ①

해설: Seq2Seq는 Encoder-Decoder 구조이며, 인코더가 입력을 표현으로 변환하고 디코더가 이를 조건으로 출력 시퀀스를 생성한다.

문제 17. 기본 Seq2Seq에서 인코더가 수행하는 역할로 가장 적절한 것은?

- ① 입력 시퀀스를 고정 차원의 문맥 표현(Context)으로 변환한다.
- ② 출력 정답을 직접 분류 라벨로 바꾼다.
- ③ 미래 단어를 마스킹한다.
- ④ 입력 문장의 길이를 출력과 같게 강제한다.

정답: ①

해설: 기본 Seq2Seq에서 인코더는 입력 시퀀스를 읽어 고정 차원의 context vector로 요약한다.

문제 18. Seq2Seq 모델의 장점으로 옳은 것은?

- ① 입력과 출력 시퀀스의 길이가 달라도 처리할 수 있다.
- ② 항상 하나의 단어만 출력할 수 있다.
- ③ 출력 생성에 인코더 정보가 필요 없다.
- ④ 역전파를 통한 통합 학습이 불가능하다.

정답: ①

해설: Seq2Seq는 번역처럼 입력과 출력 길이가 서로 다른 시퀀스 변환 문제를 처리할 수 있고, 인코더와 디코더를 End-to-End로 함께 학습한다.

문제 19. Seq2Seq의 Bottleneck Problem에 대한 설명으로 가장 적절한 것은?

- ① 긴 입력 시퀀스의 모든 정보를 하나의 고정된 문맥 벡터에 압축하면서 정보가 손실될 수 있다.

- ② 디코더의 파라미터 수가 항상 0 이 되는 문제이다.
- ③ 입력과 출력의 길이가 같아지는 문제이다.
- ④ 단어를 원-핫으로 표현할 수 없는 문제이다.

정답: ①

해설: 기본 Seq2Seq 는 긴 입력을 하나의 고정 길이 context vector 에 담으면서 정보 손실이 커질 수 있다. Attention 은 이 병목을 완화하기 위해 등장한다.

문제 20. Attention 메커니즘의 핵심 아이디어는?

- ① 출력 생성 시 입력 문장의 어느 부분이 중요한지 선택적으로 집중한다.
- ② 인코더의 크기를 무조건 두 배로 만든다.
- ③ 입력 문장의 단어를 모두 같은 가중치로 취급한다.
- ④ 디코더를 여러 개 독립적으로 학습한다.

정답: ①

해설: Attention 은 디코딩 시점마다 입력의 서로 다른 부분에 가중치를 두어 중요한 정보에 선택적으로 집중한다.

문제 21. Attention 이 기본 Seq2Seq 의 병목을 완화하는 방식으로 가장 적절한 것은?

- ① 디코더가 각 시점에서 인코더의 여러 hidden state 를 직접 참고할 수 있게 한다.
- ② 인코더의 hidden state 를 모두 제거한다.
- ③ 출력 시퀀스를 항상 한 단어로 줄인다.
- ④ 모든 attention weight 를 동일하게 고정한다.

정답: ①

해설: Attention 을 사용하면 디코더는 단 하나의 고정 context 에만 의존하지 않고 여러 인코더 hidden state 를 필요에 따라 참고할 수 있다.

문제 22. Attention weight 에 대한 설명으로 옳은 것은?

- ① 현재 출력과 각 입력 위치의 관련성이 클수록 더 큰 가중치를 줄 수 있다.
- ② 항상 모든 입력 위치에서 동일해야 한다.
- ③ 학습과 무관한 난수이다.
- ④ 문장 길이가 길면 사용할 수 없다.

정답: ①

해설: Attention 은 현재 디코딩 시점과 입력 위치 사이의 정렬(Alignment) 또는 관련성을 수치화해 가중치로 사용한다.

문제 23. Seq2Seq 의 End-to-End 학습에 대한 설명으로 옳은 것은?

- ① 인코더와 디코더가 하나의 목적 함수에 의해 함께 최적화될 수 있다.
- ② 인코더만 학습되고 디코더는 고정된다.
- ③ 두 모듈은 반드시 별개의 데이터셋으로만 학습된다.
- ④ 역전파를 사용할 수 없다.

정답: ①

해설: 교재는 Seq2Seq 를 역전파를 통해 인코더와 디코더가 통합적으로 최적화되는 End-to-End 학습 구조로 설명한다.

문제 24. 다음 중 Attention 의 효과로 보기 가장 어려운 것은?

- ① 긴 시퀀스에서 정보 손실을 줄이는 데 도움을 준다.
- ② 출력 시점마다 중요한 입력 부분에 집중한다.
- ③ 입력과 출력 사이의 정렬 관계를 표현할 수 있다.
- ④ 모든 시점에서 하나의 동일한 고정 문맥 벡터만 사용하도록 강제한다.

정답: ④

해설: Attention의 목적은 고정된 하나의 context vector만 사용하는 제약을 완화하고, 각 출력 시점에서 관련 입력 정보를 동적으로 참고하는 것이다.

문제 25. Seq2Seq를 구성하는 두 핵심 모듈의 이름을 쓰시오.

정답: Encoder(인코더), Decoder(디코더)

해설: 인코더는 입력을 표현으로 만들고, 디코더는 그 표현을 조건으로 출력 시퀀스를 생성한다.

문제 26. Attention이 해결하려는 Seq2Seq의 대표적 한계 한 가지를 쓰시오.

정답: Bottleneck Problem(긴 입력 정보를 하나의 고정 길이 context vector에 압축하며 생기는 정보 손실)

해설: Attention은 필요한 입력 위치를 직접 참고해 기본 Seq2Seq의 고정 context 병목을 완화한다.

III. Transformer

문제 27. RNN 기반 모델이 대규모 학습에서 비효율적일 수 있는 이유로 교재가 강조한 것은?

- ① 시퀀스 길이만큼 순차적인 계산 단계가 필요해 병렬화가 어렵다.
- ② 가중치를 전혀 공유하지 않기 때문이다.
- ③ 항상 이미지 입력만 처리하기 때문이다.
- ④ GPU에서는 연산할 수 없기 때문이다.

정답: ①

해설: RNN은 이전 시점 결과에 다음 시점 계산이 의존하므로 forward/backward 모두 시퀀스 길이에 따른 순차 단계가 필요해 병렬화가 어렵다.

문제 28. Self-Attention에서 각 입력 토큰으로부터 만들어지는 세 벡터는?

- ① Query, Key, Value
- ② Input, Output, Label
- ③ Forget, Input, Output
- ④ Mean, Variance, Bias

정답: ①

해설: Self-Attention은 각 토큰을 Query(Q), Key(K), Value(V) 벡터로 변환해 토큰 간 연관성을 계산한다.

문제 29. Self-Attention에서 Query와 Key의 내적이 주로 사용되는 목적은?

- ① 토큰 간 관련성(Attention Score)을 계산하기 위해
- ② 문장 길이를 줄이기 위해
- ③ 단어를 원-핫으로 되돌리기 위해
- ④ 모델의 층 수를 결정하기 위해

정답: ①

해설: 교재는 Query와 Key의 내적을 통해 Attention Score를 얻고, 이를 Value에 가중합하여 출력 벡터를 만든다고 설명했다.

문제 30. Self-Attention의 출력 생성 과정으로 가장 적절한 것은?

- ① Attention Score를 이용해 Value 벡터들을 가중합한다.
- ② Query 벡터만 그대로 출력한다.
- ③ Key 벡터를 모두 삭제한다.
- ④ Value 벡터의 차원을 매 시점 증가시킨다.

정답: ①

해설: Q-K 관계로 얻은 가중치를 V에 적용하여 관련 정보가 강조된 출력 표현을 생성한다.

문제 31. Self-Attention만으로는 토큰의 순서 정보를 직접 알기 어렵기 때문에 사용하는 것은?

- ① Positional Encoding
- ② Max Pooling
- ③ Dropout만 단독 사용
- ④ K-means

정답: ①

해설: Self-Attention은 위치 자체를 내재적으로 구분하지 않으므로 위치 정보를 입력에 더하거나 결합하는 Positional Encoding이 필요하다.

문제 32. 교재에서 소개한 Positional Encoding의 대표적인 위치 표현 방식은?

- ① 사인(sine)·코사인(cosine) 함수를 이용한 위치 정보 표현
- ② 모든 위치에 동일한 상수만 더하기
- ③ 토큰 순서를 무작위로 섞기
- ④ 문장을 이미지 픽셀 좌표로 변환하기

정답: ①**해설:** 교재 참고 자료는 사인·코사인 기반 위치 정보 표현으로 Positional Encoding의 필요성과 직관을 설명한다.**문제 33. Self-Attention 뒤에 Feed-Forward Network(FFN)를 두는 주요 이유로 가장 적절한 것은?**

- ① 비선형 변환 능력을 추가하여 더 복잡한 패턴을 학습하기 위해
- ② 토큰 순서를 완전히 제거하기 위해
- ③ 미래 단어를 모두 보이게 하기 위해
- ④ Attention Score를 항상 1로 만들기 위해

정답: ①**해설:** 교재는 Self-Attention의 선형 결합 한계를 보완하기 위해 각 토큰 위치에 FFN을 적용하여 비선형 표현력을 추가한다고 설명한다.**문제 34. 언어 생성에서 Masked Self-Attention을 사용하는 이유는?**

- ① 현재 위치가 미래 토큰을 미리 참조하는 정보 누수를 막기 위해
- ② 입력 문장의 위치 정보를 없애기 위해
- ③ 모든 토큰을 동시에 [MASK]로 바꾸기 위해
- ④ 인코더의 출력을 사용하지 않기 위해

정답: ①**해설:** 생성 시 미래 토큰을 보면 정답 정보가 누수된다. 교재에서는 미래 위치 점수에 $-\infty$ 를 부여해 softmax 가중치가 0이 되도록 마스킹하는 방식을 설명한다.**문제 35. Transformer 인코더 블록의 역할에 대한 설명으로 옳은 것은?**

- ① Self-Attention, 위치 정보, FFN 등을 이용해 입력 문맥을 분석한다.
- ② 미래 단어만 보고 이전 단어를 생성한다.
- ③ 입력을 하나의 고정 라벨로만 변환한다.
- ④ RNN의 hidden state를 반드시 순차적으로 전달한다.

정답: ①**해설:** 교재의 강의 정리에서는 인코더 블록이 입력을 Self-Attention + Positional Encoding + FFN으로 처리해 문맥 정보가 담긴 의미 표현을 만든다고 정리한다.**문제 36. Multi-Head Attention에 대한 설명으로 옳지 않은 것은?**

- ① 여러 헤드가 서로 다른 관계를 병렬로 포착할 수 있다.
- ② 헤드 수를 늘리면 언제나 성능이 무한히 향상된다.
- ③ 적정 헤드 수는 데이터·모델·최적화 조건에 따라 달라질 수 있다.
- ④ 헤드가 지나치게 많으면 중복된 패턴을 학습할 수도 있다.

정답: ②**해설:** 교재 확인문제는 Attention Head 수가 증가한다고 성능이 무한히 좋아지는 것은 아니며 중복 헤드와 최적 헤드 수의 존재 가능성을 강조한다.**문제 37. Self-Attention의 Q, K, V를 각각 풀어 쓰시오.****정답: Query, Key, Value**

해설: 각 입력 토큰은 Query, Key, Value 로 투영되고, Query-Key 관계로 가중치를 계산해 Value 를 모은다.

문제 38. Self-Attention 의 세 가지 대표적 한계와 이를 보완하는 요소를 한 쌍씩 쓰시오.

정답: 순서 정보 부재→Positional Encoding / 비선형성 부족→Feed-Forward Network / 미래 참조 문제→Masked Self-Attention

해설: 교재 확인문제에서 세 한계와 해결법을 직접 대응시켜 정리한다.

IV. 사전 학습 기반 언어 모델

문제 39. 사전학습(Pretraining)에 대한 설명으로 가장 적절한 것은?

- ① 대규모 데이터에서 일반적인 언어 패턴을 먼저 학습한 뒤 특정 태스크에 적용하는 단계이다.
- ② 특정 태스크의 정답 데이터만으로 처음부터 모델을 학습하는 과정이다.
- ③ 학습 없이 프롬프트만 바꾸는 과정이다.
- ④ 모든 파라미터를 무작위로 고정하는 과정이다.

정답: ①

해설: 교재는 사전학습을 네트워크 무작위 초기화 이후 대규모 언어 데이터로 일반 언어 패턴을 먼저 학습하고, 이후 fine-tuning 등으로 태스크에 최적화하는 흐름으로 설명한다.

문제 40. 사전학습 기반 언어 모델의 대표적인 구조와 모델 연결로 옳은 것은?

- ① Encoder-BERT / Encoder-Decoder-T5 / Decoder-GPT
- ② Encoder-GPT / Encoder-Decoder-BERT / Decoder-T5
- ③ Encoder-T5 / Encoder-Decoder-GPT / Decoder-BERT
- ④ 세 모델 모두 Encoder-only 구조이다.

정답: ①

해설: 교재 학습 목표에서 BERT는 Encoder 기반, T5는 Encoder-Decoder 기반, GPT는 Decoder 기반 대표 모델로 소개한다.

문제 41. 워드 임베딩만 사전학습하고 나머지 네트워크를 무작위 초기화하는 접근의 한계로 교재가 언급한 것은?

- ① 다운스트림 태스크에 필요한 풍부한 문맥 정보를 충분히 학습하기 어렵고, 나머지 네트워크 학습도 처음부터 필요하다.
- ② 단어 임베딩 자체를 사용할 수 없게 된다.
- ③ 모든 태스크에서 항상 완벽한 성능을 낸다.
- ④ 모델 파라미터가 전혀 존재하지 않는다.

정답: ①

해설: 교재는 워드 임베딩 사전학습만으로는 문맥 정보 학습이 제한되고, 상위 네트워크가 무작위 초기화되어 많은 데이터와 시간이 필요하다는 한계를 설명한다.

문제 42. BERT의 Masked Language Modeling(MLM)에서 학습 대상으로 무작위 선택하는 입력 토큰의 비율은?

- ① 5%
- ② 10%
- ③ 15%
- ④ 50%

정답: ③

해설: 교재는 입력 토큰의 15%를 무작위로 선택한 뒤 80%는 [MASK], 10%는 랜덤 토큰, 10%는 그대로 두는 절차를 제시한다.

문제 43. BERT MLM에서 선택된 토큰의 처리 비율을 올바르게 설명한 것은?

- ① 80% [MASK] / 10% 랜덤 토큰 / 10% 그대로 유지
- ② 100% [MASK]
- ③ 50% 삭제 / 50% 그대로 유지
- ④ 80% 랜덤 토큰 / 20% [SEP]

정답: ①

해설: 교재는 마스킹된 위치에만 과도하게 의존하지 않도록 선택 토큰을 80/10/10 방식으로 다양하게 변형한다.

문제 44. BERT의 Next Sentence Prediction(NSP)의 주된 목적은?

- ① 두 문장 사이의 관계를 학습하여 문장 수준 문맥 이해에 도움을 주는 것
- ② 이미지의 다음 픽셀을 예측하는 것
- ③ 한 문장 안의 모든 단어를 삭제하는 것
- ④ 단어 임베딩 차원을 줄이는 것

정답: ①**해설:** NSP는 두 문장 세그먼트가 실제로 이어지는지 학습하여 문장 간 관계와 문맥적 추론을 익히도록 설계되었다.**문제 45. BERT에서 두 문장 세그먼트를 구분하기 위해 사용하는 특별 토큰은?**

- ① [CLS]
- ② [MASK]
- ③ [SEP]
- ④ [END]

정답: ③**해설:** 교재의 확인문제와 해설은 [SEP]가 두 세그먼트를 구분하는 특별 토큰임을 명시한다.**문제 46. BERT의 토큰 수준(Token Level) 다운스트림 태스크 예로 교재에서 제시한 것은?**

- ① 개체명 인식(Named Entity Recognition, NER)
- ② 이미지 분할
- ③ 주가 회귀 예측
- ④ 음성 파형 생성

정답: ①**해설:** 교재는 CoNLL 2003 NER을 BERT의 대표적인 Token Level 다운스트림 태스크로 소개하고 BIO 계열 라벨 예시를 제시한다.**문제 47. Decoder 기반 언어 모델(예: GPT)의 특징으로 가장 적절한 것은?**

- ① 이전 토큰을 바탕으로 다음 토큰을 순차적으로 생성하는 단방향(Autoregressive) 구조이다.
- ② 항상 양방향 문맥을 모두 사용해 가려진 단어만 복원한다.
- ③ 출력 생성에는 적합하지 않다.
- ④ Encoder와 Decoder를 반드시 동시에 사용한다.

정답: ①**해설:** 교재는 Decoder-only 모델을 전형적인 언어 생성 구조로 설명하며, 미래 단어를 참조하지 않고 이전 토큰을 바탕으로 다음 토큰을 생성한다고 정리한다.**문제 48. T5에 대한 설명으로 옳지 않은 것은?**

- ① Encoder-Decoder 구조를 사용한다.
- ② 다양한 NLP 문제를 Text-to-Text 형식으로 통일한다.
- ③ Span Corruption 방식으로 사전학습할 수 있다.
- ④ BERT의 NSP를 사용해 두 문장 연결 여부만을 예측하는 것이 핵심 학습 방식이다.

정답: ④**해설:** 교재 확인문제는 T5의 주요 특징으로 Text-to-Text, Encoder-Decoder, Span Corruption을 제시하고 NSP는 BERT 계열 학습 방식으로 구분한다.**문제 49. GPT-3에서 강조된 In-Context Learning의 세 설정을 예시 개수 기준으로 쓰시오.****정답: Zero-shot, One-shot, Few-shot**

해설: 교재는 GPT-3 에서 모델 크기가 커질수록 zero-shot, one-shot, few-shot 전반에서 In-Context Learning 능력이 강해지는 현상을 소개한다.

문제 50. Chain-of-Thought(CoT) prompting 의 핵심 역할을 한 문장으로 쓰시오.

정답: 중간적 논리적 사고(추론) 단계를 유도하여 최종 답을 도출하도록 돕는 프롬프팅 방법

해설: 교재는 CoT 를 ICL 능력을 끌어올리기 위한 대표 기법으로, 논리적인 사고 단계를 거쳐 답을 도출하도록 유도한다고 설명한다.

V. 서술형 문제

서술형은 단순 용어 나열보다 개념 간 관계와 동작 원리를 설명하는 것을 목표로 합니다.

문제 51. [워드 임베딩과 RNN/LSTM] 원-핫 인코딩과 워드 임베딩의 차이를 설명하고, Word2Vec의 CBOW와 Skip-gram의 예측 방향을 비교하시오. 마지막으로 워드 임베딩이 원-핫 인코딩의 어떤 한계를 완화하는지 서술하시오.

모범 답안 핵심 요소

- 원-핫: 고차원·희소·의미적 유사성 반영 어려움
- 워드 임베딩: 밀집 실수 벡터, 의미 관계 표현 가능
- CBOW: 주변 단어→중심 단어
- Skip-gram: 중심 단어→주변 단어
- 임베딩 공간에서 의미적으로 가까운 단어를 가까운 표현으로 학습할 수 있음을 설명

채점 포인트: 핵심 용어를 정확히 쓰는 것뿐 아니라, 각 개념이 왜 필요한지와 앞뒤 개념 사이의 인과관계를 논리적으로 설명했는지를 함께 평가한다.

문제 52. [RNN과 LSTM] RNN이 순차 데이터를 처리하는 원리를 hidden state 관점에서 설명하고, 긴 시퀀스에서 발생하는 장기 의존성 문제의 원인을 쓰시오. 이어서 LSTM이 Cell state와 세 가지 게이트를 통해 이 문제를 어떻게 완화하는지 설명하시오.

모범 답안 핵심 요소

- RNN: 이전 hidden state + 현재 입력으로 현재 상태 계산
- 순서·시간적 의존성 반영
- 기울기 소실/폭발 및 장기 의존성 학습 어려움
- LSTM: Cell state를 통한 장기 정보 통과
- Forget/Input/Output gate의 역할을 각각 설명

채점 포인트: 핵심 용어를 정확히 쓰는 것뿐 아니라, 각 개념이 왜 필요한지와 앞뒤 개념 사이의 인과관계를 논리적으로 설명했는지를 함께 평가한다.

문제 53. [Seq2Seq와 Attention] 기본 Seq2Seq의 Encoder-Decoder 동작을 설명하고 Bottleneck Problem이 왜 발생하는지 서술하시오. 이후 Attention이 디코딩 시점마다 입력의 중요한 부분을 선택하여 이 문제를 어떻게 완화하는지 설명하시오.

모범 답안 핵심 요소

- Encoder가 입력 시퀀스를 context 표현으로 변환
- Decoder가 context를 조건으로 출력 생성
- 고정 길이 context에 긴 입력을 압축해 정보 손실 가능
- Attention score/weight로 입력 위치의 중요도 계산
- 여러 encoder hidden state를 동적으로 참고하여 병목 완화

채점 포인트: 핵심 용어를 정확히 쓰는 것뿐 아니라, 각 개념이 왜 필요한지와 앞뒤 개념 사이의 인과관계를 논리적으로 설명했는지를 함께 평가한다.

문제 54. [Transformer] Self-Attention의 Q, K, V를 이용한 계산 흐름을 설명하고, Self-Attention의 세 가지 한계인 순서 정보 부재·비선형성 부족·미래 참조 문제를 Transformer가 각각 어떻게 보완하는지 서술하시오.

모범 답안 핵심 요소

- Q/K/V 변환
- Q-K 관계로 Attention Score 계산
- Value 가중합으로 출력 생성

- 순서 정보 부재→Positional Encoding
- 비선형성 부족→FFN
- 미래 참조→Masked Self-Attention

채점 포인트: 핵심 용어를 정확히 쓰는 것뿐 아니라, 각 개념이 왜 필요한지와 앞뒤 개념 사이의 인과관계를 논리적으로 설명했는지를 함께 평가한다.

문제 55. [사전학습 기반 언어 모델] 사전학습의 목적을 설명한 뒤 BERT, T5, GPT의 구조와 대표 학습/활용 특징을 비교하시오. 마지막으로 GPT-3의 In-Context Learning과 Chain-of-Thought prompting이 무엇인지 설명하시오.

모범 답안 핵심 요소

- 사전학습: 대규모 데이터에서 일반 언어 패턴 학습 후 다운스트림 적용
- BERT: Encoder, MLM/NSP, 양방향 문맥 이해
- T5: Encoder-Decoder, Text-to-Text, Span Corruption
- GPT: Decoder-only, Autoregressive 생성
- ICL: zero/one/few-shot 문맥 예시로 수행
- CoT: 중간 추론 단계를 유도하여 답 도출

채점 포인트: 핵심 용어를 정확히 쓰는 것뿐 아니라, 각 개념이 왜 필요한지와 앞뒤 개념 사이의 인과관계를 논리적으로 설명했는지를 함께 평가한다.