

텍스트 파운데이션 모델

복습문제 - 정답 및 해설

시험 전 복습 · 개념 확인용

대목차	문항 범위	문항 수
텍스트 파운데이션 모델 살펴보기	1~13	13
거대 언어 모델의 학습	14~26	13
거대 언어 모델의 추론	27~38	12
거대 언어 모델의 평가와 응용	39~50	12

구성: 객관식 42 문제 + 단답형 8 문제 = 50 문제 / 서술형 5 문제

객관식 정답표

1. 2	2. 4	3. 3	4. 1	5. 2	6. 2
7. 2	8. 1	9. 3	10. 2	11. 2	14. 1
15. 1	16. 2	17. 2	18. 1	19. 2	20. 2
21. 1	22. 1	23. 2	24. 2	27. 2	28. 1
29. 2	30. 2	31. 2	32. 2	33. 2	34. 1
35. 1	36. 1	39. 1	40. 1	41. 1	42. 1
43. 1	44. 1	45. 1	46. 4	47. 1	48. 1

단답형 정답

문제 12. Scaling Law(스케일링 법칙)

문제 13. 창발성(Emergent Property)

문제 25. 보상 모델(Reward Model, RM)

문제 26. 정렬(Alignment)

문제 37. Zero-shot CoT(Zero-shot Chain-of-Thought)

문제 38. EOS 토큰(End-of-Sequence token)

문제 49. 환각(Hallucination)

문제 50. 탈옥(Jailbreaking)

1. 텍스트 파운데이션 모델 살펴보기 (1~13)

문제 1. [객관식] 파운데이션 모델(Foundation Model)에 대한 설명으로 가장 적절한 것은?

정답: 2

해설: 교재에서는 파운데이션 모델을 대량의 데이터로 사전학습하여 다양한 작업에 범용적으로 활용할 수 있는 기초 역할의 모델로 설명한다.

문제 2. [객관식] 교재에서 설명하는 파운데이션 모델의 주요 구성 요소와 가장 거리가 먼 것은?

정답: 4

해설: 파운데이션 모델의 핵심은 대규모 데이터/모델, 자기 지도 학습, Transformer 기반 구조 등이며, 작업마다 모델을 새로 설계하는 것은 파운데이션 모델 이전 방식에 가깝다.

문제 3. [객관식] 거대 언어 모델(LLM)과 BERT, GPT-1 같은 기존 언어 모델의 차이를 설명할 때 교재에서 특히 강조한 것은?

정답: 3

해설: 다음 토크 예측과 Transformer 는 기존 언어 모델에도 존재한다. 교재는 규모가 커지며 나타나는 창발성을 LLM 의 중요한 특징으로 제시한다.

문제 4. [객관식] 언어 모델(Language Model)의 기본 역할로 가장 적절한 것은?

정답: 1

해설: 교재의 GPT-2 예시처럼 언어 모델은 앞의 토크들을 바탕으로 다음 토크의 확률을 모델링한다.

문제 5. [객관식] Scaling Law 에 대한 설명으로 옳은 것은?

정답: 2

해설: 교재는 데이터 크기, 모델 크기, 계산량 증가에 따라 테스트 손실이 낮아지고 성능이 좋아지는 경향을 Scaling Law 로 설명한다.

문제 6. [객관식] 창발성(Emergent Property)에 대한 설명으로 가장 적절한 것은?

정답: 2

해설: 교재는 모델 규모가 커질 때 특정 과제의 성능이 비선형적으로 나타나는 현상을 창발성으로 소개한다.

문제 7. [객관식] 폐쇄형(Closed) 거대 언어 모델과 개방형(Open sourced) 거대 언어 모델의 차이에 대한 설명으로 옳은 것은?

정답: 2

해설: 교재는 폐쇄형 모델을 주로 서비스/API 형태로 제공되는 모델, 개방형 모델을 모델/가중치 등을 공개해 직접 활용 가능한 모델로 구분한다.

문제 8. [객관식] 다음 중 교재에서 폐쇄형(Closed) 거대 언어 모델의 예로 제시된 것만 묶은 것은?

정답: 1

해설: 교재의 폐쇄형 예시는 ChatGPT(OpenAI), Claude(Anthropic), Gemini(Google)이다.

문제 9. [객관식] 다음 중 교재에서 개방형(Open sourced) 거대 언어 모델의 예로 제시된 것은?

정답: 3

해설: 교재는 LLaMA(Meta), Gemma(Google), Qwen(Alibaba) 등을 개방형 거대 언어 모델 예로 제시한다.

문제 10. [객관식] 파운데이션 모델 등장 이전의 일반적인 AI 개발 방식과 비교했을 때 파운데이션 모델의 장점으로 가장 적절한 것은?

정답: 2

해설: 파운데이션 모델은 사전학습된 표현을 바탕으로 다양한 하위 작업에 적응할 수 있어 작업별 독립 학습 부담을 줄인다.

문제 11. [객관식] 교재에서 자기 지도 학습(Self-supervised Learning)이 파운데이션 모델에 중요한 이유로 설명한 내용은?

정답: 2

해설: 자기 지도 학습은 데이터 자체에서 예측 목표를 구성하므로 사람이 대규모 데이터에 일일이 정답을 달지 않아도 사전학습이 가능하다.

문제 12. [단답형] 데이터 크기, 모델 크기, 계산량이 증가할수록 언어 모델 성능이 일정한 경향으로 향상되는 관계를 무엇이라 하는가?

정답: Scaling Law(스케일링 법칙)

해설: 교재의 텍스트 파운데이션 모델 특징에서 데이터·모델·연산 규모와 성능의 관계를 Scaling Law 로 설명한다.

문제 13. [단답형] 모델의 규모가 일정 수준을 넘으면서 이전에는 잘 나타나지 않던 새로운 능력이 관찰되는 현상을 무엇이라 하는가?

정답: 창발성(Emergent Property)

해설: 규모 확장에 따라 특정 능력이 급격히 나타나는 현상을 창발성이라 한다.

2. 거대 언어 모델의 학습 (14~26)

문제 14. [객관식] GPT-3의 사전학습 방식에 대한 설명으로 옳은 것은?

정답: 1

해설: 교재는 GPT-3가 대규모 텍스트에서 다음 토큰 예측을 통해 사전학습된다고 설명한다.

문제 15. [객관식] GPT-3와 함께 주목받기 시작한 In-context Learning에 대한 설명으로 가장 적절한 것은?

정답: 1

해설: In-context Learning은 프롬프트 안에 지시나 예시를 제공해 모델이 문맥을 바탕으로 과제를 수행하도록 하는 특성이 있다.

문제 16. [객관식] 다음 토큰 예측만으로 사전학습된 언어 모델의 한계로 교재가 제시한 내용은?

정답: 2

해설: 사전학습만으로는 사용자의 의도와 가치에 맞게 정렬되지 않아 부정확하거나 원하지 않는 응답이 나올 수 있다.

문제 17. [객관식] 거대 언어 모델에서 정렬(Alignment)의 의미로 가장 적절한 것은?

정답: 2

해설: 교재는 Alignment를 언어 모델의 출력이 사용자의 의도와 가치에 맞도록 하는 과정으로 설명하며 지시 학습과 선호 학습을 소개한다.

문제 18. [객관식] 지시 학습(Instruction Tuning)의 주요 목적은?

정답: 1

해설: 지시 학습은 지시-응답 형태의 지도 데이터로 모델을 추가 학습해 다양한 지시를 더 잘 따르게 하는 방법이다.

문제 19. [객관식] FLAN 방식의 지시 학습에 대한 설명으로 옳은 것은?

정답: 2

해설: 교재는 FLAN이 여러 태스크의 다양한 지시 템플릿을 이용해 지시 학습을 수행하고 새로운 태스크로의 일반화를 높인다고 설명한다.

문제 20. [객관식] 효과적인 지시 학습을 위해 교재에서 강조한 조건으로 가장 적절한 것은?

정답: 2

해설: 지시 학습은 다양한 지시와 태스크를 포함하는 데이터가 중요하며, 모델 규모가 너무 작으면 지시 학습 후 성능이 충분히 향상되지 않을 수 있다.

문제 21. [객관식] 선호 학습(Preference Learning)의 핵심 아이디어로 옳은 것은?

정답: 1

해설: 선호 학습은 여러 후보 응답에 대해 사람이 선호를 제공하고 이를 학습에 반영하여 모델을 사람의 선호에 맞춘다.

문제 22. [객관식] RLHF 과정에서 보상 모델(Reward Model)의 역할로 가장 적절한 것은?

정답: 1

해설: 사람의 비교·선호 데이터를 이용해 보상 모델을 학습하고, 보상 모델이 이후 정책 모델의 응답을 점수화한다.

문제 23. [객관식] RLHF의 일반적인 학습 순서로 옳은 것은?

정답: 2

해설: 교재는 InstructGPT 방식의 세 단계를 SFT(지시 학습), 사람 선호 비교 데이터로 Reward Model 학습, Reward Model 기반 강화학습 정책 최적화로 설명한다.

문제 24. [객관식] RLHF 과정에서 사람의 개입에 대한 설명으로 옳은 것은?

정답: 2

해설: 교재의 InstructGPT 설명처럼 초기 지시 데이터와 비교 데이터에는 사람의 참여가 필요하지만, 정책 최적화 단계는 보상 모델을 이용해 반복적으로 진행된다.

문제 25. [단답형] 사람이 여러 응답을 비교해 제공한 선호 데이터를 학습하여, 이후 모델 응답의 좋고 나쁨을 점수로 평가하는 모델을 무엇이라 하는가?

정답: 보상 모델 (Reward Model, RM)

해설: 보상 모델은 사람의 선호 비교 데이터를 학습해 응답에 보상 점수를 부여한다.

문제 26. [단답형] 거대 언어 모델의 출력이 사용자의 의도와 사람의 가치에 더 잘 맞도록 만드는 과정을 영어 용어와 함께 쓰시오.

정답: 정렬 (Alignment)

해설: 교재에서는 지시 학습과 선호 학습을 통해 모델을 Alignment 한다고 설명한다.

3. 거대 언어 모델의 추론 (27~38)

문제 27. [객관식] 거대 언어 모델의 자동회귀 생성 (Auto-regressive Generation)에 대한 설명으로 옳은 것은?

정답: 2

해설: 자동회귀 생성은 현재까지의 문맥을 바탕으로 다음 토큰 확률을 계산하고 토큰을 하나씩 생성하는 방식이다.

문제 28. [객관식] Greedy Decoding 의 동작 방식으로 옳은 것은?

정답: 1

해설: Greedy Decoding 은 매 생성 단계에서 가장 높은 확률의 토큰을 선택하는 가장 단순한 디코딩 방법이다.

문제 29. [객관식] Beam Search 에 대한 설명으로 가장 적절한 것은?

정답: 2

해설: Beam Search 는 beam size 만큼 후보 경로를 유지해 Greedy 보다 더 넓게 탐색하지만 계산 비용이 증가한다.

문제 30. [객관식] Sampling 기반 디코딩의 특징으로 옳은 것은?

정답: 2

해설: Sampling 은 모델의 확률 분포를 바탕으로 무작위 선택을 허용하므로 생성 다양성이 높아질 수 있다.

문제 31. [객관식] Temperature 를 1 보다 크게 설정했을 때 일반적으로 나타나는 현상은?

정답: 2

해설: 교재는 $T > 1$ 일 때 분포가 평탄해져 생성 다양성이 증가하고, $T < 1$ 이면 분포가 뾰족해져 안정적이지만 다양성이 감소한다고 설명한다.

문제 32. [객관식] Top-K Sampling 에 대한 설명으로 옳은 것은?

정답: 2

해설: Top-K 는 매 시점 확률이 높은 K 개의 토큰으로 후보 집합을 제한한 뒤 샘플링한다.

문제 33. [객관식] Top-P Sampling (Nucleus Sampling)에 대한 설명으로 옳은 것은?

정답: 2

해설: Top-P 는 고정 개수 대신 누적 확률 기준으로 후보 집합 크기를 동적으로 정한다.

문제 34. [객관식] 교재에서 설명한 입력 프롬프트의 기본 구성으로 가장 적절한 것은?

정답: 1

해설: 교재는 입력 프롬프트를 지시문과 선택적인 few-shot 예시로 구성할 수 있다고 설명한다.

문제 35. [객관식] Chain-of-Thought(CoT) 프롬프팅의 목적에 가장 가까운 것은?

정답: 1

해설: CoT 는 예시 또는 지시를 통해 중간 추론 단계를 생성하도록 유도하여 산술·논리 등 추론 과제의 성능을 높이는 기법이다.

문제 36. [객관식] 시스템 프롬프트(System Prompt)와 사용자 질의(User Query)의 관계에 대한 설명으로 옳은 것은?

정답: 1

해설: 교재는 시스템 프롬프트를 기본 행동·역할을 설정하는 지시, 사용자 질의를 실제 사용자의 요청으로 구분한다.

문제 37. [단답형] 별도의 예시 없이 “Let's think step by step.”과 같은 문구로 단계적 추론을 유도하는 프롬프팅 방식을 무엇이라 하는가?

정답: Zero-shot CoT (Zero-shot Chain-of-Thought)

해설: 교재는 예시 기반 CoT 없이도 “Let's think step by step.” 같은 문구로 추론 과정을 유도하는 Zero-shot CoT 를 소개한다.

문제 38. [단답형] 자동회귀 생성에서 문장 생성의 종료를 나타내는 특별한 토큰을 무엇이라 하는가?

정답: EOS 토큰(End-of-Sequence token)

해설: 언어 모델은 EOS 가 생성되거나 사전에 정한 종료 조건에 도달하면 생성을 멈춘다.

4. 거대 언어 모델의 평가와 응용 (39~50)

문제 39. [객관식] 거대 언어 모델 평가(Evaluation)의 목적에 가장 가까운 것은?

정답: 1

해설: 교재는 평가를 구현한 시스템(모델·코드·앱)이 실제로 잘 동작하는지 확인하는 단계로 설명한다.

문제 40. [객관식] 정답이 명확하게 하나로 정해지는 분류·객관식 과제에서 가장 직접적으로 사용할 수 있는 평가 지표는?

정답: 1

해설: 정답이 명확한 경우에는 예측 정답과 기준 정답을 직접 비교해 Accuracy 를 계산할 수 있다.

문제 41. [객관식] 정답 문장이 하나로 고정되지 않는 요약·생성 과제에서 Accuracy 만 사용하기 어려운 이유는?

정답: 1

해설: 생성 과제는 표현이 달라도 의미상 정답일 수 있어 정확 일치만으로 품질을 판단하기 어렵다.

문제 42. [객관식] ROUGE 에 대한 설명으로 가장 적절한 것은?

정답: 1

해설: 교재는 정답이 고정되지 않는 생성 과제에서 기준 문장과 생성 문장의 겹치는 표현을 비교하는 지표로 ROUGE 를 제시한다.

문제 43. [객관식] 문장 임베딩을 이용한 의미적 유사도 평가에 대한 설명으로 옳은 것은?

정답: 1

해설: 교재는 문자열 겹침 외에 문장 임베딩 벡터 간 코사인 유사도로 의미적 유사성을 측정하는 방법을 소개한다.

문제 44. [객관식] Perplexity(PPL)에 대한 설명으로 옳은 것은?

정답: 1

해설: Perplexity 는 언어 모델이 실제 토큰 시퀀스에 부여한 확률을 바탕으로 예측의 불확실성을 측정한다. 일반적으로 낮을수록 해당 텍스트를 더 잘 예측한다.

문제 45. [객관식] LLM-as-a-Judge 방식의 장점으로 가장 적절한 것은?

정답: 1

해설: 교재는 생성형 과제에서 강한 LLM 을 평가자로 사용해 응답을 채점하거나 비교하는 방법을 소개한다.

문제 46. [객관식] LLM-as-a-Judge 에서 주의해야 할 편향으로 교재가 설명한 것과 가장 거리가 먼 것은?

정답: 4

해설: 교재는 위치(순서) 편향, 길이 편향, 자기 선호 편향 등을 LLM 평가자의 한계로 설명한다.

문제 47. [객관식] LM Arena 와 같은 상대적 선호 평가의 기본 아이디어로 가장 적절한 것은?

정답: 1

해설: 교재는 정답이 명확하지 않은 생성 모델 평가 방법으로 두 응답을 비교해 사용자의 상대적 선호를 수집하는 방식을 소개한다.

문제 48. [객관식] Self-Instruct 와 같은 합성 데이터 생성 방식에 대한 설명으로 가장 적절한 것은?

정답: 1

해설: 교재는 Self-Instruct 에서 seed instruction 을 바탕으로 LLM 이 대량의 지시 데이터를 생성하고, 중복·부적절한 데이터를 필터링해 다양성을 확보하는 과정을 설명한다.

문제 49. [단답형] 사실과 다르거나, 전적으로 지어낸 내용임에도 불구하고 그럴듯하고 확신에 찬 형태로 잘못된 정보를 생성하는 거대 언어 모델의 한계를 무엇이라 하는가?

정답: 환각(Hallucination)

해설: 교재는 거대 언어 모델의 대표적 한계로 사실과 다른 내용을 그럴듯하게 생성하는 Hallucination 을 설명한다.

문제 50. [단답형] 프롬프트를 변형하거나 우회하여 모델의 안전 정책·가이드라인을 무력화하고 원래 제한된 응답을 끌어내려는 공격을 무엇이라 하는가?

정답: 탈옥(Jailbreaking)

해설: 교재는 DAN 등의 사례와 함께 안전 정책을 우회하는 Jailbreaking 을 거대 언어 모델의 한계로 소개한다.

5. 서술형 모범 답안 (51~55)

서술형 51. 파운데이션 모델과 기존의 작업별 AI 모델의 차이를 설명하고, 파운데이션 모델을 가능하게 한 세 가지 핵심 요소(규모 확장, 자기 지도 학습, Transformer)를 각각 설명하시오. 또한 Scaling Law와 창발성이 이 흐름에서 어떤 의미를 갖는지 서술하시오.

모범 답안/채점 핵심: 핵심 요소: (1) 기존 방식은 작업별 데이터와 별도 모델 학습이 필요했으나 파운데이션 모델은 대규모 사전학습 모델을 여러 하위 작업에 적응시켜 활용한다. (2) 규모 확장: 더 많은 데이터, 더 큰 모델, 더 많은 계산량을 이용한다. (3) 자기 지도 학습: 데이터 자체에서 학습 신호를 만들어 사람의 대규모 라벨링 없이 사전학습한다. (4) Transformer/Attention: 멀리 떨어진 토큰 간 관계를 모델링하고 대규모 병렬 학습에 적합한 구조를 제공한다. (5) Scaling Law: 데이터·모델·계산 규모 증가와 성능 향상 사이의 경험적 경향. (6) 창발성: 일정 규모 이상에서 이전에는 뚜렷하지 않던 새로운 능력이 급격히 나타나는 현상.

서술형 52. 거대 언어 모델을 사용자의 의도와 가치에 맞추기 위한 Alignment의 필요성을 설명하고, InstructGPT/RLHF 파이프라인을 지시 학습(SFT), 보상 모델 학습, 강화학습 기반 정책 최적화의 세 단계로 나누어 설명하시오. 각 단계에서 사람의 역할도 함께 쓰시오.

모범 답안/채점 핵심: 사전학습의 다음 토큰 예측만으로는 사용자의 의도·안전·선호에 맞지 않는 응답이 나올 수 있어 Alignment가 필요하다. 1 단계 SFT: 사람이 만든 지시-모범 응답 데이터로 모델을 지도 추가 학습한다. 2 단계 Reward Model: 동일 프롬프트에 대한 여러 응답을 사람이 비교·순위화하고, 이 비교 데이터로 사람의 선호를 예측하는 보상 모델을 학습한다. 3 단계 정책 최적화: 모델이 응답을 생성하고 Reward Model의 점수를 피드백으로 받아 강화학습 방식으로 정책을 개선한다. 사람은 주로 1·2 단계 데이터 작성/선호 비교에 직접 개입하고 3 단계에서는 학습된 보상 모델이 반복 피드백을 제공한다.

서술형 53. 거대 언어 모델의 디코딩 방법인 Greedy Decoding, Beam Search, Sampling, Temperature Sampling, Top-K Sampling, Top-P Sampling의 동작 원리와 장단점을 비교하여 서술하시오.

모범 답안/채점 핵심: Greedy는 매 단계 최고 확률 토큰을 선택해 빠르고 단순하지만 전역적으로 좋은 문장을 놓칠 수 있고 다양성이 낮다. Beam Search는 여러 후보 경로를 유지해 더 좋은 누적 확률의 문장을 찾을 수 있으나 계산 비용이 크고 생성 다양성이 낮을 수 있다. Sampling은 확률 분포에서 무작위 선택해 다양성이 높지만 품질 변동이 크다. Temperature는 분포의 뾰족함을 조절하며 $T < 1$ 은 안정적·보수적, $T > 1$ 은 다양하지만 오류 가능성이 증가한다. Top-K는 상위 K개 토큰만 후보로 제한해 극단적으로 낮은 확률 토큰을 제거한다. Top-P는 누적 확률 P를 만족하는 최소 후보 집합을 동적으로 구성해 문맥에 따라 후보 수가 달라진다.

서술형 54. 프롬프트 엔지니어링에서 시스템 프롬프트, 사용자 질의, Few-shot examples, Chain-of-Thought(CoT), Zero-shot CoT가 각각 어떤 역할을 하는지 설명하고, 예시를 제공하는 방식이 모델의 성능에 영향을 줄 수 있는 이유를 서술하시오.

모범 답안/채점 핵심: 시스템 프롬프트는 모델의 역할·행동 규칙·제약을 설정하고, 사용자 질의는 실제 요청을 전달한다. Few-shot examples는 입력-출력 예시로 과제 형식과 기대 행동을 문맥에서 보여준다. CoT는 중간 추론 과정을 포함한 예시/지시로 단계적 사고를 유도한다. Zero-shot CoT는 예시 없이 “단계적으로 생각하라” 같은 지시로 추론을 유도한다. 예시의 내용·형식·순서·유사성이 모델의 in-context 판단에 영향을 주므로 어떤 예시를 선택하는지가 성능을 크게 바꿀 수 있다.

서술형 55. 정답이 명확한 과제와 정답이 하나로 고정되지 않는 생성 과제를 나누어 거대 언어 모델 평가 방법을 설계하시오. Accuracy, ROUGE, 임베딩 기반 유사도, Perplexity, LLM-as-a-Judge를 언제 사용할 수 있는지 설명하고, LLM-as-a-Judge의 편향 및 거대 언어 모델의 응용 과정에서 주의해야 할 Hallucination과 Jailbreaking도 함께 서술하시오.

모범 답안/채점 핵심: 정답이 명확한 분류·객관식 등은 기준 정답과 직접 비교하는 Accuracy가 적합하다. 생성 과제는 표현이 다양하므로 ROUGE로 n-gram 겹침을 보고, 임베딩 기반 코사인 유사도로 의미적 유사성을 보완할 수 있다. Perplexity는 언어 모델이 시퀀스를 얼마나 잘 예측하는지 토큰 확률 기반으로 평가한다. LLM-as-a-Judge는 강한 LLM에 평가 기준을 주어 생성 응답을 채점·비교할 때 유용하지만 위치/순서 편향, 길이 편향, 자기 선호 편향이 있어 응답 순서 교환, 복수 평가를

자, 사람 평가와의 조합 등 보완이 필요하다. 응용 시 Hallucination 은 사실과 다른 내용을 그럴듯하게 생성하는 문제이고, Jailbreaking 은 프롬프트 우회로 안전 정책을 무력화하는 공격이므로 검증·가드레일·모니터링이 필요하다.